



UNIVERSIDAD PRIVADA DEL VALLE
FACULTAD DE INFORMÁTICA Y ELECTRÓNICA
CARRERA DE LICENCIATURA EN INGENIERÍA DE SISTEMAS
INFORMÁTICOS

SISTEMA WEB PREDICTIVO BASADO EN XGBOOST Y
EXPLICABILIDAD SHAP PARA EL APOYO EN LA ESTIMACIÓN
DE DEMANDA DE CURSOS Y DIPLOMADOS
CASO: ACADEMIA AUTOPOIESIS SERVICIOS EDUCATIVOS
INTEGRALES S.R.L.

PROYECTO DE GRADO PARA OPTAR AL
TÍTULO DE LICENCIATURA EN INGENIERÍA
DE SISTEMAS INFORMÁTICOS

POSTULANTE: JUAN DIEGO MAMANI COARITE

TUTOR: LIC. JULIO CESAR IRAHOLA FLORES

La Paz – Bolivia

2026

Dedicatoria

A mi madre y hermano. Aunque partieron de este mundo, su memoria no ha dejado de ser mi mayor inspiración. Este logro es para ustedes. Sé que me acompañan en cada paso.

A mi padre, has sido el apoyo más grande, mi compañero y amigo irremplazable, sufriste tanto o más que yo a lo largo de todo este camino.

Agradecimiento

Culminar este proyecto de grado no es un mérito que me pertenezca únicamente a mí; es el resultado de manos que me sostuvieron cuando el camino se tornó difícil.

Gracias infinitas a mi padre, mi motor principal, por caminar a lado mío todos estos años y demostrarme que la lealtad incondicional es el refugio más seguro.

A Octavio, mi tío, por ser un soporte vital para nuestra familia. Gracias por tu ayuda desinteresada e incondicional en los momentos más críticos; tu presencia nos mantuvo a flote cuando más lo necesitábamos.

Al mi tutor, Julio Cesar. Gracias por brindarme calma cuando la duda invadía mi mente. Su guía me devolvió la certeza y la claridad técnica en los momentos más complicados de la recta final de este trabajo.

A todos los docentes que me formaron semestre a semestre, su esencia, filosofía y conocimiento lograron forjarme técnica y académicamente para afrontar la vida profesional.

A la vida, por permitirme transformar la perseverancia, el esfuerzo y la ausencia en este triunfo.

Resumen

La Academia Autopoiesis enfrenta ineficiencias operacionales en la planificación de su oferta formativa debido a una gestión empírica y reactiva frente a un mercado educativo volátil. Para abordar esta problemática, la presente investigación tuvo como objetivo general desarrollar un sistema web predictivo basado en el algoritmo de aprendizaje automático XGBoost, potenciado con técnicas de explicabilidad SHAP, destinado a apoyar la estimación de la demanda de cursos y diplomados. Se adoptó un enfoque cuantitativo con un diseño no experimental, utilizando un conjunto de datos estructurado derivado de los registros históricos de inscripción correspondientes al periodo 2020-2026. La metodología incluyó un Análisis Exploratorio de Datos para identificar patrones de estacionalidad, seguido del entrenamiento computacional del modelo mediante validación cruzada y optimización exhaustiva de hiperparámetros. Los resultados revelaron un rendimiento algorítmico sobresaliente, alcanzando un Coeficiente de Determinación (R^2) del 85.4% y un Error Absoluto Medio de apenas 3.49 estudiantes. Asimismo, el análisis de explicabilidad identificó el costo oficial y el mes de lanzamiento como las variables determinantes en la matrícula. Finalmente, se concluye que el despliegue del ecosistema web dotó a la directiva de un instrumento administrativo proactivo que optimiza los recursos logísticos, transparenta el paradigma de caja negra y garantiza un soporte tecnológico confiable para la toma de decisiones estratégicas.

Palabras Clave: XGBoost, SHAP, Sistema Web, Predicción de Demanda, Machine Learning, Analítica Predictiva, Gestión Educativa.

Abstract

Academia Autopoiesis faces operational inefficiencies in planning its educational offerings due to empirical and reactive management in a volatile educational market. To address this issue, the general objective of this research was to develop a predictive web system based on the XGBoost machine learning algorithm, enhanced with SHAP explainability techniques, aimed at supporting the demand estimation of courses and diploma programs. A quantitative approach with a non-experimental design was adopted, utilizing a structured dataset derived from historical enrollment records for the 2020-2026 period. The methodology included an Exploratory Data Analysis to identify seasonality patterns, followed by the computational training of the model through cross-validation and exhaustive hyperparameter optimization. The findings revealed outstanding algorithmic performance, achieving a Coefficient of Determination (R^2) of 85.4% and a Mean Absolute Error of barely 3.49 students. Furthermore, the explainability analysis identified the official cost and the launch month as the determinant variables for enrollment. Finally, it is concluded that the deployment of the web ecosystem provided the board of directors with a proactive administrative instrument that optimizes logistical resources, clarifies the black box paradigm, and ensures reliable technological support for strategic decision-making.

Keywords: XGBoost, SHAP, Web System, Demand Prediction, Machine Learning, Predictive Analytics, Educational Management.

ÍNDICE DE CONTENIDO

CAPÍTULO I MARCO INTRODUCTORIO.....	1
1.1 INTRODUCCIÓN	1
1.2 PLANTEAMIENTO DEL PROBLEMA.....	2
1.2.1 ANTECEDENTES	2
1.2.2 CONTEXTUALIZACIÓN	2
1.2.3 IDENTIFICACIÓN DEL PROBLEMA	3
1.3 FORMULACIÓN DEL PROBLEMA.....	5
1.4 JUSTIFICACIÓN.....	5
1.4.1 JUSTIFICACIÓN SOCIAL	6
1.4.2 JUSTIFICACIÓN TÉCNICA.....	7
1.4.3 JUSTIFICACION ECONÓMICA	8
1.5 OBJETIVOS DE LA INVESTIGACIÓN	9
1.5.1 OBJETIVO GENERAL	9
1.5.2 OBJETIVOS ESPECIFICOS	9
1.6 DELIMITACIÓN	9
1.6.1 DELIMITACIÓN ESPACIAL	9
1.6.2 DELIMITACIÓN TEMPORAL	10
1.6.3 DELIMITACIÓN POBLACIONAL.....	10
1.6.4 DELIMITACIÓN TEMÁTICA.....	10
1.7 ALCANCES Y LIMITES	11
1.7.1 ALCANCES	11
1.7.2 LIMITES	12
1.7.3 EXPLICACIÓN DE LÍMITE TÉCNICO A LA AUSENCIA DE UN APLICATIVO MÓVIL ..	13
1.8 METODOLOGÍAS.....	13
1.8.1 ENFOQUE DE LA INVESTIGACIÓN	13
1.8.2 MÉTODO DE INVESTIGACIÓN	14
1.8.3 TIPO DE INVESTIGACIÓN	14
1.8.4 DISEÑO DE INVESTIGACIÓN	15
1.8.5 TÉCNICAS E INSTRUMENTOS.....	15
1.8.5.1 Técnicas de Investigación.....	15
1.8.5.2 Instrumentos de Recolección y Medición	16
1.9 POBLACIÓN.....	16

1.10	MUESTRA.....	16
CAPÍTULO II MARCO TEÓRICO.....		16
2.1	MARCO TEÓRICO	16
2.1.1	INGENIERIA DE SOFTWARE.....	16
2.1.2	MODELOS DE DESARROLLO	16
2.1.2.1	Modelo en Cascada.....	16
2.1.2.2	Modelo en V	17
2.1.2.3	Modelos Iterativos e Incrementales	17
2.1.2.4	Modelo Espiral.....	18
2.1.2.5	Metodologías Ágiles	18
2.1.2.6	Modelos Orientados a Ciencia de Datos (CRISP-DM)	18
2.1.3	LENGUAJE UNIFICADO DE MODELADO UML.....	19
2.1.3.1	Diagrama de Clases	20
2.1.3.2	Diagrama de Objetos	20
2.1.3.3	Diagrama de Componentes.....	21
2.1.3.4	Diagrama de Despliegue	22
2.1.3.5	Diagrama de Paquetes.....	22
2.1.3.6	Diagrama de Perfil.....	23
2.1.3.7	Diagrama de Casos de Uso.....	24
2.1.3.8	Diagrama de Actividades	25
2.1.4	METODOLOGÍA DE DESARROLLO DE SOFTWARE	27
2.1.4.1	Pilares y Valores de Scrum	27
2.1.4.2	Roles en Scrum	27
2.1.4.3	Eventos de Scrum	28
2.1.4.4	Artefactos de Scrum	28
2.1.5	HERRAMIENTAS DE DESARROLLO	30
2.1.5.1	Lenguaje de Programación Python.....	31
2.1.5.2	Frameworks Backend para el Desarrollo Web.....	31
2.1.5.3	Tecnologías Frontend y Desarrollo de Interfaces Web	32
2.1.5.4	Sistemas de Gestión de Bases de datos Relacionales	33
2.1.5.5	Herramientas de Colaboración y Control de Versiones	33
2.1.6	ESTIMACIÓN DE COSTOS	34
2.1.7	ASEGURAMIENTO DE CALIDAD	36
2.1.8	SEGURIDAD DEL SISTEMA	37
2.2	MARCO CONCEPTUAL	38
2.2.1	SISTEMA WEB PREDICTIVO	38
2.2.2	ALGORITMO XGBOOST	39

2.2.3	ESTIMACIÓN DE DEMANDA EDUCATIVA	39
2.2.4	APRENDIZAJE AUTOMÁTICO SUPERVIZADO	39
2.2.5	INTELIGENCIA ARTIFICIAL EXPLICABLE (XAI) Y SHAP	40
2.2.6	ANALÍTICA PREDICTIVA	40
2.2.7	INEFICIENCIA OPERACIONAL EN LA GESTIÓN DE ACTIVIDADES	41
2.2.8	VARIABLES DETERMINANTES EN EL COMPORTAMIENTO DE INSCRIPCIÓN	41
2.2.9	DATASET Y REGISTROS HISTÓRICOS DE INSCRIPCIONES	42
2.2.10	TOMA DE DECISIONES INSTITUCIONALES (APOYADA EN DATOS)	42
2.2.11	INGENIERÍA DE DATOS Y PREPROCESAMIENTO	43
2.2.12	ARQUITECTURA WEB CLIENTE-SERVIDOR	44
2.2.13	INTERFACES DE VISUALIZACIÓN DE DATOS (DASHBOARDS)	44
2.2.14	DESPLIEGUE DE MODELOS PREDICTIVOS EN PRODUCCIÓN (MODEL DEPLOYMENT)	44
2.2.15	ESTACIONALIDAD Y PATRONES DE DEMANDA EDUCATIVA	45
2.2.16	BASES DE DATOS RELACIONALES	45
2.2.17	INTERFACES DE PROGRAMACIÓN DE APLICACIONES (API REST)	46
2.2.18	MÉTRICAS DE EVALUACIÓN PARA MODELOS PREDICTIVOS	46
2.2.19	DISEÑO CENTRADO EN EL USUARIO (UX) E INTERFACES (UI)	46
2.2.20	SEGURIDAD DE LA INFORMACIÓN Y CONTROL DE ACCESO (ROLES)	47
2.3	MARCO INSTITUCIONAL	47
2.4	ESTADO DEL ARTE	49
2.4.1	ANÁLISIS DE REFERENTES INTERNACIONALES	49
2.4.1.1	Sistema de Alerta Temprana de Deserción Escolar basado en XGBoost	49
2.4.1.2	Predicción de Matrícula y Demanda Docente mediante Series de Tiempo	50
2.4.2	ANÁLISIS REFERENTES NACIONALES	51
2.4.2.1	Proyecto 3: Minería de Datos para la Identificación de Perfiles de Deserción	51
CAPÍTULO III INGENIERÍA DEL PROYECTO		54
3.1	INTRODUCCIÓN	54
3.2	OBJETIVOS DE LA PROPUESTA	54
3.3	DESARROLLO DE LA PROPUESTA	55
3.3.1	HISTORIAS DE USUARIO COMO PRODUCT BACKLOG	55
3.3.2	REQUERIMIENTOS FUNCIONALES	62
3.3.3	REQUERIMIENTOS NO FUNCIONALES	63
3.3.4	RECOPIACIÓN Y PROCESAMIENTO DE DATOS	65
3.3.4.1	Extracción de Datos Crudos Internos y Externos	65
3.3.4.2	Análisis exploratorio de Datos (EDA) Automatizado	67
3.3.4.3	Limpieza, Transformación (ETL) y Feature Engineering	68
3.3.5	DISEÑO ARQUITECTÓNICO DEL SISTEMA Y MODELADO	70

3.3.5.1	Diseño de Arquitectura de Microservicios Docker	70
3.3.5.2	Modelado Relacional de Base de Datos	71
3.3.5.3	Prototipado y Wireframing (Mockups)	73
3.3.5.4	Configuración del Entorno y Orquestación	78
3.3.6	ENTRENAMIENTO DEL MODELO PREDICTIVO XGBOOST	81
3.3.6.1	Comprensión del Negocio (Business Understanding)	82
3.3.6.2	Comprensión de los Datos (Data Understandig)	82
3.3.6.3	Preparación de los Datos (Data Preparation).....	83
3.3.6.4	Modelado (Modeling)	84
3.3.6.5	Evaluación de Desempeño (Evaluation)	86
3.3.6.6	Despliegue (Deployment)	86
3.3.7	DESARROLLO DE PLATAFORMA WEB Y MÓDULOS	87
3.3.7.1	Construcción del Backend (API REST) y Seguridad	88
3.3.7.2	Frontend React y Módulo de Gestión	89
3.3.8	INTEGRACIÓN DE EXPLICABILIDAD Y DESPLIEGUE	90
3.3.8.1	Integración de Explicabilidad (SHAP)	91
3.3.8.2	Panel Predictivo Interactivo y Decisiones Basadas en Datos	93
3.3.8.3	Despliegue Docker	95
3.3.9	PRUEBAS Y VALIDACIÓN del sistema	97
3.3.9.1	Pruebas Unitarias y de Aislamiento (Backend y Frontend).....	97
3.3.9.2	Pruebas de Integración y Concurrencia (API REST)	98
3.3.9.3	Validación Algorítmica y Cumplimiento de Criterios de Aceptación	99
3.3.9.4	Pruebas de Aceptación de Usuario (UAT) y Conformidad	100
3.4	RESULTADOS DE LA PROPUESTA.....	102
3.4.1	RESULTADOS DE ANÁLISIS DE VARIABLES DETERMINANTES	102
3.4.2	RESULTADOS DE LA APLICACIÓN DEL ALGORITMO XGBOOST	106
3.4.2.1	Entrenamiento, Métricas y Exposición del Sistema Web	109
3.4.3	RESULTADOS DE LA IMPLEMENTACIÓN DE EXPLICABILIDAD CON SHAP	111
3.4.3.1	Explicabilidad Global (Importancia de Variables).....	112
3.4.3.2	Explicabilidad Individual y Ranking Predictivo (Cascada de Decisiones).....	113
3.4.4	RESULTADOS DE LA APLICACIÓN DE ECOSISTEMA WEB	116
3.4.4.1	Frontend React y Módulo de Gestión	117
CAPÍTULO IV MARCO PRÁCTICO		133
4.1	PRESENTACIÓN DE RESULTADOS	133
4.1.1	RESULTADOS DEL PROCESAMIENTO Y CONSOLIDACIÓN DE DATOS (ETL)	133
4.1.2	RENDIMIENTO MATEMÁTICO DEL MODELO XGBOOST.....	135
4.1.3	VISUALIZACIÓN DE PREDICCIONES FUTURAS (DASHBOARDS REACT).....	137
4.1.4	TRANSPARENCIA ALGORITMICA Y EXPLICABILIDAD (SHAP)	140

4.1.5	EFICIENCIA OPERATIVA INTEGRAL	142
4.2	ANÁLISIS DE RESULTADOS	143
4.2.1	ANÁLISIS DEL ECOSISTEMA DE DATOS Y CORRELACIÓN DE VARIABLES	144
4.2.2	ANÁLISIS DEL RENDIMIENTO DEL ALGORITMO (XGBOOST)	144
4.2.3	ANÁLISIS DE LA ESTIMACIÓN DE LA DEMANDA (TARGET VS PREDICTED)	146
4.2.4	ANÁLISIS DE LA EXPLICABILIDAD (ROMPIENDO LA CAJA NEGRA)	146
4.2.5	ANÁLISIS DE LA EFICIENCIA OPERATIVA Y DEMOCRATIZACIÓN VISUAL	148
CAPÍTULO V CONCLUSIONES		150
5.1	CONCLUSIONES	150
5.1.1	CUMPLIMIENTO DEL OBJETIVO GENERAL	150
5.1.2	cumplimiento objetivos específicos	151
5.1.2.1	Primer Objetivo Específico	151
5.1.2.2	Segundo Objetivo Específico	152
5.1.2.3	Tercer Objetivo Específico	153
5.1.2.4	Cuarto Objetivo Específico	155
5.1.2.5	Quinto Objetivo Específico	156
5.2	RECOMENDACIONES	157
APÉNDICES		1

ÍNDICE DE FIGURAS

Figura 1.1: Diagrama de Ishikawa.....	14
Figura 2.1: Ejemplo Diagrama de Clases.....	20
Figura 2.2: Ejemplo Diagrama de Objetos	21
Figura 2.3: Ejemplo Diagrama de Componentes	21
Figura 2.4: Ejemplo Diagrama de Despliegue.....	22
Figura 2.5: Ejemplo Diagrama de Paquetes.....	23
Figura 2.6: Ejemplo Diagrama de Perfil.....	23
Figura 2.7: Ejemplo Diagrama de Casos de Uso	24
Figura 2.8: Ejemplo Diagrama de Actividades	25
Figura 2.9: Ejemplo Diagrama de Secuencia	25
Figura 2.10: Procesos Scrum.....	28
Figura 2.11: Procesos Scrum (Adaptado)	29
Figura 3.1: Datos Crudos Academia Autopoiesis	61
Figura 3.2: Extracción de los Datos Crudos	66
Figura 3.3: Proceso EDA.....	66
Figura 3.4: Procesos ETL.....	68
Figura 3.5: Culminación de ETL.....	69
Figura 3.7: Diagrama de la Arquitectura del Sistema	70
Figura 3.8: Modelado de Bases de Datos	71
Figura 3.9: Diseño Mockup “Home Page”	72
Figura 3.9: Diseño Mockup “Login”	73
Figura 3.10: Diseño Mockup “Panel Inicio”.....	73
Figura 3.11: Diseño Mockup “Panel Predictivo”	74
Figura 3.12: Diseño Mockup “Panel Inscripciones”	74
Figura 3.13: Carpetas y Estructura base del proyecto en VSCode	75
Figura 3.14: Estructura Principal de archivo docker-compose.yaml.....	76
Figura 3.15: Imágenes dockerizadas	77
Figura 3.16: Prueba de funcionamiento de Backend	78
Figura 3.17: Prueba de funcionamiento de Frontend	78

Figura 3.18: Repositorio GitHub	79
Figura 3.19: Entrenamiento XGBoost y Optuna	92
Figura 3.20: Tabla de Métricas o Curva de Error	93
Figura 3.21: Home Page Sistema web	94
Figura 3.22: Cursos Page Sistema web	95
Figura 3.23: Diplomados Page Sistema web	95
Figura 3.24: Login Page Sistema web.....	96
Figura 3.25: Registro Page Sistema web	96
Figura 3.26: Auth Page Sistema web	97
Figura 3.27: Admin Dashboard Sistema Web	98
Figura 3.28: Beneficios Sistema web	99
Figura 3.29: Administración de Facilitadores Sistema web	99
Figura 3.30: Inscripciones Sistema web.....	100
Figura 3.31: Registro de Estudiantes Sistema web.....	100
Figura 3.32: Registro Histórico de Cohortes Sistema web	101
Figura 3.33: IA Predictiva Sistema web.....	101
Figura 3.34: Mailing Sistema web	102
Figura 3.35: Configuración de Perfil Sistema web	102
Figura 3.36: Activación de Autenticación Sistema web	103
Figura 3.37: Footer Boletín Informativo Directo Sistema web	103
Figura 3.38: Panel Estudiante Sistema web.....	104
Figura 3.39: Panel Facilitador Sistema web	104
Figura 3.40: Visualización SHAP lista para Mostrarse	106
Figura 3.41: Despliegue Final	106
Figura 3.42: Gráfico de Correlación o Distribución de Datos	108
Figura 3.43: Estructura de Feature Store en PostgreSQL.....	108
Figura 3.44: JSON de Métricas de XGBoost.....	110
Figura 3.45: Gráfico de Predicción (Target vs Predicted).....	110
Figura 3.46: Explicabilidad SHAP en un caso concreto	112
Figura 4.1: Consolidación del Feature Store	115
Figura 4.2: Reporte de Métricas del Modelo	116
Figura 4.3: Gráfico de Demanda vs Predicción	117

Figura 4.4: SHAP – Importancia Global	118
Figura 5.1: Acta de Conformidad	121
Figura 5.2: Rezagos Cronológicos y Variables Estructuradas	121
Figura 5.3: Comportamiento y Estacionalidad / EDA	122
Figura 5.4: Optimización de XGBoost (Optuna)	123
Figura 5.5: Funcionamiento del Sistema	124

ÍNDICE DE TABLAS

Tabla 3.1: Historia de Usuario (Autenticación y Permisos de Acceso Según el Rol)	67
Tabla 3.2: Historia de Usuario (Gestión de Cursos y Diplomados)	68
Tabla 3.3: Historia de Usuario (Carga y Gestión de Datos Históricos).....	69
Tabla 3.4: Historia de Usuario (Panel de Registros Históricos).....	69
Tabla 3.5: Historia de Usuario (Predicción de Comportamiento de futuros programas activos).....	70
Tabla 3.6: Visualización de Factores Influyentes	71
Tabla 3.7: Historia de Usuario (Reportes de Planificación)	71
Tabla 3.8: Historia de Usuario (Búsqueda y Filtros de Programas)	72
Tabla 3.9: Origen de Captación en Inscripciones.....	73
Tabla 3.10: Requerimientos Funcionales	73
Tabla 3.11: Requerimientos No Funcionales	75

CAPÍTULO I

MARCO INTRODUCTORIO

CAPÍTULO I

MARCO INTRODUCTORIO

1.1 INTRODUCCIÓN

La Academia Autopoiesis, como institución emergente en la ciudad de La Paz, ha orientado sus esfuerzos a la formación en áreas de investigación, arte y cultura, mediante cursos cortos, diplomados y actividades culturales abiertas a la comunidad. No obstante, enfrenta dificultades estructurales que limitan su sostenibilidad y crecimiento: baja inscripción de participantes a raíz de la crisis económica, promoción no estratégica en redes sociales, registros manuales poco sistematizados y una carencia de herramientas tecnológicas integradas para la gestión de datos y difusión de actividades.

El contexto actual indica que las instituciones educativas, particularmente en contextos de incertidumbre económica y alta competencia, requieren apoyarse en herramientas de predicción de demanda para optimizar la oferta de programas académicos. Entre los algoritmos de aprendizaje automático supervisado, XGBoost, ha demostrado un desempeño sobresaliente en la predicción de fenómenos educativos complejos, como la deserción y la matrícula.

En este marco, se propone el desarrollo de un sistema web predictivo, informativo e interactivo, que no solo integre datos históricos de inscripciones, costos y modalidades, sino que además brinde un entorno de interacción y retroalimentación académica. El sistema incorporará un modelo de predicción basado en XGBoost, cuyo objetivo será estimar la demanda local de cursos y diplomados de la Academia Autopoiesis. De esta manera, la institución podrá planificar con mayor certeza la apertura de programas, optimizar sus recursos económicos y fortalecer su impacto cultural en la comunidad paceña y boliviana.

Este proyecto, al combinar un enfoque cuantitativo y aplicado, busca responder a las diferentes complicaciones que sufre la academia actualmente las cuales se resumen en ineficiencia. La propuesta académica se alinea con tendencias internacionales en educación superior, donde la transformación digital y el uso de analítica avanzada constituyen herramientas estratégicas para la gestión institucional.

1.2 PLANTEAMIENTO DEL PROBLEMA

1.2.1 ANTECEDENTES

En el ámbito internacional, la predicción de la demanda educativa ha sido abordada mediante modelos de series temporales y Machine Learning. Wu, Chen y Chen, (2020) utilizaron análisis de series de tiempo para estimar la matrícula y la demanda docente en Taiwán, logrando resultados precisos que orientaron la planificación educativa. De forma más reciente, Tapio y Tarepe (2025) compararon Random Forest y un modelo híbrido ARIMA–RF para pronosticar inscripciones en educación superior, concluyendo que los enfoques híbridos ofrecen mayor exactitud en entornos dinámicos.

Por otro lado, los sistemas web predictivos han cobrado relevancia en universidades y colegios como herramientas para mejorar la gestión institucional. Carballo-Mendivil et al. (2025) desarrollaron un sistema de alerta temprana con XGBoost, capaz de predecir con alta sensibilidad la deserción de estudiantes desde su inscripción. Asimismo, Bermúdez e Hidalgo (2024) implementaron un sistema web en Perú que utilizó algoritmos bayesianos para predecir riesgo académico en secundaria, alcanzando niveles de exactitud superiores al 90%. Estos antecedentes demuestran la viabilidad y pertinencia de integrar algoritmos avanzados en plataformas web educativas.

En Bolivia, los estudios en esta línea aún son limitados, aunque comienzan a desarrollarse iniciativas de minería de datos aplicadas a la educación superior. Bedregal, Aruquipa y Cornejo (2020) aplicaron técnicas de “Data Mining” para identificar perfiles de deserción universitaria en Cochabamba, mostrando la necesidad de emplear enfoques predictivos en la gestión académica. Adicionalmente, informes del Banco Mundial han resaltado que la educación superior boliviana enfrenta altas tasas de deserción y dificultades de planificación de oferta académica (Ferreira, 2017), lo que refuerza la pertinencia de propuestas de investigación que incorporen técnicas modernas de predicción.

1.2.2 CONTEXTUALIZACIÓN

Autopoiesis Academia es un espacio que nace a partir de la inquietud de promover la formación permanente de profesionales y personas en proceso de formación, interesados en la investigación y temáticas educativas y artísticas.

Hace aproximadamente cuatro años, la academia se constituyó legalmente, obteniendo su personería jurídica y registro formal en el CEPREC (Servicio Plurinacional de Registro de Comercio). Desde entonces, ha realizado una serie de actividades formativas y de promoción cultural, incluyendo la publicación de una revista digital. La academia actualmente busca consolidar su trabajo en la ciudad de La Paz y continuar expandiendo su alcance a nivel nacional, estructurándose en tres áreas fundamentales: Formación, Comunicación/Divulgación, y Promoción de artes y obras.

En este sentido, la presente investigación se alinea con la necesidad nacional de innovar en modelos de gestión académica, ofreciendo un caso de estudio aplicado en una institución emergente que busca consolidarse como referente en formación psicológica, pedagoga e investigativa en la ciudad de La Paz y Bolivia.

Actualmente, el 90% de las actividades formativas de la Academia Autopoiesis son de carácter virtual, permitiendo la participación de personas tanto de La Paz como del interior del país. Para la impartición de clases sincrónicas, la academia hace uso de plataformas de videoconferencia como Zoom y Google Meet. Para las actividades asincrónicas, se utiliza Google Classroom, y la institución se encuentra en proceso de adquirir una licencia para implementar una plataforma Moodle (Modular Object-Oriented Dynamic Learning Environment / Entorno de Aprendizaje Dinámico Orientado a Objetos y Modular). (Fuente, Anexo 1).

1.2.3 IDENTIFICACIÓN DEL PROBLEMA

Mediante el análisis basado en el Diagrama de Ishikawa (Diagrama de Espina de Pescado), se identifican las causas raíz que convergen en el problema central de la institución. Este análisis se desglosa en las siguientes dimensiones:

Métodos: Determinación inexacta de mercados educativos al depender exclusivamente de la intuición administrativa para la apertura de cohortes.

Materiales (Datos): Dispersión de la información en plataformas externas como Zoom, Meet y Classroom, lo que impide una visión consolidada del comportamiento histórico de los inscritos.

Tecnología: Información escasa y limitada que permita conocer las tendencias de estudio al interior de la oficina.

Entorno: Alta volatilidad en la oferta académica digital post-pandemia, lo que incrementa el riesgo de deserción o falta de quórum en los programas ofertados.

Estudio (Mercado): Los productos académicos son lanzados a discreción del personal administrativo y gerencial, presentando resultados inesperados en la afluencia de usuarios.

Recurso Humano (Personal): Centralización de la toma de decisiones basada en juicios subjetivos, debido al uso exclusivo del criterio personal como referente.

Declaración del Problema:

Existe una marcada deficiencia en la capacidad de estimación de demanda para cursos y diplomados en la Academia Autopoiesis, debido a decisiones basadas exclusivamente en el criterio personal y decisiones de administrativos con datos limitados y propensos a errores humanos.

Figura 1.1: Diagrama de Ishikawa



Fuente: Elaboración propia, 2026

1.3 FORMULACIÓN DEL PROBLEMA

¿Cómo se puede mejorar la certeza de la planificación administrativa de oferta académica frente a la baja capacidad de estimación de demanda de cursos y diplomados en la Academia Autopoiesis?

1.4 JUSTIFICACIÓN

El desarrollo de un Sistema Web Predictivo para la Gestión de la Oferta Académica en la Academia Autopoiesis constituye una necesidad estratégica para fortalecer su posicionamiento como institución formativa emergente. En un contexto de alta competencia y restricciones económicas, se vuelve imprescindible optimizar los procesos de planificación académica.

Actualmente, la oferta académica se planifica mediante modelos fijos y rígidos. Esta forma de gestión genera ineficiencias institucionales que afectan directamente la sostenibilidad y la capacidad de crecimiento de la Academia.

Como resultado, se producen situaciones de sobreoferta en programas con baja demanda y, paralelamente aunque de manera menos común, suboferta en cursos y diplomados con mayor interés. Esta falta de alineación impide un uso eficiente de los recursos disponibles.

Estas ineficiencias impactan negativamente en la toma de decisiones administrativas. Asimismo, limitan la capacidad de la institución para reaccionar de manera oportuna frente a las dinámicas cambiantes del mercado educativo.

Ante este escenario, el proyecto propone la transición de un modelo de gestión reactivo hacia uno proactivo y predictivo. Para ello, se plantea el uso de análisis de datos y herramientas de inteligencia artificial que permitan anticipar el comportamiento de la demanda.

Finalmente, la justificación del proyecto se sustenta en tres ejes fundamentales: impacto social, sostenibilidad económica y viabilidad técnica. Estos elementos respaldan la pertinencia de implementar un sistema web predictivo como herramienta estratégica para la gestión institucional.

1.4.1 JUSTIFICACIÓN SOCIAL

La propuesta de un sistema web predictivo tiene un impacto social significativo. En primer lugar, permitirá que más estudiantes y profesionales accedan a ofertas formativas pertinentes y oportunas, al asegurar que los cursos se planifiquen de acuerdo con la demanda real. Esto se traduce en una mayor inclusión educativa, especialmente en contextos donde los recursos económicos son limitados y los participantes deben priorizar entre la educación y la satisfacción de necesidades básicas (Apéndice A).

En segundo lugar, al optimizar la difusión de actividades, se ampliará el alcance cultural de la Academia, fortaleciendo su rol como agente promotor de arte, ciencia y cultura.

La posibilidad de contar con un sistema que visibilice la oferta formativa en tiempo real mejorará la conexión con la comunidad, incentivando una mayor participación en master class gratuitas, cursos y diplomados.

El desarrollo del sistema web predictivo para la Academia Autopoiesis ofrece beneficios directos para los cursantes, ya que asegura un mayor acceso a ofertas formativas pertinentes y oportunas mediante una planificación basada en la demanda real. Esto fomenta la inclusión educativa y mejora la pertinencia de los cursos y diplomados ofertados.

Asimismo, el sistema proporciona un entorno interactivo que integra recursos documentales y espacios de colaboración, fortaleciendo la experiencia formativa y facilitando la participación activa de los estudiantes en las actividades académicas.

Para la institución, el sistema permite optimizar la planificación y el uso de los recursos al reducir riesgos financieros asociados a situaciones de sobreoferta o suboferta. Además, mejora la gestión operacional mediante la centralización de datos y fortalece la toma de decisiones estratégicas a través del uso de modelos predictivos como XGBoost y técnicas de explicabilidad con SHAP, generando un modelo de gestión replicable para otras instituciones educativas emergentes del país.

1.4.2 JUSTIFICACIÓN TÉCNICA

El presente proyecto se justifica técnicamente por la pertinencia y viabilidad de las herramientas seleccionadas para el desarrollo del sistema web predictivo.

Considerando que la empresa requiere predecir la demanda estimada de cursos y diplomados, es necesario entrenar un modelo de aprendizaje supervisado que permita realizar esta tarea con un alto grado de precisión, para ello se utilizará Python como lenguaje principal para el modelado de datos, debido a su robusto ecosistema de librerías científicas como Pandas, NumPy y Scikit-learn, así como a su compatibilidad nativa con XGBoost, algoritmo de aprendizaje automático supervisado seleccionado para la predicción de la demanda (Chen & Guestrin, 2016). La versatilidad de Python facilita una integración eficiente con bases de datos y frameworks web, simplificando la transición de los modelos de inferencia hacia entornos reales de producción.

En cuanto a la arquitectura del software, se utilizará Flask como framework de backend, permitiendo la construcción modular de servicios orientados al registro de participantes, la gestión de cursos y el procesamiento de reportes en tiempo real. Esta arquitectura favorece la escalabilidad y el mantenimiento del sistema.

Para la interfaz de usuario y la visualización de resultados, se implementará el framework React en conjunto con HTML5, CSS3 y JavaScript, garantizando un diseño adaptable y accesible desde dispositivos móviles (para usuarios generales, estudiantes y

facilitadores) y de escritorio. React permite gestionar de forma dinámica los datos generados por el modelo predictivo, transformando las salidas de XGBoost en componentes visuales de fácil interpretación para el usuario final.

Finalmente, la persistencia de la información se gestionará mediante PostgreSQL, seleccionada por su estabilidad, integridad relacional y sólido soporte comunitario. Esta base de datos permitirá almacenar de forma segura los registros históricos de inscripciones y las variables críticas para el análisis educativo, garantizando la solvencia técnica y la escalabilidad del sistema propuesto.

1.4.3 JUSTIFICACION ECONÓMICA

La propuesta del sistema web predictivo está orientada a impulsar el progreso económico de la Academia Autopoiesis mediante la mitigación directa de la ineficiencia operacional. El sistema permitirá directa o indirectamente un apoyo financiero a través de la minimización de riesgos, principalmente al reducir las pérdidas derivadas de la suboferta de programas académicos; de esta manera, la capacidad predictiva de XGBoost mejora la planificación y asignación de cupos, contribuyendo directamente a la sostenibilidad institucional. Adicionalmente, se logra la eliminación de costos ocultos al centralizar el control de pagos y registros, evitando los errores humanos inherentes al manejo manual de la información.

En términos de inversión, el proyecto asegura un impacto positivo al requerir un gasto mínimo en tecnología, gracias a la selección estratégica de herramientas de código abierto como Python, Flask, React y PostgreSQL, lo que elimina por completo los costos de licenciamiento y la dependencia de software propietario. El bajo costo de mantenimiento se limita a gastos básicos de hosting en Bolivia, o bien al aprovechamiento de planes de bajo costo para instituciones académicas ofrecidos por servicios en la nube.

Finalmente, el sistema transforma la dinámica interna mediante un ahorro significativo de tiempo y la mejora de la eficiencia operativa; la centralización de registros y el seguimiento automatizado reducen la carga administrativa y las tareas manuales morosas. Esto permite una toma de decisiones proactiva, ya que el sistema anticipa la

demanda y libera al personal para enfocarse en la misión estratégica de la Academia, representando, en suma, una inversión mínima que proporciona un beneficio significativo al optimizar recursos, reducir pérdidas y maximizar la productividad institucional predictivo.

1.5 OBJETIVOS DE LA INVESTIGACIÓN

1.5.1 OBJETIVO GENERAL

Desarrollar un sistema web para mejorar la gestión de cursos y diplomados con el uso del algoritmo XGBoost (eXtreme Gradient Boosting) y explicabilidad SHAP (Shapley Additive exPlanations), para la estimación de demanda en la Academia Autopoiesis.

1.5.2 OBJETIVOS ESPECIFICOS

- Identificar las variables históricas, académicas y de mercado que influyen en las inscripciones de la institución mediante la recolección de registros previos para la estructuración del conjunto de datos base (Dataset) del estudio.
- Analizar los patrones de estacionalidad y el comportamiento estudiantil aplicando técnicas de EDA (Exploratory Data Analysis / Análisis Exploratorio de Datos) para el descubrimiento de tendencias subyacentes en la demanda académica.
- Evaluar el rendimiento predictivo del algoritmo XGBoost (eXtreme Gradient Boosting) frente a la variabilidad de los datos recopilados para la validación de su nivel de exactitud y viabilidad técnica como motor central.
- Interpretar el peso de las decisiones matemáticas del algoritmo utilizando la librería SHAP (SHapley Additive exPlanations / Explicaciones Aditivas de Shapley) para la generación de explicabilidad y transparencia técnica (XAI) en los resultados proyectados.

1.6 DELIMITACIÓN

1.6.1 DELIMITACIÓN ESPACIAL

La investigación se desarrollará en torno a la Academia Autopoiesis, una institución privada emergente dedicada a la formación en artes e investigación, cuya sede administrativa se encuentra en el centro de La Paz, Bolivia. Aunque su base física está en esta ciudad, sus actividades formativas son en su gran mayoría virtuales, lo que

amplía su alcance y permite la participación de cursantes provenientes de diferentes regiones del país. La elección de esta institución como caso de estudio responde a la necesidad de mejorar su planificación académica mediante herramientas predictivas, dado que actualmente depende de registros manuales y posee una limitada visibilidad digital.

Si bien el proyecto se centra en la gestión institucional con sede en La Paz, la naturaleza virtual de la Academia extiende de forma natural su presencia a nivel nacional. Esto refuerza la relevancia del estudio, ya que las mejoras en eficiencia, gestión y predicción de la demanda no solo impactarán su estructura administrativa local, sino también a la comunidad estudiantil distribuida en el interior del país.

1.6.2 DELIMITACIÓN TEMPORAL

El estudio abarcará el periodo comprendido entre marzo y mayo de 2026, alineado estrictamente con el cronograma de sprints de desarrollo (Apéndice C). Durante este lapso se realizará la recolección de datos históricos y actuales, el entrenamiento y validación del modelo XGBoost (eXtreme Gradient Boosting), y el despliegue dockerizado final del sistema web predictivo.

1.6.3 DELIMITACIÓN POBLACIONAL

La población objetivo está conformada por estudiantes universitarios y profesionales que participan en los cursos cortos y diplomados ofrecidos por la Academia Autopoiesis. De acuerdo con la información del director, y ajustada a la estrategia de rotación y tamaño de cohortes planificada, la matrícula promedio total proyectada por gestión (anual) oscilaría entre 900 y 1300 participantes en todos sus programas, provenientes de diversas áreas (psicología, criminología, investigación académica, leyes, tecnología) y se consideran las gestiones de: Finales del 2020, 2021, 2022, 2023, 2024, 2025 y parte del 2026.

1.6.4 DELIMITACIÓN TEMÁTICA

La investigación se fundamenta en los principios del aprendizaje automático supervisado (Supervised Machine Learning), particularmente el algoritmo XGBoost (eXtreme Gradient Boosting), como herramienta para apoyar la gestión de programas y a la

predicción de demanda educativa. Se limita al desarrollo de un modelo predictivo aplicado a datos institucionales, sin profundizar en los componentes puramente contables o pedagógicos del proceso formativo.

1.7 ALCANCES Y LIMITES

1.7.1 ALCANCES

El sistema web generado será utilizado por la Administradora Académica para:

- Realizar la toma de decisiones con el apoyo de predicciones de la demanda por curso o diplomado, clasificado y mostrando el índice de confiabilidad, margen de incertidumbre y volatilidad esperada.
- Visualizar un dashboard interactivo, el cual presentará métricas clave y reportes automáticos sobre la oferta académica.
- Visualizar la Integración del algoritmo XGBoost potenciado por técnicas de “explicabilidad” (SHAP) para resolver el problema de la “caja negra”, transformando el modelo en una herramienta transparente que permita a los administradores a interpretar las variables determinantes.
- Generación de reportes en formato PDF con resultados del modelo predictivo en función del curso o diplomado.
- Visualizar dashboards estadísticos en secciones de registros históricos (Programas, Estudiantes).
- Visualizar un ranking de programas potenciales para lanzar en los siguientes meses.

Será utilizado por el Estudiante:

- Para consultar información general acerca de la academia como sus programas disponibles, inscribirse a las mismas.

Será utilizado por el Docente/Facilitador:

- Consultar información acerca de cursos o diplomados en los cuales imparte.

El desarrollador especifica que:

- El proyecto se centra exclusivamente en el Sistema Web siendo responsivo para conexiones móviles de usuarios generales o estudiantes.
- La limpieza y almacenamiento estructurado de los datos históricos se basan en registros de inscripciones desde la gestión 2020 a 2026 (en curso).
- La predicción de demanda es influenciada por: Mes, Costo, Modalidad, Tipo de Programa, Categoría.
- La Implementación de roles básicos son:
Administrador académico, Estudiante, Facilitador, Usuario General consulta y suscripción a boletín informativo.
- Se incorpora un sistema de seguridad de 2FA.

1.7.2 LIMITES

Los límites planteados para el proyecto son:

- El modelo predictivo dependerá estrictamente de la cantidad y calidad de la data recolectada (datos históricos de inscripciones, costos y modalidades); las inconsistencias o registros incompletos afectarán a la precisión de las predicciones.
- El sistema actuará como una herramienta de apoyo a la toma de decisiones, pero no automatizará ni reemplazará la gestión administrativa directa ni la ejecución de las estrategias de marketing digital de la Academia.
- La predicción del sistema se limitará al análisis de variables cuantificables (mes, año, categoría, precio, edad estudiante) todos estos datos codificados para poder entrenar al modelo y tendrán como variable dependiente (cupos reales/tamaño cohorte).
- El uso del algoritmo XGBoost y el sistema estarán restringidos al entorno web educativo de la Academia Autopoiesis y no contemplará su escalabilidad automática a otros dominios externos.
- Las predicciones no representan valores absolutos ni garantizan resultados reales.
- El modelo se entrena con datos históricos acotados a un periodo específico.

- No se incorporan variables externas macroeconómicas o sociales no estructuradas.
- El modelo se valida sólo con datos de la institución.
- No se implementan mecanismos avanzados de seguridad o cifrado.
- El sistema no sustituye sistemas administrativos existentes.

1.7.3 EXPLICACIÓN DE LÍMITE TÉCNICO A LA AUSENCIA DE UN APLICATIVO MÓVIL

El presente proyecto contempla únicamente el desarrollo de un Sistema Web y no contará con el desarrollo de un aplicativo móvil nativo. Técnicamente, esta decisión se justifica debido a que las funcionalidades principales del software como el análisis de grandes volúmenes de datos, la visualización de dashboards predictivos complejos y la interpretación de métricas de Machine Learning (SHAP), requieren de un entorno de escritorio con pantallas de mayor resolución para su correcta interpretación analítica por parte del personal administrativo. Adicionalmente, la selección de tecnologías web responsivas (como Bootstrap) permitirá que las interfaces del sistema se adapten y sean accesibles desde navegadores en dispositivos móviles, satisfaciendo cualquier necesidad de consulta remota sin incurrir en el costo computacional y de tiempo que implicaría desarrollar, mantener y licenciar una aplicación móvil independiente para Android o iOS, pero esto en cuanto a todo usuario que no sea Administrador.

1.8 METODOLOGÍAS

1.8.1 ENFOQUE DE LA INVESTIGACIÓN

Para el desarrollo de este proyecto se adoptó un enfoque cuantitativo.

Este enfoque se define como un proceso secuencial y probatorio que utiliza la recolección de datos para probar hipótesis, fundamentándose en la medición numérica y el análisis estadístico para establecer patrones de comportamiento y probar teorías (Hernández Sampieri, 2018).

La pertinencia de este enfoque para la presente investigación radica en la necesidad de dimensionar y medir objetivamente la problemática de la "Baja capacidad de estimación de demanda". Se busca recolectar datos numéricos sobre las variables que influyen en

la demanda, como la cantidad de inscritos, cupos, precios y porcentaje de origen de captación de inscritos, que permitan un análisis estadístico riguroso. Esta cuantificación es fundamental para establecer un diagnóstico preciso que sirva como fundamento para el "desarrollo de un sistema web predictivo basado en aprendizaje automático supervisado (XGBoost)" y, posteriormente, permita evaluar la efectividad de la solución propuesta para minimizar dicho problema.

1.8.2 MÉTODO DE INVESTIGACIÓN

Se aplicará el método analítico. Este método es un proceso cognoscitivo que consiste en descomponer un objeto de estudio (el problema) en sus partes constitutivas para examinarlas en profundidad, identificar sus relaciones y comprender su esencia (Hernández Sampieri, 2018).

La pertinencia de este método para el proyecto radica en que permite descomponer la problemática general de la "ineficiencia operacional" en sus variables determinantes. Tal como se plantea en los objetivos, es necesario analizar por separado factores como los datos históricos de inscripciones, costos, modalidades y variables externas. Al estudiar estas partes, se podrá comprender cómo influye cada una en la demanda. Posteriormente, el método sintético (la contraparte del analítico) se aplicará al construir el modelo XGBoost, reintegrando estas variables para crear un sistema predictivo que explique el fenómeno en su conjunto.

1.8.3 TIPO DE INVESTIGACIÓN

El proyecto se clasifica como una investigación de tipo aplicada y de alcance predictivo.

La investigación aplicada busca resolver problemas prácticos e inmediatos en un contexto específico (Hernández Sampieri, 2018). El alcance predictivo (a menudo considerado una extensión del explicativo) se enfoca en anticipar el comportamiento futuro de un fenómeno.

Este proyecto es aplicado porque su finalidad no es generar teoría pura, sino solucionar una necesidad concreta de la Academia Autopoiesis: la "Baja capacidad de estimación de demanda" y la necesidad de optimizar su planificación académica. Es predictivo porque el núcleo de la investigación utiliza aprendizaje automático no solo para describir

la demanda pasada, sino para anticipar el comportamiento futuro de las inscripciones, permitiendo a la institución tomar decisiones proactivas.

1.8.4 DISEÑO DE INVESTIGACIÓN

Se empleará un diseño no experimental.

Un diseño no experimental es aquel donde la investigación se realiza sin manipular deliberadamente las variables; se observan los fenómenos tal y como ocurren en su contexto natural para después analizarlos (Hernández Sampieri, 2018).

Este diseño es el idóneo para el proyecto porque el investigador no manipulará variables (como forzar cambios en los precios o la publicidad para ver qué ocurre). En su lugar, observará los registros históricos de la Academia tal como se dieron naturalmente.

1.8.5 TÉCNICAS E INSTRUMENTOS

De acuerdo con el enfoque cuantitativo y el diseño de investigación no experimental planteado, las técnicas e instrumentos utilizados se enfocan en la recolección, estructuración y evaluación rigurosa de datos numéricos.

1.8.5.1 Técnicas de Investigación

El Análisis Documental y Extracción de Datos constituye la técnica principal del estudio, utilizada para la extracción y recopilación de los registros históricos institucionales (inscripciones, beneficios, estudiantes) y variables exógenas del mercado a lo largo del tiempo, sin manipular el entorno de manera intencional.

Medición de Rendimiento y Análisis de Métricas, que es la técnica cuantitativa aplicada para la evaluación continua del desempeño, precisión y capacidad de generalización del modelo predictivo (XGBoost) frente a los datos reales.

Entrevista (ver Apéndice A, como apoyo de diagnóstico), técnica de recolección empleada en la fase introductoria del proyecto para comprender el contexto institucional y delimitar el problema de ineficiencia operacional desde la perspectiva de la dirección.

1.8.5.2 Instrumentos de Recolección y Medición

Registros del Sistema y Matrices de Datos, este instrumento conformado por los archivos administrativos base (como `seed_programas.json`), las bases de datos relacionales (Feature Store en PostgreSQL) que conforman el dataset de la investigación.

Matriz de Métricas de Evaluación, un instrumento matemático-estadístico utilizado para cuantificar la eficiencia de la inteligencia artificial, midiendo específicamente indicadores como el Error Cuadrático Medio (RMSE), Error Absoluto Medio (MAE) y el Coeficiente de Determinación (R^2).

Guía de Entrevista que es la herramienta compuesta por preguntas directrices aplicada a la dirección de la Academia Autopoiesis (ver Apéndice A) para el levantamiento inicial de la problemática y necesidades institucionales.

1.9 POBLACIÓN

La población de referencia para el entrenamiento del modelo predictivo corresponde a la totalidad de inscripciones realizadas en los cursos cortos y diplomados ofrecidos por la Academia Autopoiesis, conformando un dataset de ofertas de cursos durante el periodo analizado, específicamente del 2020 al 2026. Este dataset integral es fundamental para un enfoque cuantitativo robusto y abarca las variables críticas necesarias para la modelización. Estas incluyen variables de Inscripción y Operación (cupos, precios en bolivianos, descuentos, asistencia), variables de Difusión (origen de captación), y variables de Gestión Administrativa (registros de docentes y gestores académicos), ya que todas ellas aportan datos relevantes para la predicción de la demanda.

Es crucial garantizar la calidad de este dataset, sometiéndolo a un riguroso preprocesamiento que incluye limpieza, normalización y codificación, para evitar que inconsistencias o registros incompletos afecten la precisión predictiva del modelo.

1.10 MUESTRA

Debido a la naturaleza predictiva del proyecto y al uso del algoritmo de aprendizaje automático XGBoost, aplicar una fórmula de muestreo probabilístico tradicional para extraer una porción reducida de datos resulta técnica y metodológicamente inviable, ya

que los modelos de Inteligencia Artificial requieren el mayor volumen de datos posible para identificar patrones no lineales y evitar el sesgo de información.

Por lo tanto, se aplicará un muestreo no probabilístico de tipo censal (o intencional), donde la muestra de estudio estará conformada por el 100% de la población accesible; es decir, la totalidad de los aproximadamente 3,000 registros históricos estructurados en el Feature Store. Las cuales pasarán por un proceso de preparación/consolidación/agregación para que estos datos crudos estén listos, agrupándolos en cohortes que es el objetivo de predicción.

Para asegurar la validación científica y el rigor cuantitativo del modelo predictivo sin incurrir en fuga de datos (Data Leakage), esta muestra censal se someterá a una división de validación cruzada temporal (Train-Test Split), estructurándose de la siguiente manera:

- **Conjunto de Entrenamiento (80%):** Conformado por los registros históricos más antiguos, utilizados exclusivamente para enseñar al algoritmo XGBoost a correlacionar las variables y ajustar sus hiperparámetros.
- **Conjunto de Prueba (20%):** Conformado por los registros cronológicamente más recientes, los cuales se ocultarán durante el entrenamiento y se utilizarán únicamente para evaluar la precisión del modelo (mediante métricas como RMSE y R^2), mostrando su capacidad de predecir demanda futura en un entorno real.

CAPÍTULO II

MARCO TEÓRICO

CAPÍTULO II

MARCO TEÓRICO

2.1 MARCO TEÓRICO

2.1.1 INGENIERIA DE SOFTWARE

La Ingeniería de Software es una disciplina de la ingeniería que se ocupa de la aplicación sistemática, disciplinada y cuantificable de métodos, técnicas y herramientas para el desarrollo, operación y mantenimiento de software. Su objetivo principal es producir sistemas confiables, eficientes y económicamente viables, considerando todo su ciclo de vida (Pressman, 2014).

Esta disciplina integra principios de gestión, diseño, aseguramiento de la calidad y mantenimiento, permitiendo abordar la complejidad creciente de los sistemas informáticos modernos. La aplicación de modelos, metodologías y estándares busca reducir errores, mejorar la mantenibilidad y asegurar que el software responda adecuadamente a los requisitos funcionales y no funcionales definidos.

2.1.2 MODELOS DE DESARROLLO

Los modelos de desarrollo de software representan estructuras metodológicas que guían el proceso de construcción de sistemas informáticos, desde la concepción inicial hasta su despliegue y mantenimiento. Estos modelos permiten organizar las actividades, roles y entregables del proyecto de manera sistemática (Pressman, 2014).

Entre los enfoques más difundidos se encuentran los modelos tradicionales, como el modelo en cascada, y los enfoques ágiles, los cuales priorizan la adaptabilidad, la colaboración y la entrega incremental de valor. Las metodologías ágiles han cobrado relevancia en entornos de alta incertidumbre y dinamismo, al permitir una rápida respuesta a cambios en los requisitos (Schwaber & Sutherland, 2020).

2.1.2.1 Modelo en Cascada

El modelo en cascada es uno de los primeros enfoques formales propuestos para el desarrollo de software. Se caracteriza por una secuencia lineal de etapas claramente

definidas: análisis de requisitos, diseño, pruebas, despliegue y mantenimiento. Cada fase debe completarse antes de avanzar a la siguiente, lo que enfatiza una documentación exhaustiva y una planificación rígida (Royce, 1970; Pressman, 2014).

Este modelo resulta adecuado en contextos donde los requisitos son estables y bien conocidos desde el inicio del proyecto. Sin embargo, presenta limitaciones significativas en entornos dinámicos, ya que el coste de realizar cambios en etapas avanzadas suele ser elevado, afectando la flexibilidad y adaptabilidad del proceso (Sommerville, 2016).

2.1.2.2 Modelo en V

El modelo en V surge como una extensión del modelo en cascada, incorporando una fuerte orientación a la verificación y validación del software. En este modelo, cada fase de desarrollo está asociada a una fase correspondiente de pruebas, de manera que la calidad es considerada desde las primeras etapas del ciclo de vida (Pressman, 2014).

Este enfoque refuerza la trazabilidad entre requisitos y pruebas, favoreciendo la detección temprana de errores. No obstante, al igual que el modelo en cascada, mantiene una estructura secuencial rígida, lo que limita su aplicación en proyectos con requisitos cambiantes.

2.1.2.3 Modelos Iterativos e Incrementales

Los modelos iterativos e incrementales proponen la construcción del software mediante ciclos repetitivos, en los cuales el sistema se desarrolla, prueba y refina de manera progresiva. En cada iteración se implementa un conjunto parcial de funcionalidades que se amplía en incrementos sucesivos (Larman, 2004).

Este enfoque permite obtener retroalimentación temprana de los usuarios, reducir riesgos y adaptarse mejor a cambios en los requisitos. Los modelos iterativos representan un avance significativo respecto a los enfoques secuenciales, al priorizar la evolución continua del producto sobre la planificación exhaustiva inicial (Sommerville, 2016).

2.1.2.4 Modelo Espiral

El modelo espiral, propuesto por Boehm, combina elementos del modelo en cascada con enfoques iterativos, incorporando explícitamente la gestión de riesgos como eje central del proceso de desarrollo. Cada ciclo de la espiral incluye la identificación de objetivos, análisis de riesgos, desarrollo y validación, y planificación de la siguiente iteración (Boehm, 1988).

Este modelo resulta especialmente adecuado para proyectos complejos y de gran escala, donde los riesgos técnicos, económicos u operacionales pueden comprometer el éxito del software. Sin embargo, su aplicación requiere experiencia en análisis de riesgos y una gestión avanzada del proyecto.

2.1.2.5 Metodologías Ágiles

Las metodologías ágiles surgen como respuesta a las limitaciones de los modelos tradicionales, especialmente en contextos caracterizados por cambios frecuentes en los requisitos y alta incertidumbre. Estas metodologías priorizan la colaboración entre equipos, la entrega incremental de valor y la adaptación continua al cambio, tal como se establece en el Manifiesto Ágil (Beck et al., 2001).

Entre los marcos ágiles más difundidos se encuentran Scrum, Extreme Programming (XP) y Kanban. Scrum, en particular, se basa en ciclos cortos de desarrollo denominados sprints, promoviendo la inspección y adaptación continua del proceso (Schwaber & Sutherland, 2020). Las metodologías ágiles han demostrado ser efectivas en proyectos donde se requiere rapidez, flexibilidad y retroalimentación constante de los interesados (Highsmith, 2009).

2.1.2.6 Modelos Orientados a Ciencia de Datos (CRISP-DM)

En el ámbito del análisis de datos y la minería de datos, surgen modelos especializados como CRISP-DM (Cross-Industry Standard Process for Data Mining). Este modelo propone un proceso estructurado compuesto por seis fases: comprensión del negocio,

comprensión de los datos, preparación de los datos, modelado, evaluación y despliegue (Chapman et al., 2000).

CRISP-DM se ha convertido en un estándar de facto para proyectos de analítica y aprendizaje automático, ya que proporciona un marco sistemático para transformar datos en conocimiento útil. Su enfoque iterativo permite mejorar los modelos de manera progresiva a partir de los resultados obtenidos en cada ciclo.

2.1.3 LENGUAJE UNIFICADO DE MODELADO UML

El Lenguaje Unificado de Modelado (Unified Modeling Language, UML) es un lenguaje gráfico estandarizado utilizado para la especificación, visualización, construcción y documentación de sistemas de software. UML permite representar de manera formal tanto la estructura estática como el comportamiento dinámico de un sistema, facilitando la comunicación entre analistas, diseñadores, desarrolladores y otros interesados a lo largo del ciclo de vida del software (Booch, Rumbaugh & Jacobson, 2005; Sommerville, 2016).

UML surge en la década de 1990 como resultado de la unificación de diversos enfoques de modelado orientado a objetos, principalmente los métodos de Booch, Object Modeling Technique (OMT) y Object-Oriented Software Engineering (OOSE). Esta unificación fue liderada por Grady Booch, James Rumbaugh y Ivar Jacobson, quienes establecieron una notación común para el modelado de sistemas complejos (Booch et al., 2005).

Actualmente, UML es mantenido y estandarizado por la Object Management Group (OMG), organismo responsable de la evolución formal del lenguaje. La versión de referencia vigente y ampliamente aceptada en la literatura académica y profesional es UML 2.5.1, publicada oficialmente por la OMG en el 2017. Esta versión consolida y corrige las especificaciones previas, mejorando la claridad semántica, la consistencia del metamodelo y la precisión de los distintos tipos de diagramas (OMG, 2017).


UML 2.5.1 define un conjunto de catorce tipos de diagramas, clasificados en diagramas estructurales y de comportamiento.

Los diagramas estructurales permiten modelar la organización estática del sistema, incluyendo clases, componentes, paquetes y relaciones entre ellos. Por su parte, los diagramas de comportamiento describen la dinámica del sistema, representando flujos de actividades, interacciones entre objetos y cambios de estado a lo largo del tiempo (Fowler, 2004; OMG, 2017).

2.1.3.1 Diagrama de Clases

Muestra la estructura lógica del sistema mediante clases, atributos, métodos y relaciones, siendo fundamental para definir los módulos clave como Curso, Inscripción, Predicción y Usuario.

Figura 2.1 Ejemplo Diagrama de Clases




Fuente: Elaboración propia, 2025

2.1.3.2 Diagrama de Objetos

Representa instancias específicas de clases para comprender escenarios concretos, como una instancia de un curso específico ("Diplomado en Investigación Aplicada") con sus valores de inscripción histórica o el estado de una predicción.

Figura 2.2 Ejemplo Diagrama de Objetos.




Fuente: Elaboración propia,2025

2.1.3.3 Diagrama de Componentes

Útil para describir módulos funcionales como el Dashboard de Predicciones, el Módulo de Registro de Datos Históricos o el sistema de autenticación de gestores.

Figura 2.3 Ejemplo Diagrama de Componentes.




Fuente: Elaboración propia,2025

2.1.3.4 Diagrama de Despliegue

Describe la arquitectura física del sistema, permitiendo visualizar cómo se distribuyen los servidores web (donde reside Flask), la base de datos (MySQL) y los dispositivos de usuario que acceden al sistema.

Figura 2.5 Ejemplo Diagrama de Despliegue.




Fuente: Elaboración propia, 2025

2.1.3.5 Diagrama de Paquetes

Organiza el sistema en módulos lógicos como Gestión de la Demanda, Modelado Predictivo y Administración de Usuarios

Figura 2.6 Ejemplo Diagrama de Paquetes.




Fuente: Elaboración propia, 2025

2.1.3.6 Diagrama de Perfil

Extiende UML mediante estereotipos específicos para representar elementos propios del dominio, como “Variable Predictiva” o “Resultado de SHAP”.

Figura 2.8 Ejemplo Diagrama de Perfil.




Fuente: Elaboración propia,2025

Asimismo, UML integra diagramas de comportamiento que permiten analizar cómo interactúa el sistema en tiempo real. Entre los más importantes están:

2.1.3.7 Diagrama de Casos de Uso

Describe las interacciones entre actores como Gestores Académicos o Administradores y las funcionalidades principales del sistema, como "Generar Predicción de Demanda" o "Cargar Registros Históricos".

Figura 2.9 Ejemplo Diagrama de Casos de Uso.




Fuente: Elaboración propia,2025

2.1.3.8 Diagrama de Actividades

Modela procesos internos, como el flujo de trabajo para la ejecución del modelo XGBoost (que incluye preprocesamiento de datos, cálculo de la predicción y almacenamiento del resultado).

Figura 2.10 Ejemplo Diagrama de Actividades.




Fuente: Elaboración propia,2025

2.1.3.9 Diagrama de Secuencia

Muestra el flujo temporal de mensajes entre objetos en procesos como la autenticación o la solicitud de datos históricos para la generación de un nuevo reporte de demanda.

Figura 2.11 Ejemplo Diagrama de Secuencia.



Fuente: Elaboración propia,2025

2.1.4 METODOLOGÍA DE DESARROLLO DE SOFTWARE

Scrum es un marco de trabajo ágil, liviano e incremental, diseñado para ayudar a equipos a generar valor a través de soluciones adaptativas frente a problemas complejos. Scrum se fundamenta en el empirismo, el cual sostiene que el conocimiento surge de la experiencia y de la toma de decisiones basada en la observación y la experimentación (Schwaber & Sutherland, 2020).

El marco Scrum se estructura en torno a roles claramente definidos, eventos periódicos, artefactos formales y reglas que rigen la interacción entre estos elementos. Su aplicación permite gestionar la complejidad mediante ciclos cortos de trabajo, promoviendo la inspección frecuente del progreso y la adaptación continua del proceso.

2.1.4.1 Pilares y Valores de Scrum

Scrum se basa en tres pilares fundamentales que sostienen la implementación del empirismo:

- **Transparencia:** Los aspectos relevantes del proceso deben ser visibles para todos los involucrados, garantizando una comprensión común del estado del trabajo.
- **Inspección:** Los artefactos y el progreso hacia los objetivos se inspeccionan de forma regular para detectar desviaciones.
- **Adaptación:** Si como resultado de la inspección se identifican variaciones críticas, el proceso debe ajustarse oportunamente.

Estos pilares se complementan con los valores de compromiso, enfoque, apertura, respeto y coraje, que orientan el comportamiento de los equipos Scrum (Schwaber & Sutherland, 2020).

2.1.4.2 Roles en Scrum

Scrum define tres roles principales que conforman el Equipo Scrum:

- **Product Owner:** Responsable de maximizar el valor del producto, gestionando y priorizando el Product Backlog conforme a los objetivos del negocio.
- **Scrum Master:** Facilita el marco Scrum, asegurando que se comprenda y aplique correctamente, y eliminando impedimentos que afecten al equipo.
- **Equipo de Desarrollo:** Grupo multidisciplinario encargado de transformar los elementos del backlog en incrementos funcionales del producto.

Estos roles promueven la autoorganización y la responsabilidad compartida, elementos clave en los enfoques ágiles (Highsmith, 2009).

2.1.4.3 Eventos de Scrum

El trabajo en Scrum se estructura en iteraciones de duración fija denominadas Sprints, que usualmente tienen una duración de una a cuatro semanas. Cada Sprint incluye los siguientes eventos, los cuales se reflejan temporalmente en el cronograma presentado (ver Apéndice C):

- **Planificación del Sprint:** Evento en el que se define qué trabajo se realizará durante el Sprint y cómo se llevará a cabo.
- **Scrum Diario:** Reunión diaria breve destinada a inspeccionar el progreso y adaptar el plan de trabajo.
- **Revisión del Sprint:** Evento orientado a inspeccionar el incremento desarrollado y obtener retroalimentación de los interesados.
- **Retrospectiva del Sprint:** Espacio de reflexión donde el equipo identifica oportunidades de mejora para el siguiente Sprint.

Estos eventos garantizan ciclos continuos de retroalimentación, aprendizaje y mejora incremental del proceso (Schwaber & Sutherland, 2020).


2.1.4.4 Artefactos de Scrum

Scrum define tres artefactos principales que proporcionan transparencia y oportunidades de inspección y adaptación:

- Product Backlog: Lista ordenada de todas las funcionalidades, mejoras y requisitos del producto.
- Sprint Backlog: Conjunto de elementos seleccionados del Product Backlog para un Sprint específico, junto con el plan para entregarlos.
- Incremento: Suma de todos los elementos del Product Backlog completados durante el Sprint, que representa una versión funcional y potencialmente entregable del producto.

Cada artefacto está asociado a un compromiso específico (Objetivo del Producto, Objetivo del Sprint y Definición de Terminado), los cuales aseguran claridad y alineación entre el equipo y los objetivos del desarrollo (Schwaber & Sutherland, 2020).


Figura 2.12 Procesos Scrum



Fuente: Shutterstock, 2025

Se puede observar la adaptación del proyecto actual a este marco de trabajo.

Figura 2.11 Procesos Scrum (Adaptado)



Fuente: Shutterstock, 2026

2.1.5 HERRAMIENTAS DE DESARROLLO

La selección de herramientas de desarrollo es un componente fundamental en la ingeniería de software, ya que influye directamente en la eficiencia, mantenibilidad y calidad de los sistemas informáticos. Las herramientas adecuadas permiten optimizar los

tiempos de desarrollo, reducir errores y facilitar la colaboración entre los integrantes del equipo, aspectos que resultan especialmente relevantes en entornos de desarrollo iterativos y ágiles (Pressman, 2014).

2.1.5.1 Lenguaje de Programación Python

Python es un lenguaje de programación de alto nivel, interpretado, multiparadigma y de propósito general, diseñado con una sintaxis clara y legible que favorece la productividad del desarrollador y la mantenibilidad del software. Fue concebido con el objetivo de reducir la complejidad del código y facilitar su comprensión, lo que ha impulsado su adopción tanto en el ámbito académico como en el industrial (Van Rossum & Drake, 2009; Lutz, 2013).

En la actualidad, Python se utiliza ampliamente en diversos dominios como el desarrollo de aplicaciones web, la automatización de procesos, el análisis de datos y la inteligencia artificial. Su popularidad se debe en gran medida a la existencia de un ecosistema robusto de bibliotecas y frameworks que permiten abordar problemas complejos de manera eficiente y escalable (Sanner, 2014; Géron, 2019).

En el contexto de la ciencia de datos y el aprendizaje automático, Python se ha consolidado como uno de los lenguajes predominantes. Bibliotecas como NumPy, Pandas y Scikit-learn proporcionan herramientas especializadas para el procesamiento numérico, la manipulación de datos estructurados y la implementación de algoritmos de aprendizaje supervisado y no supervisado, facilitando procesos de análisis reproducibles y basados en evidencia (McKinney, 2017; Pedregosa et al., 2011).

2.1.5.2 Frameworks Backend para el Desarrollo Web

Los frameworks backend constituyen plataformas de software que facilitan el desarrollo de aplicaciones del lado del servidor, proporcionando estructuras predefinidas para la gestión de la lógica de negocio, la comunicación con bases de datos y la exposición de servicios a través de interfaces de programación de aplicaciones (APIs). Su principal

objetivo es promover la reutilización de código, mejorar la seguridad y acelerar el proceso de desarrollo (Pressman, 2014).

En los últimos años, los frameworks orientados a la construcción de APIs REST han cobrado especial relevancia debido a la adopción de arquitecturas cliente-servidor desacopladas y sistemas distribuidos. FastAPI es un framework moderno desarrollado en Python que se orienta a la creación eficiente de servicios web, destacándose por su alto rendimiento, soporte nativo para tipado de datos y generación automática de documentación basada en estándares abiertos como OpenAPI (Ramalho, 2022; FastAPI, 2024). De manera similar, Flask constituye un microframework ligero también desarrollado en Python, que proporciona una base minimalista pero flexible para la construcción de aplicaciones web y APIs, permitiendo a los desarrolladores seleccionar y integrar únicamente los componentes necesarios para sus proyectos específicos (Grinberg, 2018).

Este tipo de frameworks resulta especialmente adecuado para entornos donde se requiere exponer servicios web que puedan ser consumidos por múltiples clientes, favoreciendo la interoperabilidad y la escalabilidad de los sistemas informáticos (Fielding, 2000; Tanenbaum & Van Steen, 2017).

2.1.5.3 Tecnologías Frontend y Desarrollo de Interfaces Web

El desarrollo frontend se encarga de la construcción de interfaces de usuario que permiten la interacción entre las personas y los sistemas informáticos. Las tecnologías fundamentales del frontend web incluyen HTML5 para la estructuración del contenido, CSS3 para el diseño visual y JavaScript para la implementación de comportamientos dinámicos e interactivos (MDN Web Docs, 2020).

En el ecosistema moderno del desarrollo web, las bibliotecas y frameworks de JavaScript han adquirido un rol protagónico al facilitar la creación de interfaces modulares, reutilizables y mantenibles. React es una biblioteca ampliamente utilizada para el desarrollo de interfaces de usuario basadas en componentes, permitiendo una gestión

eficiente del estado y optimizando el rendimiento mediante el uso del Virtual DOM (Flanagan, 2020; React Team, 2024).

Estas herramientas permiten desarrollar aplicaciones web dinámicas que mejoran la experiencia del usuario y facilitan la visualización de información compleja en tiempo real, características fundamentales en sistemas orientados a la presentación de datos y análisis visual.

2.1.5.4 Sistemas de Gestión de Bases de datos Relacionales

Los sistemas de gestión de bases de datos relacionales (SGBDR) permiten almacenar, organizar y administrar grandes volúmenes de información de forma estructurada, garantizando la integridad, consistencia y disponibilidad de los datos. Este tipo de sistemas se basa en el modelo relacional propuesto por Codd, donde la información se organiza en tablas relacionadas entre sí mediante claves primarias y foráneas (Date, 2019; Silberschatz et al., 2020).

Bases de datos relacionales como MySQL y PostgreSQL son ampliamente utilizadas en aplicaciones web debido a su madurez tecnológica, estabilidad y amplio soporte comunitario. Estas herramientas facilitan la persistencia de la información y permiten la ejecución eficiente de consultas complejas, constituyéndose como un pilar fundamental en la arquitectura de sistemas informáticos modernos.

2.1.5.5 Herramientas de Colaboración y Control de Versiones

En entornos de desarrollo colaborativo, el uso de herramientas de control de versiones es esencial para gestionar los cambios en el código fuente, coordinar el trabajo entre múltiples desarrolladores y mantener un historial completo de modificaciones. Git es un sistema de control de versiones distribuido ampliamente adoptado por la industria, que permite trabajar de manera paralela y segura sobre un mismo proyecto de software (Chacon & Straub, 2014).

Plataformas colaborativas como GitHub complementan el uso de Git al ofrecer funcionalidades adicionales como la gestión de incidencias, la revisión de código y la integración continua. Estas herramientas resultan fundamentales en proyectos desarrollados bajo metodologías ágiles, ya que facilitan la comunicación, la transparencia y la entrega incremental de valor (Schwaber & Sutherland, 2020).

2.1.6 ESTIMACIÓN DE COSTOS

La estimación de costos en proyectos de software constituye un proceso fundamental dentro de la ingeniería de software, ya que permite planificar y asignar de manera eficiente los recursos financieros, humanos y materiales necesarios para el desarrollo de sistemas informáticos. Una estimación adecuada contribuye a la viabilidad del proyecto, al facilitar la toma de decisiones estratégicas y reducir el riesgo de desviaciones en tiempo, presupuesto y alcance (Pressman, 2014).

El proceso de estimación de costos se apoya en el análisis sistemático de diferentes factores que influyen en el desarrollo del software, tales como el tamaño del sistema, la complejidad técnica, la experiencia del equipo de desarrollo y las herramientas tecnológicas empleadas. Diversos modelos y técnicas han sido propuestos en la literatura, incluyendo la estimación basada en expertos, modelos algorítmicos como COCOMO y enfoques híbridos que combinan métricas históricas con juicio profesional (Boehm et al., 2000; Fairley, 2009).

En contextos donde se adoptan metodologías de desarrollo ágiles, la estimación de costos adquiere un carácter iterativo y dinámico. En lugar de definir un presupuesto rígido desde el inicio, las metodologías ágiles proponen revisiones periódicas de las estimaciones ancladas a ciclos cortos de desarrollo, permitiendo ajustar los recursos y el esfuerzo conforme se obtiene más información del sistema y de sus requisitos emergentes (Schwaber & Sutherland, 2020; Highsmith, 2009).

De manera general, los costos en proyectos de software pueden clasificarse en tres grandes categorías. En primer lugar, los costos asociados a los recursos humanos, que incluyen al personal involucrado en el análisis, diseño, implementación, pruebas y

mantenimiento del sistema. En segundo lugar, los costos temporales, relacionados con el esfuerzo y la duración de cada iteración o fase del desarrollo. Finalmente, los costos de aseguramiento de la calidad y mantenimiento, orientados a garantizar que el software cumpla con los estándares requeridos y pueda evolucionar de forma sostenible a lo largo del tiempo (Pressman, 2014).

Asimismo, la literatura destaca que la adopción de herramientas de desarrollo libres y de código abierto puede influir positivamente en la estructura de costos, al reducir los gastos asociados a licencias de software propietario. No obstante, se enfatiza que el ahorro económico debe evaluarse de forma integral, considerando también aspectos como soporte, capacitación y sostenibilidad tecnológica (Sommerville, 2016).

Adicionalmente a los modelos de esfuerzo orientados al equipo de desarrollo, en proyectos de carácter académico o de implementación individual, es indispensable aplicar el Método de Costeo Directo para la evaluación de la viabilidad financiera operativa. Este método consiste en la identificación, cuantificación y sumatoria de todos los gastos tangibles e inmediatos en los que incurre directamente el investigador o desarrollador durante el ciclo de vida del proyecto (Project Management Institute, 2017). A diferencia de los modelos algorítmicos, el costeo directo no estima el valor del software en sí, sino el presupuesto logístico de bolsillo requerido para su ejecución, abarcando rubros específicos como los gastos de movilización física (transporte para reuniones de levantamiento de requisitos y tutorías) y los costos de papelería, impresión y documentación formal exigida. La aplicación de este método se formaliza mediante una ecuación sumatoria que multiplica la frecuencia de la actividad logística por su costo unitario en el mercado local.

En conjunto, una correcta estimación de costos proporciona una visión integral del esfuerzo requerido para el desarrollo de un sistema, contribuyendo a una gestión financiera más eficiente, a una mejor asignación de recursos y a la toma de decisiones informadas durante todo el ciclo de vida del software.

2.1.7 ASEGURAMIENTO DE CALIDAD

El aseguramiento de la calidad del software (Quality Assurance, QA) es un conjunto de actividades sistemáticas y planificadas orientadas a garantizar que los procesos y productos de software cumplan con los requisitos establecidos y con los estándares de calidad definidos. A diferencia del control de calidad, que se enfoca en la detección de defectos en el producto final, el QA se centra en la prevención de errores mediante la mejora continua de los procesos de desarrollo (Pressman, 2014).

El QA debe integrarse a lo largo de todo el ciclo de vida del software, desde la definición de requisitos hasta el mantenimiento posterior a la entrega. Este enfoque permite identificar deficiencias de manera temprana, reducir el retrabajo y mejorar la confiabilidad y mantenibilidad de los sistemas informáticos (ISO/IEC 25010, 2011). Incorporar prácticas de aseguramiento de calidad desde las etapas iniciales contribuye significativamente a la estabilidad y éxito del producto final.

Una actividad fundamental dentro del aseguramiento de la calidad es la gestión y validación de requisitos. La revisión de requisitos busca asegurar que estos sean claros, completos, consistentes y verificables, evitando ambigüedades que puedan derivar en errores durante las fases de diseño e implementación. Una definición adecuada de requisitos facilita la trazabilidad y constituye la base para las actividades posteriores de verificación y validación (Sommerville, 2016).

Las pruebas de software (software testing) representan otro componente esencial del QA. Estas pruebas incluyen distintos niveles y enfoques, tales como pruebas unitarias, de integración, de sistema y de aceptación, cuyo objetivo es verificar el correcto funcionamiento del software y validar que cumple con los requisitos funcionales y no funcionales especificados. La aplicación sistemática de pruebas contribuye a mejorar la confiabilidad y reducir la tasa de defectos en sistemas complejos (Myers, Sandler & Badgett, 2011).

Asimismo, el control de calidad del código se apoya en prácticas como la revisión por pares, el análisis estático de código y la automatización de pruebas. Estas técnicas

permiten mejorar la legibilidad, mantenibilidad y seguridad del software, además de identificar vulnerabilidades y defectos antes de la puesta en producción. La utilización de métricas de calidad, como la densidad de defectos o la cobertura de pruebas, facilita la evaluación objetiva del proceso de desarrollo y la identificación de áreas críticas de mejora (Pressman, 2014; McConnell, 2004).

Finalmente, el aseguramiento de la calidad se encuentra estrechamente relacionado con la gestión de riesgos, ya que permite identificar, analizar y mitigar factores que puedan afectar el desempeño, estabilidad y confiabilidad del software. La adopción de un enfoque preventivo, apoyado en estándares y buenas prácticas, garantiza que los sistemas de información alcancen niveles aceptables de calidad y puedan evolucionar de forma controlada a lo largo del tiempo (ISO/IEC 12207, 2017).

2.1.8 SEGURIDAD DEL SISTEMA

La seguridad en sistemas de software es un componente fundamental en el desarrollo de sistemas de información, ya que tiene como objetivo proteger los recursos digitales frente a accesos no autorizados, modificaciones indebidas y pérdida de información. La seguridad informática busca preservar la confianza en los sistemas y garantizar que estos operen de manera confiable dentro de entornos organizacionales y tecnológicos cada vez más complejos (Stallings & Brown, 2018).

De manera general, la seguridad de la información se fundamenta en el cumplimiento de tres principios conocidos como el triángulo CIA: confidencialidad, integridad y disponibilidad. La confidencialidad asegura que la información solo sea accesible por usuarios autorizados; la integridad garantiza que los datos no sean alterados de forma no autorizada; y la disponibilidad procura que los recursos estén accesibles cuando sean requeridos por los usuarios legítimos (Whitman & Mattord, 2019).

La confidencialidad se logra mediante mecanismos como la autenticación, la autorización y el control de accesos, los cuales permiten definir y restringir los permisos de uso del sistema de acuerdo con perfiles y roles previamente establecidos. Estas medidas reducen el riesgo de exposición de información sensible y contribuyen a un manejo seguro de los datos (Stallings, 2018).

Por su parte, la integridad de los datos se mantiene a través de validaciones, controles de consistencia, auditorías y registros de cambios, que permiten detectar alteraciones no autorizadas y asegurar la fiabilidad de la información almacenada y procesada. La integridad es especialmente crítica en sistemas que procesan grandes volúmenes de datos y soportan procesos de toma de decisiones (Silberschatz et al., 2020).

La disponibilidad garantiza que los servicios y recursos del sistema estén operativos y accesibles de forma continua. Para ello, se implementan mecanismos como copias de respaldo, planes de contingencia, monitoreo del sistema y tolerancia a fallos. Estas prácticas permiten minimizar el impacto de interrupciones y asegurar la continuidad operativa del software (Tanenbaum & Van Steen, 2017).

Finalmente, la auditoría y el control de registros constituyen elementos clave dentro de la seguridad informática. La auditoría permite supervisar las acciones realizadas en el sistema, facilitando la detección temprana de incidentes de seguridad y el análisis posterior de eventos. La trazabilidad de las operaciones fortalece la transparencia, el cumplimiento normativo y la mejora continua de los mecanismos de protección del software (ISO/IEC 27001, 2022).

2.2 MARCO CONCEPTUAL

2.2.1 SISTEMA WEB PREDICTIVO

Para el presente estudio, un sistema web predictivo se comprende no solo como un repositorio de información, sino como una plataforma digital avanzada que integra la gestión de información histórica con la capacidad matemática de generar estimaciones sobre comportamientos futuros. Esto se logra mediante la implementación subyacente de modelos de aprendizaje automático. De acuerdo con Romero y Ventura (2010), en su análisis sobre la minería de datos educativos, la transición de sistemas transaccionales tradicionales a sistemas predictivos permite a las instituciones extraer valor estratégico de sus bases de datos. Desde el punto de vista aplicativo, este sistema es viable para la Academia Autopoiesis porque se cuenta con registros históricos estructurados y con la arquitectura técnica necesaria para centralizar datos, procesarlos en tiempo real y presentar resultados de forma accesible para el apoyo directo a la toma de decisiones.

2.2.2 ALGORITMO XGBOOST

En el marco de esta investigación, el algoritmo XGBoost se define como un robusto sistema escalable de aprendizaje automático basado en el ensamblaje de árboles de decisión potenciados (Gradient Boosting). Según Chen y Guestrin (2016), creadores del algoritmo, este modelo fue diseñado específicamente para optimizar la velocidad de ejecución y el rendimiento computacional frente a datos tabulares, superando ampliamente a modelos tradicionales.

En el proyecto, XGBoost actúa como el motor analítico encargado de estimar la demanda de cursos y diplomados a partir del aprendizaje iterativo sobre datos históricos de inscripción. Su aplicación es idónea debido a que el estudio dispone de una variable dependiente claramente identificada (volumen de demanda) y múltiples variables independientes cuantificables, permitiendo un entrenamiento objetivo y la minimización progresiva de la tasa de error.

2.2.3 ESTIMACIÓN DE DEMANDA EDUCATIVA

La estimación o pronóstico de la demanda educativa constituye el proceso analítico de anticipar el volumen de participantes esperados en programas de formación, utilizando para ello información histórica y características observables de la oferta académica.

La literatura contemporánea en analítica educativa (Alyahyan & Düşteğör, 2020) señala que anticipar el comportamiento estudiantil es vital para garantizar la sostenibilidad de las instituciones frente a un mercado volátil. En el contexto particular del proyecto, esta estimación es fundamental para mitigar el riesgo de sobreoferta o suboferta en la Academia Autopoiesis, permitiendo planificar con antelación los recursos tecnológicos, el presupuesto publicitario y la contratación del plantel docente.

2.2.4 APRENDIZAJE AUTOMÁTICO SUPERVIZADO

El aprendizaje automático supervisado (Supervised Machine Learning) se define como el enfoque algorítmico predictivo donde un modelo informático es entrenado utilizando

un conjunto de datos previamente etiquetado. Según Géron (2022), en este paradigma, el algoritmo recibe simultáneamente las entradas (variables predictoras, como precio y publicidad) y las salidas correctas esperadas (etiquetas, como la demanda final), con el objetivo fundamental de aprender la relación o función matemática que mapea unas con otras. Una vez que el modelo ha generalizado este conocimiento, es capaz de recibir datos nuevos o inéditos para emitir predicciones precisas, técnica que constituye el núcleo lógico de la presente investigación aplicada.

2.2.5 INTELIGENCIA ARTIFICIAL EXPLICABLE (XAI) Y SHAP

Históricamente, los modelos de ensamblaje complejos han sido criticados por comportarse como "cajas negras", donde se conoce la entrada y la salida, pero no el razonamiento interno. La inteligencia artificial explicable (XAI) surge como el conjunto de técnicas orientadas a interpretar y transparentar estas decisiones matemáticas (Molnar, 2022). En este estudio, la explicabilidad se logra mediante la implementación de los valores SHAP (Shapley Additive exPlanations). Basado en la teoría de juegos cooperativos, SHAP proporciona un enfoque unificado que asigna a cada variable un valor de importancia específica para una predicción determinada (Lundberg & Lee, 2017). Esta tecnología garantiza que los directivos de la Academia comprendan el porqué de cada predicción, facilitando la adopción y confianza en la herramienta tecnológica.

2.2.6 ANALÍTICA PREDICTIVA

La analítica predictiva trasciende el simple análisis descriptivo de lo que ocurrió en el pasado, para enfocarse en la inferencia estadística de lo que es altamente probable que ocurra en el futuro. Provost y Fawcett (2013) establecen que la toma de decisiones basada en datos (Data-Driven Decision Making) es la práctica de basar las estrategias organizacionales en el análisis de información y no estrictamente en la intuición o la experiencia empírica. Desde el enfoque del proyecto, el uso de la analítica predictiva permite a la Academia migrar de un modelo de gestión reactivo hacia uno proactivo,

donde la apertura de un diplomado no responde a supuestos, sino a proyecciones matemáticas respaldadas por el historial de la institución.

2.2.7 INEFICIENCIA OPERACIONAL EN LA GESTIÓN DE ACTIVIDADES

La ineficiencia operacional, dentro de la gestión de proyectos y recursos institucionales, se refiere a las fricciones, sobrecostos y dificultades de planificación que generan pérdidas de tiempo y merman la capacidad de acción de una entidad (Project Management Institute, 2017). En la presente investigación, esta ineficiencia se materializa como el problema central a resolver. Resulta observable en la Academia Autopoiesis debido a la dispersión de información, las decisiones centralizadas sin respaldo estadístico y la ausencia de herramientas sistematizadas, lo que convierte a la ineficiencia en un fenómeno susceptible de ser mitigado mediante la ingeniería de software y la implementación del sistema web propuesto.

2.2.8 VARIABLES DETERMINANTES EN EL COMPORTAMIENTO DE INSCRIPCIÓN

Las variables determinantes son todos aquellos factores cuantificables, tanto de naturaleza interna como del entorno de mercado, que influyen de manera significativa y directa en la fluctuación de la demanda de cursos. Al adoptar un enfoque de investigación cuantitativo, donde la recolección de datos medibles es imperativa (Hernández-Sampieri & Mendoza, 2018), estas variables se estructuran en tres categorías críticas para el entrenamiento del modelo:

- **Variables de Inscripción y Operación:** Atributos directos de la oferta, tales como el nombre del programa, la temporalidad (semana y año), el cupo límite, el precio establecido en moneda local y los descuentos aplicados.
- **Variables de Difusión:** Indicadores del esfuerzo de marketing institucional, donde destaca el volumen de publicaciones en redes sociales, elemento vital para captar la atención del prospecto.
- **Variables de Gestión Administrativa:** Factores como la asignación docente y el estado operativo del curso.

2.2.9 DATASET Y REGISTROS HISTÓRICOS DE INSCRIPCIONES

El Dataset, o conjunto de datos históricos, constituye la materia prima fundamental y la base empírica ineludible sobre la cual se cimienta el Sistema Web Predictivo. Para este caso de estudio, abarca la consolidación de los registros transaccionales del periodo 2020 al 2026.

2.2.10 TOMA DE DECISIONES INSTITUCIONALES (APOYADA EN DATOS)

La Toma de Decisiones Institucionales Apoyada por Datos (Data-Driven Decision Making o DDDM) constituye un enfoque estratégico, organizativo y tecnológico que trasciende la simple recopilación pasiva de información transaccional. Según Mandinach y Schildkamp (2021), el éxito de la toma de decisiones basada en evidencia dentro de los entornos educativos no radica en la posesión de la tecnología per se, sino en la capacidad cultural e institucional de transformar los flujos de datos crudos en conocimiento pedagógico y administrativo accionable.

Para la Academia Autopoiesis, la adopción de este paradigma representa un cambio de rumbo estructural y crítico. Históricamente, la planificación y lanzamiento de su oferta académica ha operado bajo modelos fijos, rígidos y excesivamente condicionados por la intuición empírica o el juicio subjetivo de sus directivos. Esta inercia tradicional genera ineficiencias operacionales severas, caracterizadas por pérdidas económicas debidas al quórum insuficiente o a la sobreoferta no planificada. Al migrar hacia un esquema proactivo sustentado en analítica predictiva, la institución adquiere la capacidad de alinear científicamente sus programas de formación con las necesidades, intereses y perfiles proyectados de su comunidad profesional y estudiantil.

Como sostienen Gaftandzhieva et al. (2023), el uso de metodologías de aprendizaje automático e inteligencia de negocios permite a la alta dirección de las instituciones educativas monitorear campañas de reclutamiento, optimizar la asignación presupuestaria y atenuar riesgos operacionales con un rigor matemático inédito. En este proyecto aplicado, el Sistema Web Predictivo propuesto constituye la pieza de ingeniería central que materializa este enfoque. Al integrar la potencia algorítmica de XGBoost con

la explicabilidad matemática de SHAP, se supera la limitación de la "caja negra" que suele provocar resistencia al uso de IA en áreas administrativas (Molnar, 2022).

En la práctica, la optimización decisional se concreta en pronósticos automatizados de demanda con horizontes temporales trimestrales y semestrales, clasificando la afluencia de matrícula en niveles de participación de probabilidad alta, media o baja. Este soporte analítico genera beneficios de naturaleza dual: para la organización, reduce sustancialmente el riesgo financiero y la incertidumbre operacional; para los coordinadores académicos y docentes, pone a disposición un dashboard interactivo que reporta métricas dinámicas y automatiza informes. Comprender la causalidad detrás de cada estimación predictiva —es decir, descubrir cómo interactúan y pesan factores críticos como los costos de los cursos o la intensidad de la difusión publicitaria— garantiza que las acciones del negocio educativo, tales como el rediseño de tarifas o la reestructuración de calendarios, se ejecuten de manera informada, proactiva y empíricamente verificable.

2.2.11 INGENIERÍA DE DATOS Y PREPROCESAMIENTO

La ingeniería de datos es una disciplina técnica que comprende el conjunto de operaciones dedicadas a la extracción, limpieza, transformación y carga (conocido en la industria como procesos ETL) de los datos en bruto. Estas metodologías se encuentran estandarizadas en marcos de trabajo internacionales como CRISP-DM (Wirth & Hipp, 2000).

El preprocesamiento es una etapa innegociable que garantiza la calidad del dataset, e incluye la imputación de valores nulos, la normalización de rangos numéricos y la codificación algorítmica de variables categóricas (One-Hot Encoding), asegurando que el modelo matemático procese la información de manera íntegra, eficiente y sin sesgos inducidos por formatos incorrectos.

2.2.12 ARQUITECTURA WEB CLIENTE-SERVIDOR

La arquitectura web cliente-servidor representa el paradigma de diseño de sistemas distribuidos donde la carga informática se segmenta estratégicamente entre los proveedores de recursos informáticos (los servidores) y los demandantes de servicios e interfaces (los clientes o navegadores) (Sommerville, 2015).

Su fundamentación es vital para el proyecto, puesto que el sistema predictivo operará bajo un esquema de responsabilidades separadas: contará con un Frontend reactivo enfocado en la experiencia del gestor administrativo, y un Backend robusto encargado de procesar la lógica de negocio, invocar el modelo XGBoost y mantener la conexión segura con la base de datos. Esta arquitectura promueve un alto grado de escalabilidad y facilidad de mantenimiento (Pressman & Maxim, 2020).

2.2.13 INTERFACES DE VISUALIZACIÓN DE DATOS (DASHBOARDS)

Un dashboard o panel de control es una herramienta de Inteligencia de Negocios (Business Intelligence) que rastrea, sintetiza y despliega de forma estructurada, gráfica y altamente visual las métricas e indicadores clave de rendimiento. Su relevancia teórica y práctica en el estudio radica en que funge como el puente cognitivo definitivo entre la complejidad matemática oculta en el backend y los usuarios finales de la Academia.

A través de componentes de diseño de interfaz de usuario (UI), el sistema presenta las predicciones y los diagramas explicativos de SHAP de forma digerible, democratizando el acceso a la inteligencia artificial para perfiles no técnicos.

2.2.14 DESPLIEGUE DE MODELOS PREDICTIVOS EN PRODUCCIÓN (MODEL DEPLOYMENT)

El despliegue (Deployment) consiste en el proceso avanzado de integrar un algoritmo de machine learning, previamente entrenado y validado de manera local, dentro de un entorno de producción informático real y continuo. Autores como Géron (2022) recalcan

que el valor comercial de un modelo solo se cristaliza cuando este es capaz de recibir datos nuevos en tiempo real e interactuar con aplicaciones de usuario.

Para la institución educativa en cuestión, este concepto justifica la transición técnica de un "experimento de ciencia de datos" a una herramienta web funcional, donde el Backend consume activamente el archivo serializado del modelo para automatizar las estimaciones de la oferta académica.

2.2.15 ESTACIONALIDAD Y PATRONES DE DEMANDA EDUCATIVA

En el ámbito de la estadística y la econometría, la estacionalidad se define como la presencia de fluctuaciones, picos y caídas periódicas que se repiten de manera predecible en intervalos regulares (semanas, meses o trimestres) a lo largo del tiempo (Hyndman & Athanasopoulos, 2021).

Reconocer este concepto permite comprender que el comportamiento de inscripción de los estudiantes está intrínsecamente ligado a calendarios laborales, periodos de graduación y disponibilidad económica de fin de año. El modelo predictivo debe estar diseñado para identificar automáticamente esta estacionalidad, ajustando sus predicciones en función de la época del año en que se pretende lanzar un programa de formación.

2.2.16 BASES DE DATOS RELACIONALES

Una base de datos relacional es un paradigma de almacenamiento estructurado que organiza los datos en entidades o tablas interconectadas lógicamente mediante claves foráneas y primarias, bajo estrictas reglas de integridad referencial. De acuerdo con Obe y Hsu (2017), el uso de motores como PostgreSQL garantiza las propiedades ACID (Atomicidad, Consistencia, Aislamiento y Durabilidad) de las transacciones.

El sistema web propuesto requiere invariablemente este modelo para centralizar con seguridad la información administrativa sobre cursos, historiales docentes e inscripciones, mitigando la fragmentación original de la información institucional.

2.2.17 INTERFACES DE PROGRAMACIÓN DE APLICACIONES (API REST)

Una API REST (Representational State Transfer) es un estilo arquitectónico para el diseño de aplicaciones en red que estandariza la comunicación y transferencia fluida de datos bajo el protocolo HTTP, de manera completamente independiente al estado (Stateless) (Grinberg, 2018).

Conceptualmente, es la capa de integración, actuando como el canal de mensajería asíncrono. Mediante esta API, las vistas construidas en React solicitarán información y parámetros al servidor en Flask, el cual responderá estructurando las predicciones analíticas en formato JSON estandarizado para su consumo e impresión en pantalla.

2.2.18 MÉTRICAS DE EVALUACIÓN PARA MODELOS PREDICTIVOS

Para certificar el rigor científico del proyecto, las métricas de evaluación funcionan como los indicadores estadísticos diseñados metodológicamente para cuantificar objetivamente la capacidad de generalización y la tasa de penalización por error de un algoritmo frente a datos de validación no observados previamente.

Según la literatura especializada (Géron, 2022), se emplean métricas como la Raíz del Error Cuadrático Medio (RMSE), que castiga severamente los errores de estimación grandes, y el Coeficiente de Determinación (R^2), que indica el porcentaje de la varianza en las inscripciones que el modelo es capaz de explicar; validando así, empíricamente, su superioridad frente a las estimaciones intuitivas.

2.2.19 DISEÑO CENTRADO EN EL USUARIO (UX) E INTERFACES (UI)

La Experiencia de Usuario (UX) agrupa los factores psicológicos, emocionales y de usabilidad asociados a la interacción de un individuo con un producto informático, mientras que el diseño de Interfaz de Usuario (UI) se ocupa de la ergonomía visual, la distribución de información y la disposición de elementos gráficos en pantalla (Pressman & Maxim, 2020).

Aplicar estos principios metodológicos garantiza que la adopción de la plataforma por parte de los coordinadores y gestores de la Academia sea intuitiva y libre de sobrecarga cognitiva, factor vital para asegurar el retorno de inversión del desarrollo de software.

2.2.20 SEGURIDAD DE LA INFORMACIÓN Y CONTROL DE ACCESO (ROLES)

La seguridad informática establece las políticas, arquitecturas y protocolos criptográficos destinados a salvaguardar los tres pilares de la información: confidencialidad, integridad y disponibilidad frente a posibles amenazas (Sommerville, 2015).

Dado que la plataforma albergará datos transaccionales, historiales docentes e información estratégica sobre los ingresos y la proyección financiera de la Academia Autopoiesis, es ineludible implementar una capa de seguridad. El marco conceptual incluye la gestión de sesiones mediante tokens web estándar (JWT) y el control de acceso basado en roles jerárquicos (Directores, Gestores, Docentes) para restringir funcionalidades críticas.

2.3 MARCO INSTITUCIONAL

La Academia Autopoiesis Servicios Educativos e Integrales S.R.L., se constituye como una institución privada emergente y especializada en el ámbito de la formación en artes, cultura e investigación. Su naturaleza se centra en la vinculación del conocimiento científico y artístico con la comunidad, buscando activamente promover, apoyar y acompañar el desarrollo de talentos jóvenes en ambas áreas. En cuanto a su presencia física, la sede administrativa y las oficinas principales de la Academia se encuentran ubicadas estratégicamente en el centro de la ciudad de La Paz, Bolivia, específicamente en la calle Murillo. No obstante, en su ámbito operacional y de entrega de valor, la institución ha adoptado una modalidad de funcionamiento totalmente virtual, lo cual le permite expandir su alcance geográfico, facilitar la participación de cursantes de diferentes regiones del interior del país y optimizar sus costos operativos.

Bajo el liderazgo del director Víctor Hugo Aranda, la Academia Autopoiesis orienta su misión principal a ser un motor de desarrollo cultural e investigativo. El director asume la

responsabilidad de dirigir, planificar, desarrollar y evaluar las diversas actividades y procesos, manteniendo la coherencia de la misión institucional. La oferta formativa se caracteriza por su diversidad e interdisciplinariedad, incluyendo cursos cortos, diplomados (a menudo realizados en convenio con universidades privadas) y actividades culturales abiertas a la comunidad. Como parte de su compromiso con la difusión del conocimiento, la Academia edita la revista digital interdisciplinaria Emergentes 4.0, además de pretender ofrecer servicios de valor añadido, como un repositorio de material documental y bibliográfico de apoyo para sus participantes y abierto a la población estudiantil universitaria en general.

A pesar de sus metas claras y su impacto cultural, la Academia Autopoiesis enfrenta una Ineficiencia Operacional en la Gestión de Actividades Formativas y Difusión, lo cual limita su crecimiento y pone en riesgo su sostenibilidad. Esta ineficiencia tiene raíces estructurales y se debe a que la Gestión Administrativa es Deficiente, caracterizada por registros manuales poco sistematizados y un seguimiento desorganizado de las actividades; estos trabajos son percibidos como morosos y dificultan el control preciso de las inscripciones. Paralelamente, la Academia sufre de una dependencia tecnológica fragmentada, careciendo de una página web interactiva o un sistema centralizado de información, recurriendo al uso desarticulado de plataformas como Zoom, Meet y Classroom para la operación diaria.

Esta falta de sistematización se suma a problemas de visibilidad, pues la promoción de actividades carece de una estrategia clara en redes sociales y medios digitales, afectando su alcance. El contexto externo también incide severamente, ya que la crisis económica nacional se traduce en una baja inscripción de participantes a pesar de la accesibilidad de los precios, limitando la capacidad de inversión de los estudiantes en su formación. Estos problemas convergen en una sobreoferta o suboferta de programas al no contar con una planificación basada en datos. Es este contexto de fragilidad operativa y necesidad de migrar de un modelo reactivo a un modelo proactivo y predictivo lo que justifica plenamente la necesidad e idoneidad del Sistema Web Predictivo basado en XGBoost, ya que la institución requiere alinear su oferta con las necesidades reales y proyectadas de la comunidad para asegurar su viabilidad futura.

2.4 ESTADO DEL ARTE

El Estado del Arte permite situar el desarrollo del sistema web predictivo propuesto dentro del panorama actual de la investigación tecnológica aplicada a la educación. En este apartado se analizan estudios relevantes, tanto a nivel internacional como nacional, que abordan problemáticas similares mediante técnicas de aprendizaje automático, sistemas predictivos y gestión educativa basada en datos.

2.4.1 ANALISIS DE REFERENTES INTERNACIONALES

2.4.1.1 Sistema de Alerta Temprana de Deserción Escolar basado en XGBoost

Referencia: Carballo-Mendivil, B., et al. (2025). Predicción de deserción utilizando aprendizaje automático.

En el ámbito internacional más reciente, la investigación desarrollada por CarballoMendivil y colaboradores representa uno de los acercamientos más directos al uso del algoritmo XGBoost en entornos educativos. Este trabajo se centró en el desarrollo de un sistema predictivo diseñado para identificar estudiantes en riesgo de deserción en instituciones de educación superior tecnológica. El estudio utilizó variables académicas y socioeconómicas para entrenar un modelo supervisado que alerta a los administradores sobre qué alumnos tienen altas probabilidades de abandonar sus estudios, permitiendo intervenciones preventivas.

Similitudes: La similitud fundamental entre este referente y el proyecto de la Academia Autopoiesis radica en el núcleo tecnológico: ambos seleccionan el algoritmo XGBoost como motor de inferencia debido a su superioridad en el manejo de datos tabulares y su eficiencia computacional frente a otros modelos como Random Forest o Redes Neuronales. Asimismo, ambos proyectos comparten una arquitectura de implementación orientada a la web, buscando que los resultados del modelo matemático no se queden en un análisis estático, sino que se integren en una herramienta operativa para la gestión institucional.

Similitudes con el proyecto en curso

La divergencia principal es el objeto de la predicción. Mientras Carballo-Mendivil se enfoca en la "retención" (evitar que el alumno se vaya), el presente proyecto se enfoca

en la "adquisición y demanda" (predecir cuántos alumnos llegarán). El referente utiliza variables centradas en el individuo (calificaciones, estatus socioeconómico), mientras que este proyecto utiliza variables centradas en la oferta y el mercado (precio del curso, inversión en publicidad, temporalidad, cupos). Además, el sistema de Carballo-Mendívil opera bajo una lógica de riesgo, mientras que el sistema para la Academia Autopoiesis opera bajo una lógica de oportunidad de negocio y planificación de recursos.

Aporte del proyecto en curso

La mejora sustancial que introduce este proyecto es la incorporación de la Inteligencia Artificial Explicable (XAI) mediante SHAP. Aunque el referente utiliza XGBoost con éxito, a menudo estos sistemas funcionan como "cajas negras". La propuesta para la Academia Autopoiesis supera esta limitación al integrar visualizaciones SHAP que explican por qué se predice una demanda alta o baja (ej. "la predicción bajó debido al precio elevado" o "subió gracias a la difusión en redes"). Esta capacidad de explicar la causalidad de variables de marketing y gestión no está presente en el enfoque de alerta temprana del referente, dotando al director de la Academia de una herramienta mucho más potente para la toma de decisiones estratégicas y financieras, no solo académicas.

2.4.1.2 Predicción de Matrícula y Demanda Docente mediante Series de Tiempo

Referencia: Wu, C.-J., Chen, H.-M., & Chen, Y.-M. (2020). Forecasting enrollment and teacher demand using time series analysis.

Este estudio realizado en Taiwán abordó el problema de la planificación educativa a nivel macro, utilizando modelos estadísticos de series de tiempo para proyectar la matrícula de estudiantes y, consecuentemente, la necesidad de contratación de docentes. El enfoque fue predominantemente cuantitativo, basándose en registros históricos de varios años para establecer tendencias lineales y cíclicas que permitieran al gobierno y a las universidades ajustar sus presupuestos y capacidades físicas con antelación.

Similitudes del proyecto en curso.

Ambos proyectos comparten el objetivo final de la optimización de recursos. Tanto el estudio de Wu et al. como el presente proyecto buscan resolver el problema de la ineficiencia operacional causada por la incertidumbre futura. Existe una concordancia en

la necesidad de utilizar datos históricos para "mirar hacia el futuro" y evitar tanto la sobreoferta (aulas vacías o cursos cancelados) como la suboferta (pérdida de oportunidades educativas).

La diferencia tecnológica es marcada. Wu et al. utilizan métodos estadísticos clásicos de series de tiempo (como ARIMA o suavizado exponencial), los cuales son efectivos para tendencias lineales pero a menudo fallan al capturar relaciones complejas no lineales o interacciones abruptas entre variables externas. El proyecto de la Academia Autopoiesis, al utilizar Machine Learning (XGBoost), puede procesar variables exógenas dinámicas que un modelo de serie de tiempo tradicional no integra fácilmente, como el impacto de una campaña específica en Facebook o un descuento promocional puntual. Además, el referente es un estudio macro-estadístico, mientras que nuestra propuesta es un sistema de software transaccional y analítico (Flask + MySQL).

Aporte al proyecto en curso

La actual mejora reside en la granularidad y la capacidad de respuesta. Mientras que el modelo de Wu et al. ofrece proyecciones anuales o semestrales generales, el Sistema Web Predictivo propuesto permite una estimación a nivel de curso específico o diplomado. La propuesta supera al referente al integrar un módulo de gestión operativa (CRUD de cursos e inscripciones) con el módulo predictivo en una sola plataforma. Esto significa que la predicción se actualiza dinámicamente cada vez que se ingresan nuevos datos operacionales, ofreciendo una agilidad que los reportes estáticos de series de tiempo no pueden igualar.

2.4.2 ANALISIS REFERENTES NACIONALES

2.4.2.1 Proyecto 3: Minería de Datos para la Identificación de Perfiles de Deserción

Referencia: Bedregal, N., Aruquipa, M., & Cornejo, J. (2020). Aplicación de Data Mining para la gestión académica en Cochabamba.

En el contexto nacional boliviano, el trabajo de Bedregal y sus colegas es un referente clave. Aplicaron técnicas de Minería de Datos (Data Mining) en una universidad de Cochabamba para descubrir patrones ocultos en el comportamiento estudiantil, específicamente orientados a caracterizar los perfiles de deserción. Utilizaron algoritmos

de agrupamiento (clustering) y clasificación para entender qué características compartían los estudiantes que abandonaban la carrera

Similitudes al proyecto en curso

Ambas investigaciones se desarrollan en el contexto educativo boliviano, enfrentando desafíos similares como la heterogeneidad de la información y la necesidad de digitalizar procesos para la toma de decisiones. Existe una similitud en la fase de Ingeniería de Datos: tanto Bedregal como este proyecto deben enfrentar la tarea de limpiar, normalizar y estructurar datos que provienen de entornos administrativos que a menudo presentan registros manuales o poco sistematizados, una realidad común en las instituciones locales.

La principal diferencia radica en el alcance temporal y la naturaleza del análisis. El trabajo de Bedregal es de tipo descriptivo y diagnóstico (explica qué pasó y cómo son los grupos), utilizando técnicas de minería para encontrar patrones en datos estáticos. El proyecto para la Academia Autopoiesis es predictivo y prescriptivo. No se limita a describir cómo son los cursos que fracasan, sino que estima la probabilidad futura de éxito de un nuevo curso antes de que este inicie. Además, el referente nacional se presenta como un estudio académico ex post, mientras que nuestra propuesta es una solución tecnológica de software (SaaS interno) que sistematiza el flujo de trabajo diario de la institución.

CAPÍTULO III

INGENIERÍA DEL PROYECTO

CAPÍTULO III

INGENIERÍA DEL PROYECTO

3.1 INTRODUCCIÓN

El presente capítulo describe detalladamente la ingeniería del proyecto, es decir, el proceso técnico y metodológico mediante el cual se desarrolló el Sistema Web Predictivo basado en XGBoost para el apoyo en la estimación de demanda de cursos y diplomados en la Academia Autopoiesis.

Este capítulo tiene como objetivo puentear el marco teórico con la implementación real del sistema, explicando de forma estructurada cómo se materializó la solución propuesta, de acuerdo con el modelo de desarrollo seleccionado, el cronograma de sprints, y los principios de ingeniería de software.

Para la construcción del sistema se adoptó:

- Scrum, como marco ágil para el desarrollo del sistema web, organizado en 12 Sprints, dentro de estas se encuentran las respectivas Pruebas y posteriormente Resultados de Validación.
- La ingeniería del proyecto se estructura en fases técnicas incrementales, alineadas estrictamente al cronograma de desarrollo (Apéndice C), que abarcan desde la recolección y preprocesamiento de datos, el entrenamiento del modelo XGBoost, hasta la integración del sistema web, explicabilidad con SHAP y despliegue final.

3.2 OBJETIVOS DE LA PROPUESTA

1. Analizar las variables históricas, académicas y de gestión que inciden en el comportamiento de inscripción de cursos y diplomados, para identificar los factores determinantes de la demanda en la Academia Autopoiesis.
2. Aplicar técnicas de análisis predictivo mediante el algoritmo XGBoost, para estimar la demanda académica de cursos y diplomados a partir de datos institucionales históricos.

3. Implementar técnicas de explicabilidad (XAI) a los resultados del modelo predictivo utilizando para comprender la influencia relativa de las variables en la estimación de la demanda.
4. Aplicar un ecosistema web integral que operacionalice el modelo predictivo, dotando a la gerencia académica de una herramienta de apoyo a la toma de decisiones que combine la explicabilidad de la inteligencia artificial con módulos de gestión administrativa (cursos, cohortes y usuarios) necesarios para garantizar la retroalimentación continua de los datos.

3.3 DESARROLLO DE LA PROPUESTA

El desarrollo del sistema se ejecuta bajo los lineamientos de la metodología ágil Scrum, centrando los esfuerzos en la entrega de valor mediante un ciclo de vida iterativo que garantiza la calidad del software y la satisfacción de las necesidades del taller mecánico.

A través de este apartado se describe la implementación detallada de la arquitectura web y la configuración del motor de inteligencia artificial, especificando cómo la integración de herramientas avanzadas como el framework Flask Python, permite sistematizar el flujo de información desde la captura inicial de parámetros físicos hasta la generación de información predictiva de precisión, conectándose a React como Frontend para los aspectos visuales.

3.3.1 HISTORIAS DE USUARIO COMO PRODUCT BACKLOG

Se adoptó el uso de esta herramienta porque en la ingeniería de software moderna es bastante común preparar los requerimientos utilizando estas mismas por la claridad de consultar en el momento del desarrollo para saber si el avance y proceso es el correcto.

Tabla 3.1: Historia de Usuario (Autenticación y Permisos de Acceso Según el Rol)

Historia de Usuario	Número: 001
Usuario:	General
Nombre historia:	Autenticación y Permisos de Acceso Según el Rol

Historia de Usuario	Número: 001
Prioridad en negocio:	Alta
Programador responsable:	Juan Diego Mamani Coarite
Descripción:	Como usuario del Sistema Web, requiero tener un sistema de doble factor de autenticación y un sistema de permisos de acceso y visualizaciones bien adaptado para no tener problemas.
Observaciones desarrollador:	Se debe utilizar una aplicación de terceros para poder realizar la autenticación

Fuente: Elaboración Propia, 2026

Tabla 3.2: Historia de Usuario (Gestión de Cursos y Diplomados)

Historia de Usuario	Número: 002
Usuario:	Administrador
Nombre historia:	Gestión del Catálogo de Cursos y Diplomados.
Prioridad en negocio:	Alta
Programador responsable:	Juan Diego Mamani Coarite
Descripción:	Como gestor académico, quiero registrar, modificar y dar de baja los cursos y diplomados (Nombre, Cupo Máximo, Precio, Estado) para mantener actualizada la oferta formativa de la Academia Autopoiesis.

Historia de Usuario	Número: 002
Observaciones:	El frontend en React debe contener formularios validados y comunicarse a través de la API REST con Flask, almacenando los datos de forma consistente en MySQL, evitando duplicidades de cursos en el mismo periodo.

Fuente: Elaboración Propia, 2026

Tabla 3.3: Historia de Usuario (Carga y Visualización del Registro de Inscripciones Histórico)

Historia de Usuario	Número: 003
Usuario:	Administrador
Nombre historia:	Carga y Visualización del registro de Inscripciones Histórico
Prioridad en negocio:	Crítica
Programador responsable:	Juan Diego Mamani Coarite
Descripción:	Como administrador, quiero poder visualizar el registro de todos los programas y sus cohortes registrados históricamente.
Observaciones desarrollador:	El backend en Flask debe incluir un script de ingeniería de datos que realice la limpieza, normalización y codificación de las variables categóricas antes de insertarlas masivamente en la base de datos MySQL.

Fuente: Elaboración Propia, 2026

Tabla 3.4: Historia de Usuario (Panel de Registros Históricos)

Historia de Usuario	Número: 004
Usuario:	Administrador
Nombre historia:	Panel de Inscripciones Históricas
Prioridad en negocio:	Media
Programador responsable:	Juan Diego Mamani Coarite
Descripción:	Como gestor académico, quiero visualizar un dashboard interactivo con gráficas sobre el historial de matrículas, ingresos y métricas de difusión, para analizar visualmente el comportamiento pasado de la demanda.
Observaciones desarrollador:	La interfaz debe desarrollarse con React, consumiendo datos agrupados directamente desde la API en Flask y renderizando gráficos dinámicos sin necesidad de recargar la página.

Fuente: Elaboración Propia, 2026

Tabla 3.5: Historia de Usuario (Predicción de Comportamiento de futuros programas activos)

Historia de Usuario	Número: 005
Usuario:	Administrador
Nombre historia:	Predicción de Comportamiento de futuros programas activos.
Prioridad en negocio:	Crítica
Programador responsable:	Juan Diego Mamani Coarite

Historia de Usuario	Número: 005
Descripción:	Como administrador, quiero que el sistema apoye en la estimación de la cantidad de inscritos esperados para evitar ineficiencias por sobredemanda o aulas vacías.
Observaciones desarrollador:	El servidor Flask debe procesar las variables ingresadas desde React, inyectarlas en el modelo XGBoost previamente entrenado y retornar el valor numérico proyectado (inferencia) en tiempo real al frontend.

Fuente: Elaboración Propia, 2026

Tabla 3.6: Visualización de Factores Influyentes

Historia de Usuario	Número: 006
Usuario:	Administrador
Nombre historia:	Visualización factores influyentes en la predicción.
Prioridad en negocio:	Alta
Programador responsable:	Juan Diego Mamani Coarite
Descripción:	Como gestor académico, quiero saber qué factores influyen en la estimación de inscritos.
Observaciones desarrollador:	El backend generará los valores matemáticos de SHAP derivados de la predicción y los enviará a React, donde se renderizará un gráfico de cascada (waterfall) ilustrando el peso exacto de cada determinante.

Fuente: Elaboración Propia

Tabla 3.7: Historia de Usuario (Reportes de Planificación)

Historia de Usuario	Número: 007
Usuario:	Administrador
Nombre historia:	Generación de Reportes
Prioridad en negocio:	Media
Programador responsable:	Juan Diego Mamani Coarite
Descripción:	Como administrador, quiero poder extraer un documento que muestre los resultados del sistema para poder utilizarlo en reuniones de decisión y también poder mandarlo por correo a interesados.
Observaciones desarrollador:	El sistema debe utilizar una librería en el backend (ej. ReportLab o PDFKit) para consolidar las predicciones en una tabla con la identidad visual de la Academia Autopoiesis y forzar su descarga en el navegador.

Fuente: Elaboración Propia, 2026

Tabla 3.8: Historia de Usuario (Búsqueda y Filtros de Programas)

Historia de Usuario	Número: 008
Usuario:	Administrador
Nombre historia:	Listado Dinámico con Búsqueda y Filtros de Oferta Académica
Prioridad en negocio:	Media
Programador responsable:	Juan Diego Mamani Coarite

Historia de Usuario	Número: 008
Descripción:	Como gestor académico, quiero poder buscar y encontrar rápidamente cualquier programa histórico de la Academia, ya que muchas veces se reapertura algunos ya lanzados con anterioridad.
Observaciones desarrollador:	La vista del listado en React debe procesar la búsqueda de manera asíncrona mediante consultas optimizadas a la base de datos MySQL, filtrando los registros instantáneamente (Live Search).

Fuente; Elaboración Propia, 2026

Tabla 3.9: Origen de Captación en Inscripciones

Historia de Usuario	Número: 009
Usuario:	Administrador
Nombre historia:	Registro de Origen de Captación en Inscripciones
Prioridad en negocio:	Alta
Programador responsable:	Juan Diego Mamani Coarite
Descripción:	Como gestor académico, quiero que se pueda ingresar la información de origen de captación dentro de cada uno de los registros. Ya sea Facebook, Boletín Informativo, Recomendación, etc.
Observaciones desarrollador:	Esta funcionalidad es vital porque la variable PUBLICACIONES_REDES influye directamente en el modelo predictivo. Se debe validar en el frontend que los valores ingresados sean numéricos absolutos antes de su inserción.

Fuente: Elaboración Propia, 2026

3.3.2 REQUERIMIENTOS FUNCIONALES

Tabla 3.10: Requerimientos Funcionales

ID	Requerimiento Funcional	Descripción Técnica
RF-01	Autenticación y Control de Acceso (RBAC)	El sistema debe validar credenciales, encriptando contraseñas asíncronamente, y emitir tokens JWT seguros para gestionar los niveles de privilegio entre Administrador y Estudiante.
RF-02	Gestión del Catálogo de Programas	La plataforma debe permitir al administrador registrar y gestionar los cursos y diplomados (precio, modalidad, duración), persistiendo los datos estructurales en PostgreSQL.
RF-03	Ingesta y Preprocesamiento de Datos (ETL)	El servidor web Flask debe contar con un módulo para extraer, limpiar y consolidar el historial de inscripciones, generando un Feature Store listo para el machine learning.
RF-04	Panel Estadístico de Monitoreo (Dashboard)	La interfaz debe consolidar las métricas mediante componentes dinámicos desarrollados en React para visualizar gráficamente información histórica y la demanda histórica de la academia.
RF-05	Procesamiento Predictivo con XGBoost	El motor de inteligencia artificial estructurado en Python debe calcular la demanda futura utilizando validación cruzada y optimización exhaustiva de hiperparámetros mediante Búsqueda de Cuadrícula (GridSearchCV).
RF-06	Integración de Señales de telemetría de usuarios.	El sistema debe sincronizarse automáticamente con la API de Google Analytics 4, para rastrear el tráfico web y búsquedas.
RF-07	Visualización de Nivel de Riesgo e Incertidumbre	El sistema proveerá métricas absolutas de error (MAE, RMSE) y el porcentaje de varianza explicada (R^2) para transparentar el margen de incertidumbre operativa de cada proyección algorítmica.

ID	Requerimiento Funcional	Descripción Técnica
RF-08	Análisis de Importancia de Variables (SHAP)	La interfaz de resultados debe incluir gráficos en cascada (waterfalls) que revelen con exactitud qué variable matemática impulsó o restó inscripciones en la predicción algorítmica.
RF-09	Generación de Reportes y Recomendaciones	El sistema debe interpretar los resultados matemáticos y emitir recomendaciones textuales accionables en la tabla de predicciones del dashboard del administrador.

Fuente: Elaboración Propia

3.3.3 REQUERIMIENTOS NO FUNCIONALES

Tabla 3.11: Requerimientos No Funcionales

ID	Requerimiento No Funcional	Descripción Técnica
RNF-01	Privacidad de Datos y Cifrado	El sistema garantizará la confidencialidad del usuario utilizando el algoritmo Bcrypt para hashes de contraseñas y protegiendo el JWT mediante cookies estrictas HTTP-Only.
RNF-02	Despliegue y Escalabilidad (Docker)	La infraestructura global (Frontend, Backend, Base de Datos) estará empaquetada en microservicios independientes orquestados mediante Docker Compose para asegurar una escalabilidad aislada.
RNF-03	Compatibilidad y Diseño Responsivo	La interfaz gráfica de React empleará patrones modernos como Glassmorphism y utilidades Mobile-First, garantizando fluidez y adaptabilidad visual en Chrome, Edge y dispositivos móviles. Sobre todo para Estudiantes, Facilitadores y Público General que visita la web ya que el Administrador requiere la vista.

ID	Requerimiento Funcional	Descripción Técnica
RNF-04	Rendimiento Computacional del Modelo	Para garantizar su máxima precisión, el algoritmo predictivo optimizará su fase de entrenamiento utilizando la técnica de Búsqueda de Cuadrícula Exhaustiva (GridSearchCV). El sistema iterará de manera sistemática a través de una validación cruzada de 5 pliegues (5-Fold CV), evaluando exhaustivamente las diferentes combinaciones de hiperparámetros hasta hacer converger al modelo en su configuración óptima, garantizando así su capacidad de generalización y evitando el sobreajuste (overfitting).
RNF-05	Tolerancia a Fallos y Prevención de Errores	El modelo debe impedir matemáticamente la fuga de datos (Data Leakage) dividiendo el entrenamiento cronológicamente, sin mezclar aleatoriamente fechas futuras con eventos del pasado.
RNF-06	Integridad Referencial	El esquema de PostgreSQL exigirá una normalización estricta (1NF a 3NF).
RNF-07	Interoperabilidad de Arquitectura	La plataforma web debe mantener un flujo de mensajería API REST asíncrono y estable (en formato JSON) entre el entorno React del cliente y el servidor lógico Flask del administrador.
RNF-08	Manejo de Valores Nulos	El backend en Python será tolerante a la pérdida de conexión externa.
RNF-09	Mantenibilidad del Código	La programación requerirá separación de responsabilidades y modularidad absoluta. Para futuras implementaciones, integración de desarrolladores o equipos de desarrollo nuevos.

Fuente: Elaboración Propia, 2026

Con ayuda de toda esta información se desarrolló el Cronograma de Desarrollo (ver Apéndice C), como Diagrama de Venn, el cual contiene la separación de los Sprints respectivos para el desarrollo del proyecto considerando las fechas y proceso secuencial completo de todo el proyecto.

A continuación, los Sprints, Pruebas y Resultados de Validación.

3.3.4 RECOPIACIÓN Y PROCESAMIENTO DE DATOS

Fase 1 (Sprints 1 y 2)

En esta fase fundacional, el desarrollo se centró en la construcción de un ecosistema de datos robusto, partiendo de los registros históricos crudos proporcionados por la Academia Autopoiesis y complementándolos con señales del mercado externo. El objetivo central del Sprint 1 fue evitar que el modelo predictivo trabajara con datos ruidosos o aislados. Específicamente para el Sprint Backlog de esta fase, se abordó parcialmente la Historia de Usuario 003 (ver Tabla 3.3), construyendo el script de ingeniería de datos (ETL) esencial para la carga de registros en la base de datos.

3.3.4.1 Extracción de Datos Crudos Internos y Externos

La extracción inicial de datos (Raw Data) se realizó consumiendo los archivos administrativos base (*seed_programas.json* y registros históricos) creados a partir de una recolección manual desde fuentes diversas (por ejemplo: Todos los programas lanzados se obtuvieron de la página oficial de Facebook de la academia, que según Víctor Hugo Aranda, es donde se publicaron sin falta cada uno de ellos de inicio a la actualidad). Para tener el volumen necesario de aprendizaje, se implementó el script *import_data.py*, el cual introdujo de forma lógica y estructurada aproximadamente 3,000 inscripciones históricas, distribuidas entre perfiles de estudiantes reales

A continuación, se puede observar una breve porción del archivo *seed_programas.json* (ver Figura 3.1), el cual contiene información de todos los programas históricos lanzados por la academia.

Figura 3.1 Datos Crudos Academia Autopoiesis

```

{} seed_programas.json X
backend > data > {} seed_programas.json > ...
1
2   {
3     "nombre": "DEPENDENCIA EMOCIONAL",
4     "categoria": "Psicología",
5     "tipo": "Curso",
6     "costo_oficial_bs": 150.0,
7     "descripcion": "",
8     "imagen_url": ""
9   },
10  {
11    "nombre": "OBJETIVOS SEGÚN PARADIGMA Y ENFOQUE",
12    "categoria": "Investigación",
13    "tipo": "Curso",
14    "costo_oficial_bs": 150.0,
15    "descripcion": "",
16    "imagen_url": ""
17  },
18  {
19    "nombre": "OBJETO Y PROBLEMA DE INVESTIGACIÓN",
20    "categoria": "Investigación",
21    "tipo": "Curso",
22    "costo_oficial_bs": 150.0,
23    "descripcion": "",
24    "imagen_url": ""
25  },
26  {
27    "nombre": "POTENCIA TUS COMPETENCIAS INVESTIGATIVAS",

```

Fuente: Elaboración Propia, 2026

Se puede observar la terminal en el proyecto raíz corriendo el archivo `import_data.py` (ver Figura 3.2), el cual se encarga de generar los datos históricos para el Modelo de Machine Learning, este archivo de código además de éste realiza otros procesos, por lo cual también se verá más adelante. Adicionalmente se observa cómo se introducen los datos crudos con la respuesta de la terminal al correr el archivo anteriormente mencionado.

Figura 3.2 Extracción de los Datos Crudos

```
PS C:\Users\pipe-\Repositorio Local\xgboost-course-prediction> docker exec -it xgboost-c
ourse-prediction-backend-1 python import_data.py
Conectando a postgresql://admin:password123@db:5432/autopoiesis_db para Importación...
Recuperando Catálogos...
Poblando Programas Reales (Generando Cohortes Temporales)...

Generando datos históricos para Machine Learning a partir del dataset...
1. Limpiando estudiantes históricos anteriores...
2. Cargando estudiantes históricos desde semilla JSON...
  -> Insertando 1560 usuarios a la DB...
3. Cargando inscripciones desde /app/data/dataset.csv...
  -> Insertando 2983 inscripciones a la DB...


✅ Proceso de Importación finalizado con éxito (Modo Cargador).
Administrador: juandiegomc.sis@gmail.com / admin123
PS C:\Users\pipe-\Repositorio Local\xgboost-course-prediction>
```

Fuente: Elaboración Propia, 2026

3.3.4.2 Análisis exploratorio de Datos (EDA) Automatizado

Durante el Sprint 2, antes de entrenar cualquier algoritmo, se ejecutó un EDA exhaustivo. Mediante el uso de librerías como Pandas, el sistema analizó la distribución de las inscripciones semanales, identificando patrones estacionales claros (p. ej., picos de inscripción a inicio de trimestre). Se evaluó la correlación de Pearson y Spearman entre variables financieras (precio pagado) y demográficas (edad, ocupación).

Se puede observar el comienzo de resultados de la consola ejecutando la Fase 2 del avance del proyecto en la cual están claros los parámetros utilizados como ser: Media, Mediana, Desviación Estándar, Métrica de valores mínimo y máximo, Percentiles (ver Figura 3.3). Todos estos analizando la variable objetivo históricamente la cual es la cantidad de inscritos a diferentes programas de la academia.

Figura 3.3 Proceso EDA

Fuente: Elaboración Propia, 2026

3.3.4.3 Limpieza, Transformación (ETL) y Feature Engineering

La transformación de datos fue el proceso más crítico para el éxito del modelo XGBoost. En lugar de procesar los datos de manera *ad-hoc*, se construyó un pipeline ETL (*Extract, Transform, Load*) que consolida la información en una vista materializada llamada *Feature Store*. El *Feature Engineering* involucró la creación de más de 25 variables predictivas (Features), destacando:

- **Variables Temporales Cíclicas:** Se aplicaron transformaciones trigonométricas (Senos y Cosenos) a los meses del año para que la inteligencia artificial comprenda la continuidad del tiempo, evitando el salto lógico entre el mes 12 y el mes 1.
- **Lag Features (Autocorrelación temporal):** Se calcularon rezagos (conteo_lag_1, conteo_lag_4) para enseñarle al modelo que la demanda de la mensual actual depende fuertemente del volumen de inscripciones del mes anterior.

Es así como en el siguiente fragmento del script de ejecución, se pueden observar resultados de la terminal que corresponden a este proceso al correr el archivo `import_data.py`.

Figura 3.4 Procesos ETL

```
# -----
# Feature columns (in order, matching DB schema)
# -----
FEATURE_COLS = [
    # Demographics
    "edad_promedio", "edad_mediana", "edad_min", "edad_max",
    "porc_estudiantes", "porc_profesionales",
    "porc_la_paz", "porc_otros_depts",
    # Financial
    "ingreso_semana", "precio_promedio_pagado", "tasa_descuento", "precio_relativo",
    # Retention states
    "tasa_activos", "tasa_retirados", "tasa_finalizados", "tasa_pendientes",
    # Channels
    "porc_facebook", "porc_boletin", "porc_organico", "porc_recomendacion",
    # Program attributes
    "duracion_horas", "num_facilitadores", "costo_oficial_bs",
    "categoria_id", "tipo_servicio_id", "modalidad_id", "num_beneficios",
    # Cyclical temporal
    "seno_semana", "coseno_semana", "seno_mes", "coseno_mes",
    "es_inicio_trimestre", "es_fin_anio",
    # GA4 external
    "ga4_sesiones_semana", "ga4_eventos_conversion",
    "ga4_usuarios_activos", "ga4_tasa_rebote",
    # Trends external
    "trends_interes_categoria", "trends_interes_programa",
    # Lag features
    "conteo_lag_1", "conteo_lag_2", "conteo_lag_4",
    "conteo_rolling_4w", "conteo_rolling_8w",
    "conteo_mismo_periodo_anio_ant",
```

Fuente: Elaboración Propia, 2026

La exitosa ejecución de este pipeline automatizado llegó a la generación de la confirmación por consola que valida la correcta transformación estructural de todos los registros históricos. Como se puede observar en la respuesta del sistema, el script logró juntar el total de cohortes a disposición, aplicando las conversiones matemáticas necesarias (como la codificación cíclica y binaria) y definiendo las dimensiones exactas del Feature Store final (ver Figura 3.5). Con la finalización técnica de este proceso de ingeniería de datos la información abandona su estado empírico y alcanza la forma relacional óptima, quedando lista para ser consumida en la etapa de entrenamiento del modelo predictivo.

Figura 3.5 Porción Dataset Óptimo Preparado

```
PS C:\Users\pipe-\Repositorio Local\xgboost-course-prediction> docker exec -it xgboost-course-prediction-backend-1 python scripts/feature_engineering.py
Cargando datos...
Calculando variables del cohorte...
Aplicando codificación cíclica...
Aplicando One-Hot Encoding...
¡Éxito! Dataset de cohortes guardado en: /app/data/cohortes_dataset.csv
Total de cohortes procesados: 309
Dimensiones del dataset final: (309, 17)
```

Fuente: Elaboración Propia, 2026

3.3.5 DISEÑO ARQUITECTÓNICO DEL SISTEMA Y MODELADO

Fase 2 (Sprints 3 y 4)

En esta fase, el proyecto evolucionó de un entorno puramente analítico a un producto de software integral. El Sprint 3 se enfocó en la infraestructura Backend y el Sprint 4 en el diseño de interfaces (UI/UX).


3.3.5.1 Diseño de Arquitectura de Microservicios Docker

Para garantizar la escalabilidad técnica y tolerancia a fallos, se decidió contenerizar el proyecto empleando Docker. La arquitectura cliente-servidor se segmentó lógicamente en cuatro contenedores orquestados mediante docker-compose, más uno adicional (jupyter) para los notebooks corridos dentro del proyecto:

- Contenedor Frontend: Desplegando el servidor Node y Vite por el puerto 3000.
- Contenedor Backend: Alojando el entorno de Python, Flask y el motor de ML en el puerto 5000.
- Contenedor Database: Ejecutando PostgreSQL 15 para el almacenamiento OLTP y OLAP.
- Contenedor pgAdmin: Para la administración visual de la base de datos relacional.
- Contenedor Jupyter: Para la verificación de visualización de funcionamiento de variables como en el proceso EDA.

Para facilitar la perspectiva y ordenar visualmente el plan, la (Figura 3.6) demuestra el Diagrama de la Arquitectura del Sistema.

Figura 3.6 Diagrama de la Arquitectura del Sistema



Fuente: Elaboración Propia, 2026

3.3.5.2 Modelado Relacional de Base de Datos

Para estructurar los datos institucionales históricos y prepararlos para el pipeline analítico, se diseñó un modelo relacional aplicando estrictamente las reglas de normalización de bases de datos (desde la Primera Forma Normal, 1NF, hasta la Tercera Forma Normal, 3NF).

Como se evidencia en la definición del esquema del sistema (ver Figura 3.8), se implementó una separación categórica entre las entidades físicas y los registros transaccionales:

- **Evitación de Redundancia (3NF):** En lugar de duplicar valores textuales repetitivos (como nombres de departamentos, áreas de estudio, modalidades o roles de usuario), se crearon tablas de catálogo indexadas (departamentos, categorías, modalidades, roles). Esto previene dependencias transitivas e inconsistencias en la escritura.

- **Separación de Usuarios e Inscripciones:** La información demográfica y de contacto reside de forma única en la tabla usuarios. Las inscripciones a los cursos se registran como transacciones en la tabla inscripciones, la cual actúa como entidad asociativa para resolver la relación muchos a muchos (N:M) entre los usuarios y los programas académicos (agrupados por cohortes).
- **Optimización del Acceso:** Se añadieron índices en árbol B (*B-Tree*) en columnas clave frecuentemente consultadas (`idx_inscripciones_cohorte_id`, `idx_inscripciones_fecha`) para optimizar el rendimiento de las consultas y agilizar la extracción de datos durante la fase de modelado predictivo.

Esta arquitectura relacional no solo asegura la integridad de los datos en el día a día operativo de la academia, sino que estructura los campos necesarios para que el algoritmo XGBoost pueda procesar variables consistentes y limpias.

Figura 3.7 Script de Modelado de Bases de Datos

```

01_schema.sql X
db > init > 01_schema.sql
1  -- =====
2  -- ESQUEMA DE BASE DE DATOS: ACADEMIA AUTOPOIESIS (PostgreSQL 18 )[cite: 4]
3  -- =====
4
5  -- 1. Fundamento: Restricciones de Dominio y Normalización a 1NF (Primera Forma Normal) y 2NF (Segunda Forma Normal)[cite: 4]
6  -- Se crean tablas catálogo para evitar la redundancia de texto y dependencias transitivas[cite: 4].
7  -- En lugar de escribir "La Paz" o "Curso" repetidas veces (lo que rompe la 3NF (Tercera Forma Normal)),
8  -- se asigna un identificador único[cite: 4].
9
10 CREATE TABLE categorias (
11     id INT GENERATED ALWAYS AS IDENTITY PRIMARY KEY,
12     nombre VARCHAR(100) NOT NULL UNIQUE
13     -- Fundamento: Tipado Estricto y Unicidad[cite: 4].
14     -- 'nombre' tiene un límite de memoria y no permite valores nulos ni duplicados,
15     -- garantizando la consistencia de los datos[cite: 4].
16 );
17
18 CREATE TABLE tipos_servicio (
19     id INT GENERATED ALWAYS AS IDENTITY PRIMARY KEY,
20     nombre VARCHAR(50) NOT NULL UNIQUE
21 );
22
23 CREATE TABLE departamentos (
24     id INT GENERATED ALWAYS AS IDENTITY PRIMARY KEY,
25     nombre VARCHAR(50) NOT NULL UNIQUE
26 );
27
28 CREATE TABLE estados_inscripcion (
29     id INT GENERATED ALWAYS AS IDENTITY PRIMARY KEY,
30     nombre VARCHAR(50) NOT NULL UNIQUE
31 );
32
33 CREATE TABLE roles (
34     id INT GENERATED ALWAYS AS IDENTITY PRIMARY KEY,
35     nombre VARCHAR(50) NOT NULL UNIQUE
36 );
37

```


Fuente: Elaboración Propia, 2026

3.3.5.3 Prototipado y Wireframing (Mockups)

Basado en principios de Experiencia de Usuario (UX), se establecieron paletas de colores corporativos (Púrpura y Cian) correspondientes a la Academia Autopoiesis Servicios Integrales S.R.L. y se implementó la tendencia visual del Glassmorphism (fondos translúcidos). Se crearon los wireframes de las vistas principales antes de tirar código para asegurar que los gestores académicos comprendieran la visualización de datos de manera intuitiva utilizando la herramienta Figma.

Primeramente, al ser un prototipo el cual considera un acceso general al público, se diseñó la “Home Page”, respectiva la cual funcionará como punto de aterrizaje para todos los interesados en la Academia (Figura 3.8), tantos estudiantes, facilitadores, administrador y clientes potenciales.


Figura 3.8 Diseño Mockup “Home Page”



Fuente: Elaboración Propia, 2026

Considerando los roles existentes y anteriormente mencionados dentro de la Academia, se desarrolló el Mockup de la página de Logueo, la cual contiene una interfaz simple e intuitiva para el administrador ya que se limita a dos espacios para sus credenciales: Usuario y Contraseña (Figura 3.10).


Figura 3.10 Diseño Mockup “Login”



Fuente: Elaboración Propia, 2026

Tanto el aporte como los procesos principales solicitados en la Entrevista (Apéndice A) se tratan de plasmar en las siguientes figuras, las cuales se mostraron como aporte visual hacia los interesados, éste presenta una estructuración visual simple y amigable para el usuario considerando dos secciones importantes: Barra Lateral Izquierda (el cual funciona como menú de navegación) y Cuerpo Lateral Derecho (donde prácticamente se muestra toda la información, dashboards, kpi's, listas, etc. Necesarios para servir como herramienta para el administrador y sirva como fuente de información para cuando así lo requiera en el momento preciso. Dicha sección es volátil ya que en el mundo del desarrollo los usuarios tienen a encontrar sus propios requisitos en el camino mediante el desarrollo del mismo, lo cual la metodología SCRUM, considera y respeta, tomando en cuenta al usuario final como parte del equipo en el proceso semanal, por lo que el cambió con el resultado final no debería ser extraño a esto (Figura 3.11).


Figura 3.11 Diseño Mockup “Panel Inicio”



Fuente: Elaboración Propia, 2026

El resultado del modelo predictivo reflejado en el sistema web se proyectó a tener una forma como la siguiente. (ver Figura 3.11).


Figura 3.11 Diseño Mockup “Panel Predictivo”



Fuente: Elaboración Propia, 2026

Como aporte administrativo para la información histórica, también se consideran páginas de creación, eliminación, modificación, búsqueda. (ver Figura 3.12).

Figura 3.12 Diseño Mockup “Panel Inscripciones”




Fuente: Elaboración Propia, 2026

3.3.5.4 Configuración del Entorno y Orquestación

Se consolidó la estructura de directorios en el entorno local empleando VSCode, respetando el diagrama definido en la (Figura 3.6) asegurando la correcta separación entre las carpetas de frontend/ y backend/. Finalmente, el archivo docker-compose.yml unificó el sistema para permitir levantarlo con un solo comando: `docker-compose up -d --build`, validando la comunicación asíncrona entre todos los nodos.

En la (Figura 3.13), se muestra el resultado de la organización de carpetas donde se realizó la codificación, scripts, notebooks, datasets, el archivo .pkl resultante del entrenamiento. Es el lienzo donde se construye el proyecto entero definido así por el enfoque de contenerización que se consideró para el despliegue.


Figura 3.13 Carpetas y Estructura base del proyecto en VSCode



Fuente: Elaboración Propia, 2026

Justamente, a continuación, se demuestra la orquestación en Docker, la cual corresponde a un archivo `.yaml`. Archivo bastante importante y esencial tanto para el Desarrollo como Despliegue del Proyecto (ver Figura 3.14).

Figura 3.14 Estructura Principal de archivo docker-compose.yaml



```

1  services:
54  frontend:
63    environment:
65      CHOKIDAR_USEPOLLING: "true"
66    volumes:
67      - ./frontend:/app
68      - /app/node_modules
69    depends_on:
70      backend:
71        condition: service_started
72
73  pgadmin:
74    image: dpage/pgadmin4
75    restart: unless-stopped
76    environment:
77      PGADMIN_DEFAULT_EMAIL: ${PGADMIN_DEFAULT_EMAIL:-admin@autopoiesis.com}
78      PGADMIN_DEFAULT_PASSWORD: ${PGADMIN_DEFAULT_PASSWORD:-admin}
79      TZ: ${TZ:-America/La_Paz}
80    ports:
81      - "${PGADMIN_PORT:-5051}:80"
82    depends_on:
83      db:
84        condition: service_healthy
85
86  volumes:
87    postgres_data:
88


```

Fuente: Elaboración Propia, 2026

Para habilitar la comunicación entre el motor de base de datos y la interfaz de usuario en React, se desarrolló una API RESTful centralizada utilizando el framework Flask (Python). La arquitectura del backend fue diseñada bajo un enfoque de microservicios lógicos, definiendo rutas específicas (endpoints) para cada módulo del sistema, tales como la gestión de programas académicos, autenticación de usuarios y consumo del modelo predictivo XGBoost.

Para garantizar la seguridad en la transmisión de datos, el servidor implementó políticas estrictas de CORS (*Cross-Origin Resource Sharing*) permitiendo únicamente peticiones provenientes del dominio del frontend. Asimismo, el control de acceso a rutas protegidas se desarrolló mediante decoradores personalizados que validan tokens JWT (*JSON Web Tokens*) inyectados y transmitidos a través de cookies *HTTP-Only*, mitigando así vulnerabilidades de tipo XSS. La estructura de estos controladores permite que el frontend consuma datos de manera asíncrona, recibiendo respuestas estandarizadas en formato JSON (ver Figura 3.15).

Figura 3.15 Estructura Backend




```

539 @app.route('/api/programas', methods=['GET'])
540 def get_public_programas():
541     """Retorna el catálogo unificado de Cursos y Diplomados ACTIVOS para la Portada"""
542     with get_db_connection() as conn:
543         result = conn.execute(text("""
544             SELECT p.id, p.nombre, p.costo_oficial_bs, c.nombre as categoria,
545                    ts.nombre as tipo, m.nombre as modalidad,
546                    p.duracion_horas,
547                    p.imagen_url, p.descripcion, p.activo
548             FROM programas p
549             JOIN categorias c ON p.categoria_id = c.id
550             JOIN tipos_servicio ts ON p.tipo_servicio_id = ts.id
551             JOIN modalidades m ON p.modalidad_id = m.id
552             WHERE p.activo = true AND p.eliminado = false
553             ORDER BY p.id DESC
554         """)).fetchall()
555
556     programas = []
557     for r in result:
558         programas.append({
559             "id": r.id,
560             "nombre": r.nombre,
561             "costo": float(r.costo_oficial_bs),
562             "categoria": r.categoria,
563             "tipo": r.tipo,
564             "modalidad": r.modalidad,
565             "duracion_horas": r.duracion_horas,
566             "imagen_url": r.imagen_url,
567             "descripcion": r.descripcion,
568             "activo": r.activo
569         })
570     return jsonify(programas)

```

Como se utilizó la herramienta Docker, un complemento importante y práctica cotidiana de desarrollo, es el uso de un repositorio guardado en la nube, en este caso GitHub. Hay bastantes ventajas que justifican su uso, entre ellas, la seguridad de tener el proyecto siempre disponible para realizar clonaciones y posteriores pruebas en distintas PC, también, el manejo de versiones controlado, copia de seguridad, entre muchos otros. (Figura 3.16).

Figura 3.16 Repositorio GitHub



Fuente: Elaboración Propia, 2026

3.3.6 ENTRENAMIENTO DEL MODELO PREDICTIVO XGBOOST

Fase 3 (Sprints 5, 6 y 7)


El núcleo inteligente y predictivo del sistema fue programado en el entorno Backend a través de Python. Para dotar al desarrollo de un rigor científico y académico adecuado, el ciclo de vida del aprendizaje automático se orquestó con el apoyo de la metodología

CRISP-DM (Cross-Industry Standard Process for Data Mining). Esta estructuración iterativa en seis fases permitió mitigar riesgos y asegurar que el modelo matemático resultante respondiera genuinamente al problema de la academia.

3.3.6.1 Comprensión del Negocio (Business Understanding)

El objetivo primordial del proyecto consistió en transformar la intuición empírica de la Academia Autopoiesis en un entorno de certidumbre estocástica. Matemáticamente, el problema se planteó como un modelo de **Regresión Supervisada**. El objetivo técnico fue lograr que el algoritmo aprenda a predecir la variable objetivo-continua ($Y =$ Tamaño del Cohorte), basándose en un vector de variables independientes estáticas (X_i) previas al lanzamiento comercial del programa. (ver Figura 3.17)

Figura 3.17 Función Matemática del Modelo



Fuente: Elaboración Propia (2026)

3.3.6.2 Comprensión de los Datos (Data Understanding)

Como indica una segunda etapa de la metodología, para comprender las dimensiones probabilísticas del problema, se utilizó el entorno interactivo de Jupyter Notebooks. A través del Análisis Exploratorio de Datos (EDA), se auditaron las distribuciones estadísticas de la demanda, identificando agrupaciones atípicas (outliers) y

comprobando la integridad de los registros históricos exportados del motor PostgreSQL. Se descubrió una alta dependencia entre la fecha de apertura de un curso y su éxito comercial, sentando las bases para la ingeniería de características. (ver Figura 3.18).

Figura 3.18: Diccionario de Datos


```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 3000 entries, 0 to 2999
Data columns (total 35 columns):
#   Column                                Non-Null Count  Dtype
---  -
0   programa_id                          3000 non-null   int64
1   anio                                 3000 non-null   int64
2   semana_del_anio                      3000 non-null   int64
3   conteo_demanda                       3000 non-null   int64
4   edad_promedio                        3000 non-null   float64
5   porc_estudiantes                     3000 non-null   float64
6   porc_profesionales                   3000 non-null   float64
... (se omiten columnas por brevedad)
32  seno_semana                          3000 non-null   float64
33  coseno_semana                        3000 non-null   float64
34  es_inicio_trimestre                  3000 non-null   int64
dtypes: float64(25), int64(10)
memory usage: 820.4 KB
```

Fuente: Elaboración Propia, 2026

3.3.6.3 Preparación de los Datos (Data Preparation)

Esta es la fase de mayor densidad algorítmica, ya que el algoritmo XGBoost requiere matrices numéricas estrictas. Se desarrolló el script de procesamiento automatizado `feature_engineering.py` para transformar la base de datos transaccional en un *Feature Store* analítico. Para modelar la estacionalidad del tiempo (meses del año) sin que el algoritmo interprete un salto errático entre diciembre (12) y enero (1), se programó una **Codificación Cíclica Temporal** (ver Figura 3.19) inyectando trigonometría (Funciones Seno y Coseno) a las fechas de lanzamiento. Asimismo, se vectorizó la información cualitativa utilizando el método de *One-Hot Encoding* (ver Figura 3.20).

Figura 3.19: Codificación Cíclica Temporal




```

feature_engineering.py X
backend > scripts > feature_engineering.py
6 def feature_engineering():
35
36     # 3. Feature Engineering: Codificación Cíclica Temporal
37     # Usamos senos y cosenos para que Diciembre (12) y Enero (1) estén "cerca" matemáticamente.
38     print("Aplicando codificación cíclica...")
39     cohortes_stats['Seno_Mes'] = np.sin(2 * np.pi * cohortes_stats['Mes_Lanzamiento'] / 12)
40     cohortes_stats['Coseno_Mes'] = np.cos(2 * np.pi * cohortes_stats['Mes_Lanzamiento'] / 12)
..

```

Fuente: Elaboración Propia, 2026

Figura 3.20: ONE-HOT ENCODING



```

feature_engineering.py X
backend > scripts > feature_engineering.py
6 def feature_engineering():
42     # 4. Feature Engineering: One-Hot Encoding
43     print("Aplicando One-Hot Encoding...")
44     # get_dummies genera columnas como Tipo_Programa_Diplomado, Categoria_Derecho, etc.
45     df_encoded = pd.get_dummies(cohortes_stats, columns=['Tipo_Programa', 'Categoria'])
46

```


Fuente: Elaboración Propia, 2026

3.3.6.4 Modelado (Modeling)

Con los datos estructurados, se procedió a la implementación algorítmica central (train_model.py). Se instanció el modelo XGBRegressor por su destacable optimización en el uso de memoria y la construcción iterativa de árboles de decisión (*Gradient Boosting*). Para aislar un entorno de prueba inquebrantable que evite la fuga de información (*Data Leakage*), el código dividió estrictamente la matriz matricial en un entorno 80/20 mediante la técnica train_test_split (ver Figura 3.21). Para evitar que el modelo sufriera un sesgo humano, no se usaron parámetros preestablecidos. En su lugar, el sistema fue sometido a una técnica exhaustiva de optimización de hiperparámetros mediante la clase GridSearchCV (ver Figura 3.22). El algoritmo ejecutó un entrenamiento intensivo iterando a través de validación cruzada de 5 pliegues (*5-Fold*

CV), ajustando milimétricamente la profundidad del árbol (max_depth) y las tasas de aprendizaje (learning_rate).

Figura 3.21: Código de Prevención de Fuga




```

train_model.py X
backend > ml > train_model.py
13 def train():
40     # 4. División Train-Test (80% Entrenamiento, 20% Prueba)
41     print("Dividiendo en Conjunto de Entrenamiento (80%) y Prueba (20%)...")
42     X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2, random_state=42)
43     print(f"Dimensiones Train: {X_train.shape}, Test: {X_test.shape}")

```

Fuente: Elaboración Propia (2026)

Figura 3.22: Código Múltiples Dimensiones GridSearchCV



```

train_model.py X
backend > ml > train_model.py
13 def train():
44
45     # 5. Configuración Base y Ajuste de Hiperparámetros (GridSearchCV)
46     print("Iniciando búsqueda de hiperparámetros (GridSearchCV)...")
47     xgb_model = xgb.XGBRegressor(random_state=42, objective='reg:squarederror')
48
49     # Malla de parámetros a explorar
50     param_grid = {
51         'n_estimators': [50, 100, 150],
52         'learning_rate': [0.01, 0.05, 0.1],
53         'max_depth': [3, 5, 7],
54         'subsample': [0.8, 1.0]
55     }
56
57     grid_search = GridSearchCV(
58         estimator=xgb_model,
59         param_grid=param_grid,
60         scoring='neg_mean_absolute_error', # Buscamos minimizar el error absoluto
61         cv=5, # Validación cruzada de 5 pliegues
62         verbose=1,
63         n_jobs=-1
64     )
65
66     # Entrenar la malla
67     grid_search.fit(X_train, y_train)


```

Fuente: Elaboración Propia

3.3.6.5 Evaluación de Desempeño (Evaluation)

Concluido el ciclo de entrenamiento, el algoritmo definitivo (`best_model`) fue forzado a predecir los resultados de la matriz de datos aislada (*Test Set*). Para tener una validación matemática objetiva, se programó el cálculo automático de los principales indicadores de precisión para modelos de regresión: El Error Absoluto Medio (MAE), la Raíz del Error Cuadrático Medio (RMSE) y el Coeficiente de Determinación (R^2). Estos estadísticos evalúan exactamente la magnitud de los residuos (errores) entre las predicciones del modelo y las realidades pasadas de la academia. (ver Figura 3.23).

Figura 3.23: Cálculo de Métricas



```

train_model.py X
backend > ml > train_model.py
13 def train():
14     /s
15
16     # 6. Evaluación de Métricas en el Conjunto de Prueba
17     print("\nEvaluando el modelo con datos no vistos (Test Set)...")
18     y_pred = best_model.predict(X_test)
19
20     # Cálculo de métricas académicas
21     mae = mean_absolute_error(y_test, y_pred)
22     rmse = np.sqrt(mean_squared_error(y_test, y_pred))
23     r2 = r2_score(y_test, y_pred)
24
25     print(f"MAE (Error Absoluto Medio): {mae:.2f} alumnos.")
26     print(f"RMSE (Raíz del Error Cuadrático Medio): {rmse:.2f} alumnos.")
27     print(f"R² (Coeficiente de Determinación): {r2:.4f} ({(r2*100):.1f}% de la varianza explicada).")
28
29

```

Fuente: Elaboración Propia, 2026

3.3.6.6 Despliegue (Deployment)

Al validar que el desempeño era superior a la deducción humana tradicional, se abordó la serialización del componente inteligente. El modelo convergió y fue exportado a formato binario (Pickle) mediante la biblioteca `joblib`, generando el archivo final `xgboost_model.pkl`. (ver Figura 3.25). Esto permite que el algoritmo extraiga su estado cognitivo aprendido y pueda ser invocado instantáneamente (sin requerir re-entrenamiento) por la API REST del ecosistema de producción, dejando constancia de la culminación del desarrollo.


Figura 3.24: Código de Exportación y Serialización


```

train_model.py
backend > ml > train_model.py
82 joblib.dump(best_model, model_export_path)
102
103 # 8. Exportación del Modelo Definitivo
104 print("\nExportando el modelo optimizado (.pkl)...")
105 joblib.dump(best_model, model_export_path)
106 print(f"¡Éxito! Modelo exportado a: {model_export_path}")
107
108 print("\nGuardando metadatos del modelo...")
109 metadata = {
110     "training_date": datetime.now().isoformat(),
111     "training_record_count": len(df)
112 }
113 with open(metadata_path, 'w', encoding='utf-8') as f:
114     json.dump(metadata, f, indent=4)
115
116 print("Pipeline de Machine Learning concluido satisfactoriamente.")
117
118 if __name__ == "__main__":
119     train()

```

Fuente: Elaboración Propia, 2026

Figura 3.25: Archivo Final Generado

Fuente: Elaboración Propia

3.3.7 DESARROLLO DE PLATAFORMA WEB Y MÓDULOS

Fase 4 (Sprints 7, 8, 9)

Una vez que el modelo XGBoost fue entrenado y exportado, el objetivo pasó a ser el diseño de la herramienta administrativa mediante el o los administradores operarían diariamente. El Sprint Backlog para estos sprints integró las Historias de Usuario 001, 002, 004, 007, 008 y 009. Durante el Sprint 7 y 8 se resolvió la HU-001 con la

implementación de JWT y RBAC. En los Sprints 8 y 9 se desarrollaron los CRUDs (HU-002, HU-008, HU-009) y los dashboards y reportes en React (HU-004 y HU-007).

3.3.7.1 Construcción del Backend (API REST) y Seguridad

Durante el Sprint 7, se construyó una API REST en Python utilizando el framework Flask. Se implementó SQLAlchemy como ORM (*Object-Relational Mapping*) para mapear las tablas de la base de datos hacia objetos manipulables. A nivel de ciberseguridad, se implementó un sistema de autenticación asíncrona utilizando tokens JWT (*JSON Web Tokens*) inyectados mediante cookies *HTTP-Only*, junto con el encriptado de contraseñas mediante el algoritmo bcrypt. Adicionalmente, se programó un Control de Acceso Basado en Roles (RBAC), asegurando lógicamente que solo el rol "Administrador" tenga los privilegios para detonar el reentrenamiento del modelo predictivo y lanzar campañas, aislando a los perfiles de estudiantes y facilitadores a módulos de consulta.

Figura 3.26: Código de Seguridad JWT/RBAC

```

app.py x
backend > app.py

42 def admin_required(f):
43     """Decorador para proteger rutas requiriendo el rol de Administrador usando JWT en Cookies HTTP-Only"""
44     def wrap(*args, **kwargs):
45         token = request.cookies.get('access_token')
46         if not token:
47             return jsonify({"error": "No token provisto. Acceso denegado."}), 401
48
49         try:
50             decoded = jwt.decode(token, SECRET_KEY, algorithms=["HS256"])
51             if decoded.get('rol') != 'Administrador':
52                 return jsonify({"error": "No tienes privilegios de Administrador."}), 403
53
54             # Pasar info del usuario a la función
55             request.user_info = decoded
56         except jwt.ExpiredSignatureError:
57             return jsonify({"error": "Token expirado. Inicia sesión nuevamente."}), 401
58         except jwt.InvalidTokenError:
59             return jsonify({"error": "Token inválido."}), 401
60
61         return f(*args, **kwargs)
62     wrap.__name__ = f.__name__
63     return wrap
64
65 def auth_required(f):
66     """Decorador para proteger rutas requiriendo un JWT válido sin importar el rol"""
67     def wrap(*args, **kwargs):
68         token = request.cookies.get('access_token')
69         if not token:
70             return jsonify({"error": "No token provisto. Acceso denegado."}), 401
71
72         try:
73             decoded = jwt.decode(token, SECRET_KEY, algorithms=["HS256"])
74             request.user_info = decoded
75         except jwt.ExpiredSignatureError:
76             return jsonify({"error": "Token expirado. Inicia sesión nuevamente."}), 401
77         except jwt.InvalidTokenError:
78             return jsonify({"error": "Token inválido."}), 401

```


Fuente: Elaboración Propia

3.3.7.2 Frontend React y Módulo de Gestión

Durante los Sprints 8 y 9, se levantó la interfaz de usuario consumiendo la API construida. El entorno frontend fue desarrollado utilizando la librería React (versión 19) montada sobre el empaquetador Vite para garantizar tiempos de compilación óptimos. Mediante la librería react-router-dom, el sistema fue concebido estructuralmente como una *Single Page Application* (SPA). Esta arquitectura elimina por completo los tiempos de recarga del navegador al cambiar de módulo, brindando una experiencia de usuario fluida e

instantánea, esencial para herramientas de gestión de datos pesados y visualización de gráficos. (ver Figura 3.27).

Figura 3.27: Código de Enrutamiento SPA



```

87  function App() {
94      <main style={{ flex: 1 }}>
95          <Routes>
96              {/* Rutas Públicas */}
97              <Route path="/" element={<Home />} />
98              <Route path="/cursos" element={<Cursos />} />
99              <Route path="/diplomados" element={<Diplomados />} />
100             <Route path="/programa/:id" element={<ProgramaDetalle />} />
101
102             {/* Ruta Login y Registro */}
103             <Route path="/login" element={<Login />} />
104             <Route path="/registro" element={<Registro />} />
105             <Route path="/verificar-email" element={<VerificarEmail />} />
106             <Route path="/reset-password" element={<ResetPassword />} />
107             <Route path="/cambiar-password-forzado" element={
108                 sessionStorage.getItem('isLoggedIn') === 'true' && JSON.parse(sessionStorage.getItem('user'))
109                 ? <ForcePasswordChange />
110                 : <Navigate to="/dashboard" replace />
111             } />
112
113             {/* Rutas Privadas */}
114             <Route path="/dashboard" element={
115                 <PrivateRoute>
116                     <DashboardLayout />
117                 </PrivateRoute>
118             }>
119             {/* Rutas compartidas o de Estudiante */}
120             <Route index element={<DashboardIndex />} />
121             <Route path="seguridad" element={<Seguridad />} />
122             <Route path="preferencias" element={<Preferencias />} />
123
124             {/* Rutas exclusivas de Administrador */}
125             <Route path="estudiantes" element={
126                 <RoleRoute allowedRoles={['Administrador']}>
127                     <GestorEstudiantes />
128                 </RoleRoute>
129             } />

```

Fuente: Elaboración Propia, 2026

3.3.8 INTEGRACIÓN DE EXPLICABILIDAD Y DESPLIEGUE

Fase 5 (Sprints 10, 11, 12).

En la fase de cierre representó el hito de unión entre el área de Machine Learning y la de Desarrollo Web, con un enfoque absoluto en la usabilidad y la transparencia de la IA. Para los Sprints de cierre, el Sprint Backlog se centró en las Historias de Usuario 005 y

006. En el Sprint 10 se conectó la API para consumir el modelo predictivo (HU-005) y en el Sprint 11 se integró la librería SHAP renderizando los gráficos de cascada en el frontend (HU-006).

3.3.8.1 Integración de Explicabilidad (SHAP)

El mayor reto para la adopción de algoritmos complejos en instituciones es el efecto "caja negra". Para solucionar esto, el Sprint 10 se dedicó a la Inteligencia Artificial Explicable (XAI). Se implementó la librería SHAP (SHapley Additive exPlanations) usando su componente TreeExplainer. El sistema fue configurado para que, cada vez que XGBoost proyecta la demanda de un diplomado, SHAP analice la inferencia en segundo plano y calcule qué variables (p. ej. estacionalidad o publicidad) empujaron matemática y lógicamente el número hacia arriba o hacia abajo. Estos datos persistieron en PostgreSQL utilizando el tipo de dato nativo JSONb.

El cálculo de los valores Shap, se manejó en el archivo: predict.py. (Figura 3.40). La extracción de la variable principal es importante porque demuestra la conexión matemática entre el modelo predictivo, la biblioteca SHAP y la traducción de los datos a lenguaje natural.

Figura 3.28: Inferencia Shap

```

predict.py U X
backend > ml > predict.py
95 def predict_programa(programa_id, semana, anio, features_dict=None):
134     # 2. Explicabilidad SHAP
135     shap_vals = _explainer.shap_values(x_input)
136
137     if isinstance(shap_vals, list):
138         shap_vals = shap_vals[0]
139
140     shap_values_dict = {}
141     for i, col in enumerate(FEATURE_COLS):
142         shap_values_dict[col] = float(shap_vals[0][i])
143
144     top_feature = max(shap_values_dict, key=lambda k: abs(shap_values_dict[k]))
145
146     # 3. Intervalo de confianza heurístico (cuando no es bootstrap en batch)
147     demanda_lower = max(0.0, demanda_predicha - demanda_predicha * 0.20)
148     demanda_upper = demanda_predicha + demanda_predicha * 0.20
149     nivel_confianza = 0.85
150
151     # 4. Recomendación accionable y nivel de riesgo
152     if demanda_predicha > 10.0:
153         recomendacion = "Alta demanda proyectada. Lanzamiento recomendado. Considere aumentar cupos."
154         nivel_riesgo = "bajo"
155     elif demanda_predicha >= 4.0:
156         recomendacion = "Demanda moderada esperada. Evalúe costo vs. umbral de rentabilidad."
157         nivel_riesgo = "medio"
158     else:
159         recomendacion = "Demanda baja proyectada. Se recomienda posponer o fortalecer campaña de marketing."
160         nivel_riesgo = "alto"
161
162     return {
163         "demanda_predicha": demanda_predicha,
164         "demanda_lower": demanda_lower,
165         "demanda_upper": demanda_upper,
166         "nivel_confianza": nivel_confianza,
167         "shap_values_dict": shap_values_dict,
168         "top_feature": top_feature,
169         "recomendacion": recomendacion,

```

Fuente: Elaboración Propia, 2026

El `train_model.py`, contiene la captura del entrenamiento del mejor modelo otorgado por XGBoost, para realizar el ranking de variables correspondiente (Figura 3.29).

La inicialización de `shap.TreeExplainer(best_model)`, el cálculo de `shap_values = explainer.shap_values(X_test)`, y la generación del gráfico global con `shap.summary_plot` guardado como `shap_summary.png`.

Figura 3.29: Pipeline de Entrenamiento y Shap Global


```

train_model.py X
backend > ml > train_model.py
13 def train():
86
87     # 7. Explicabilidad: SHAP Values
88     print("\nGenerando explicabilidad visual (SHAP)...")
89     explainer = shap.TreeExplainer(best_model)
90     shap_values = explainer.shap_values(X_test)
91
92     # Configuración del gráfico
93     plt.figure(figsize=(10, 6))
94     shap.summary_plot(shap_values, X_test, show=False)
95     plt.title('Impacto de las Variables en el Tamaño del Cohorte (SHAP)')
96     plt.tight_layout()
97
98     # Guardar gráfico
99     plt.savefig(shap_plot_path, bbox_inches='tight', dpi=300)
100    plt.close()
101    print(f"Gráfico SHAP guardado en: {shap_plot_path}")

```

Fuente: Elaboración Propia, 2026

3.3.8.2 Panel Predictivo Interactivo y Decisiones Basadas en Datos

Durante sprints anteriores se realizó la conexión del modelo y explicabilidad con la parte visual, también en el Sprint 11, el frontend en React se conectó a la API predictiva. Se utilizaron bibliotecas de renderizado gráfico como Recharts para generar gráficos interactivos de cascada (Waterfall Charts). Estos gráficos tradujeron los números complejos de SHAP a una interfaz visualmente comprensible. Además, se desarrolló un algoritmo lógico secundario para procesar el árbol de resultados y emitir Recomendaciones Textuales Automáticas para el gestor académico (por ejemplo: Este gráfico de explicabilidad (SHAP) muestra qué variables influyen más al momento de predecir la demanda. El color verde indica un valor alto en esa variable, y el rojo un valor bajo. Seguido del gráfico SHAP global que muestra las variables más influyentes para el desarrollo del entrenamiento del modelo). Todo esto se muestra en la sección “Ficha técnica del Modelo”.

Para el detalle predictivo de cada uno de los programas históricos El formateo de los valores de SHAP provenientes de la API, donde se asigna el color verde (#51cf66) para valores positivos y rojo (#ff6b6b) para negativos. (Figura 3.30).

Figura 3.30: Asignación de colores para gráficos SHAP

```

IAPredictivaDetalle.jsx M X
frontend > src > pages > dashboard > IAPredictivaDetalle.jsx > IAPredictivaDetalle
34 const IAPredictivaDetalle = () => {
47 const fetchRealPredictiveData = async (id) => {
81 // Extraemos y ordenamos los valores SHAP reales devueltos por XGBoost para el mes objetivo
82 const shapEntries = Object.entries(progData.shap_values)
83 .map(([key, value]) => ({
84   name: key.replace('Categoria_', 'Cat: ').replace('Tipo_Programa_', 'Tipo: '),
85   value: value,
86   color: value >= 0 ? '#51cf66' : '#ff6b6b'
87 })))
88 .sort((a, b) => Math.abs(b.value) - Math.abs(a.value))
89 .slice(0, 6);
90
91 setShapData(shapEntries);

```

Fuente: Elaboración Propia, 2026

A continuación, la etiqueta <BarChart> de Recharts renderizando las barras interactivas con los colores asignados en el anterior paso. Es importante porque demuestra la conexión visual en React para transformar los números complejos de SHAP en la interfaz final. (Figura 3.31).

Figura 3.31. Renderizado de barras interactivas

```

IAPredictivaDetalle.jsx M X
frontend > src > pages > dashboard > IAPredictivaDetalle.jsx > IAPredictivaDetalle
34 const IAPredictivaDetalle = () => {
273
274   <div className="chart-shap-container" style={{ height: '220px', width: '100%' }}>
275     <ResponsiveContainer width="100%" height="100%">
276       <BarChart data={shapData} layout="vertical" margin={{ left: 80, right: 20 }}>
277         <CartesianGrid strokeDasharray="3 3" horizontal={true} vertical={false} opacity={0.3} />
278         <XAxis type="number" tick={{fill: 'var(--text-muted)'}} />
279         <YAxis dataKey="name" type="category" width={100} tick={{fill: 'var(--text-main)', fontSize: 12, fontWeight: 'bold'}} />
280         <RechartsTooltip content={CustomTooltip} />
281         <Bar dataKey="value" radius={[0, 4, 4, 0]} barSize={20}>
282           {shapData.map((entry, idx) => (
283             <Cell key={`cell-${idx}`} fill={entry.color} />
284           ))}
285         </Bar>
286       </BarChart>
287     </ResponsiveContainer>
288   </div>
289 </div>

```


Fuente: Elaboración Propia, 2026

3.3.8.3 Despliegue Docker

Finalmente, el Sprint 12 consolidó el Despliegue (Deployment). Se depuraron las variables de entorno de producción y se validó la persistencia de los volúmenes de datos de Docker. Se realizaron pruebas de estrés en las conexiones asíncronas entre la UI y el motor analítico, concluyendo en un sistema de estimación educativa pionero, rápido y 100% auditable.

El archivo `“.env”` (Figura 3.32) del repositorio contiene las configuraciones base y las credenciales del entorno de producción. Su propósito fundamental es aislar los datos sensibles del control de versiones. Tanto el archivo `app.py` como `db.py` consumen dinámicamente estas variables de entorno en tiempo de ejecución. Esto garantiza que ninguna clave secreta, token JWT, puerto o credencial de base de datos quede 'hardcodeada' (escrita estáticamente) en el código fuente, cumpliendo así con los más altos estándares de ciberseguridad e integridad de la aplicación.

Figura 3.32: Arvchivo .env




```
1 # Project Configuration
2 POSTGRES_USER=admin
3 POSTGRES_PASSWORD=password123
4 POSTGRES_DB=autopoiesis_db
5
6 SECRET_KEY=autopoiesis_super_secret_dev_key
7
8 # Timezone (Bolivia)
9 TZ=America/La_Paz
10
11 # Host ports
12 FRONTEND_PORT=3000
13 BACKEND_PORT=5000
14 DB_PORT=5433
15 PGADMIN_PORT=5051
16
17 PGADMIN_DEFAULT_EMAIL=admin@autopoiesis.com
18 PGADMIN_DEFAULT_PASSWORD=admin
19
20 # =====
21 # SMTP CONFIGURATION (Gmail)
22 # =====
23 MAIL_SERVER=smtp.gmail.com
24 MAIL_PORT=587
25 MAIL_USE_TLS=True
26 MAIL_USERNAME=juandiegomc.sis@gmail.com
27 MAIL_PASSWORD=mnwyhzwmrnqjqnk
28 MAIL_DEFAULT_SENDER=juandiegomc.sis@gmail.com
```

Fuente: Elaboración Propia

La persistencia se maneja mediante Docker. Se muestra la prueba de levantamiento de las imágenes respectivas, preparándose para el despliegue. (Figura 3.33).

Figura 3.33: Preparación de imágenes Docker para Despliegue Final



Fuente: Elaboración Propia, 2026

3.3.9 PRUEBAS Y VALIDACIÓN DEL SISTEMA


En concordancia con los principios iterativos de la metodología ágil Scrum, la fase de control de calidad no se relegó al final del proyecto, sino que se ejecutó de forma continua a lo largo de los 12 Sprints. El ecosistema desarrollado, al poseer tanto una arquitectura web interactiva como un motor analítico avanzado, requirió un protocolo de pruebas multidimensional. A continuación, se detallan los mecanismos técnicos implementados para validar la fiabilidad de la plataforma.

3.3.9.1 Pruebas Unitarias y de Aislamiento (Backend y Frontend)

Para garantizar la estabilidad del código fuente, se ejecutaron pruebas unitarias orientadas a aislar cada componente crítico de la aplicación. En el entorno de Python (Flask), se verificó el correcto funcionamiento de los controladores lógicos (*Controllers*)

mediante la inyección de peticiones controladas a los *endpoints*, validando que las funciones de registro de usuarios, cálculo de contraseñas *Bcrypt* y generación de tokens JWT retornaran los códigos de estado HTTP correspondientes (ej. 200 OK o 401 Unauthorized), tal y como se evidencia en la simulación de peticiones (ver Figura 3.40). En paralelo, en el entorno de React, se aislaron los componentes visuales para certificar que el empaquetado y enrutamiento (SPA) no sufrieran quiebres frente a datos nulos.

Figura 3.34: Ejecución de Integración y Concurrency (API REST)




Fuente: Elaboración Propia, 2026

3.3.9.2 Pruebas de Integración y Concurrency (API REST)

Una vez validados los módulos individuales, se procedió a la prueba de integración de microservicios dentro de la arquitectura Docker. El objetivo principal fue auditar la capa de comunicación (API REST) que une el Frontend, el Backend y el motor de Base de Datos PostgreSQL. A través del monitoreo del tráfico de red, se validó el correcto flujo de los encabezados de autorización (CORS y Tokens) y la respuesta eficaz del motor relacional, asegurando que el sistema logre entrelazar todas sus tecnologías sin cuellos de botella (ver Figura 3.35).

Figura 3.35: Evidencia de Pruebas de Integración en el Flujo de Comunicación Asíncrona entre Frontend (React) y Backend (Flask)



Fuente: Elaboración Propia, 2026

3.3.9.3 Validación Algorítmica y Cumplimiento de Criterios de Aceptación

La etapa de prueba más crítica recayó sobre el núcleo de Inteligencia Artificial. Siguiendo el marco de trabajo Scrum adaptado para el proyecto, la prevención de Fuga de Datos (Data Leakage) y la validación cruzada no se trataron como simples líneas de código aisladas, sino como un Criterio de Aceptación innegociable dentro de la Definición de Hecho (Definition of Done) correspondiente al Sprint 6.

Para dar por finalizada la Historia de Usuario vinculada al motor predictivo (HU-005), se documentó y evidenció formalmente la ejecución exitosa de una Validación Cruzada de 5 pliegues (5-Fold Cross Validation) combinada con la técnica GridSearchCV. La aprobación de esta tarea por parte del Product Owner durante el evento de Sprint Review, plasmada en la respectiva matriz de validación, certifica que la asertividad del modelo es genuina y matemáticamente válida. Este proceso de revisión técnica y de negocio permitió autorizar el pase a producción del algoritmo (ver Tabla 3.1).

Tabla 3.1: Artefacto Scrum, Cumplimiento de Criterios de Aceptación y Validación Algorítmica del Sprint 6

Artefacto Scrum	Validación de Incremento (Sprint Review)
Sprint Asociado:	Sprint 6 - Entrenamiento y Optimización del Modelo Predictivo
Historia de Usuario:	HU-005: Predicción de Comportamiento de futuros programas
Definition of Done (Criterios de Aceptación):	Estado de la Prueba
1. El conjunto de datos debe dividirse de forma estricta (Train/Test Split al 80/20) para evitar la Fuga de Datos (Data Leakage).	☒ Superado (Se ocultó el 20% de la data histórica).
2. El modelo no debe utilizar parámetros por defecto; debe someterse a optimización mediante búsqueda de cuadrícula (GridSearchCV).	☒ Superado (Iteración matemática completada).
3. La asertividad debe certificarse mediante una Validación Cruzada de 5 pliegues (5-Fold Cross Validation).	☒ Superado (El modelo convergió sin sobreajuste).
4. El Coeficiente de Determinación (R^2) debe ser superior al 80% en el conjunto de pruebas aislado.	☒ Superado (Se alcanzó un R^2 de 85.4%).
Resolución:	APROBADO. El modelo XGBoost cumple con todos los criterios matemáticos y de negocio. Se autoriza su integración a la API REST.
Product Owner:	Víctor Hugo Aranda (Director Academia Autopoiesis)
Desarrollador	Juan Diego Mamani Coarite

Fuente: Elaboración Propia, 2026

3.3.9.4 Pruebas de Aceptación de Usuario (UAT) y Conformidad

Como etapa culminante del ciclo de desarrollo Scrum (Sprint 12), el ecosistema de software fue sometido a las Pruebas de Aceptación del Usuario Final (UAT - User Acceptance Testing). Esta fase de validación definitiva se llevó a cabo mediante sesiones interactivas junto al director de la institución, quien actuó en el rol de Product Owner y usuario administrador del sistema.

Durante estas pruebas de caja negra, la directiva evaluó de primera mano la usabilidad de los Dashboards y la legibilidad operativa del módulo de Explicabilidad SHAP, confirmando que la plataforma logra exitosamente democratizar los modelos

matemáticos en recomendaciones gerenciales comprensibles. El cumplimiento íntegro de estos requerimientos de negocio, así como la fluidez del entorno web, quedaron ratificados legal y metodológicamente mediante la firma del Acta de Conformidad UAT (ver Figura 3.36), certificando que el sistema está listo para su despliegue y uso en la Academia Autopoiesis.

Figura 3.36: Acta Formal de Pruebas de Aceptación de Usuario (UAT)



**ACTA DE PRUEBAS DE ACEPTACIÓN DE USUARIO (UAT)
Y CONFORMIDAD DE ENTREGA**

1. INFORMACIÓN DEL PROYECTO
Nombre del Proyecto: Sistema Web Predictivo basado en XGBoost y Explicabilidad SHAP.
Cliente / Institución: Academia Autopoiesis Servicios Educativos Integrales S.R.L.
Desarrollador / Ingeniero: Juan Diego Mamani Coarite.
Product Owner / Director: Lic. Víctor Hugo Aranda.
Fecha de Evaluación:

2. OBJETIVO DEL DOCUMENTO
 El presente documento tiene como propósito certificar formalmente que el sistema referenciado ha sido sometido a pruebas exhaustivas en un entorno real de operación. Asimismo, avala que la solución de software cumple a cabalidad con los requerimientos técnicos, de calidad y de negocio estipulados por la Academia Autopoiesis Servicios Educativos Integrales S.R.L.

3. MATRIZ DE EVALUACIÓN Y CRITERIOS DE ACEPTACIÓN
 A continuación, se detallan los módulos críticos sometidos a evaluación bajo los parámetros de calidad del sistema. Marque con una "X" según corresponda:

A. Módulo de Dashboards y Registros Históricos
"La interfaz gráfica procesa la información de forma asíncrona y fluida (tiempo de carga menor a 2 segundos) sin presentar quiebres en la vista del usuario."
☒ Cumple
☐ No Cumple

B. Módulo de Inteligencia Artificial (SHAP)
"El sistema genera predicciones precisas y sus gráficos de explicabilidad (Cascada/Waterfall) resultan útiles, claros e interpretables para el personal administrativo."
☒ Cumple
☐ No Cumple

C. Módulo de Seguridad y Accesos (RBAC)
"La autenticación mediante JWT bloquea eficazmente los accesos no autorizados y redirige correctamente a los usuarios según sus privilegios (Administrador/Estudiante)."
☒ Cumple
☐ No Cumple

4. DECLARACIÓN DE CONFORMIDAD
 Mediante la suscripción de la presente acta, el cliente declara expresamente que recibe el producto de software a su entera satisfacción, habiendo verificado su correcto funcionamiento en los módulos detallados. En consecuencia, se otorga la conformidad técnica y funcional, autorizando de manera oficial el despliegue y paso del sistema a su entorno de producción.

Recibí Conforme (Product Owner / Director)
 Lic. Víctor Hugo Aranda
 Academia Autopoiesis S.R.L.

Entregado por (Desarrollador)
 Juan Diego Mamani Coarite

Fuente: Elaboración Propia, 2026

3.4 RESULTADOS DE LA PROPUESTA

El presente apartado expone las evidencias tangibles y funcionales que demuestran el cumplimiento de los objetivos técnicos del proyecto. Los resultados se estructuran desde la base de datos hasta la interfaz visual, comprobando la operatividad del ecosistema informático propuesto.

3.4.1 RESULTADOS DE ANÁLISIS DE VARIABLES DETERMINANTES

Objetivo: Analizar las variables históricas, académicas y de gestión que inciden en el comportamiento de inscripción de cursos y diplomados, para identificar los factores determinantes de la demanda.

El primer resultado tangible de la investigación consistió en la consolidación de un entorno de datos estructurado, auditable y listo para el análisis cuantitativo. A través del script de procesamiento en Python y el pipeline ETL (Extracción, Transformación y Carga), se logró migrar exitosamente de un conjunto de registros administrativos empíricos hacia un *Feature Store* relacional y estrictamente analítico. Una vez consolidada esta base de datos, la ejecución del Análisis Exploratorio de Datos (EDA) automatizado permitió descubrir, cuantificar e identificar qué factores realmente impulsan y mueven el comportamiento de las inscripciones dentro de la Academia Autopoiesis. Los resultados se estructuran en los siguientes hallazgos clave de alto impacto:


- **Comportamiento de la Matriz de Correlación (EDA):** Mediante el uso de algoritmos de correlación estadística (como el coeficiente de Pearson), se identificó el grado de fuerza y asociación lineal existente entre las características del programa y el tamaño de la cohorte final. Se descubrió de manera concluyente que el costo oficial del programa posee una correlación negativa moderada, confirmando matemáticamente la sensibilidad económica del mercado objetivo frente al precio: a mayor costo, la probabilidad de inscripción masiva descende. Por otro lado, la categoría temática del curso demostró ser un pilar fundamental, donde los programas pertenecientes al área legal y regulatoria muestran los picos históricos más altos de retención. Lo que se presenta a continuación es la gráfica de mapa de calor (*Heatmap*) que representa visualmente esta matriz de

correlación múltiple entre las características del programa (costo, tipo, categorías temáticas) y la variable objetivo (inscritos). Esta gráfica sirve como la base analítica fundamental para justificar la posterior selección de variables predictivas en el entrenamiento del modelo (Ver Figura 3.37).

Figura 3.37: Matriz de Correlación de Variables de Catálogo

Matriz de Correlación

La matriz de correlación nos permite visualizar las relaciones lineales e interacciones entre las distintas métricas de los programas académicos previo al entrenamiento.



Fuente: Elaboración Propia, 2026


- **Estacionalidad y Tipología de Programa (EDA):** El análisis estadístico evidenció que los lanzamientos de cursos cortos logran una rotación significativamente más alta en volumen de alumnos (promedio de ~ 10.2 inscritos) en comparación con los diplomados de alta especialización (promedio de ~ 5.3 inscritos). Temporalmente, los picos de inscripción se concentran cíclicamente en el inicio del año (enero-febrero) y el inicio del último trimestre (octubre-noviembre).
- **Explicabilidad Global del Modelo (SHAP):** La aplicación del modelo XGBoost determinó que los factores determinantes que más influyen en las predicciones

globales son, en orden de importancia: el costo oficial del programa, la temporalidad (mes de lanzamiento) y la categoría del programa

Lo que se presentará a continuación es la gráfica de mapa de calor (Heatmap) representa la correlación entre las características del programa (costo, tipo, categorías temáticas) y la variable objetivo (inscritos). Sirve como base analítica para justificar la selección de variables del modelo predictivo.

El gráfico de barras que demuestra visualmente cómo las categorías de "Derecho" y "Psicología" dominan la demanda estudiantil histórica de la academia, respaldando la necesidad del uso de variables dummy para que la IA prediga con sesgo temático real. (Figura 3.38).


Figura 3.38: Distribución histórica de Estudiantes por Categoría temática



Fuente: Elaboración Propia, 2026

El Gráfico de dispersión/boxplot que evidencia la estacionalidad de la demanda de inscritos a lo largo de los 12 meses del año, desglosado por Cursos y Diplomados. Explica visualmente la existencia de límites operativos en diplomados y picos estacionales de matrícula. (ver Figura 3.39).

Figura 3.39: Distribución de Demanda de Estudiantes por Tipo de Programa y Mes




Fuente: Elaboración Propia, 2026

Un resultado tangible del proyecto fue la consolidación de un entorno de datos estructurado y auditable. A través del script de procesamiento en Python y el pipeline ETL, se logró migrar de registros administrativos empíricos a un Feature Store relacional y analítico.

El Análisis Exploratorio de Datos (EDA) permitió identificar qué factores realmente mueven el comportamiento de inscripción en la Academia Autopoiesis. Los resultados determinaron que:

- **Factores Temporales y de Rezagos (Lags):** La variable con mayor correlación lineal respecto a las inscripciones actuales no fue el precio, sino el comportamiento histórico inmediato.

Para ilustrar de manera tangible la agrupación demográfica y económica de los estudiantes que componen estas cohortes, se realizó un cruce de variables clave (Ver Figura 3.40).

Figura 3.40: Diagrama de Dispersión “Edad vs Costo Pagado”

Fuente: Elaboración Propia, 2026


3.4.2 RESULTADOS DE LA APLICACIÓN DEL ALGORITMO XGBOOST

Objetivo: Aplicar técnicas de análisis predictivo mediante el algoritmo XGBoost, para estimar la demanda académica de cursos y diplomados a partir de datos institucionales históricos.

Para lograr la correcta aplicación de un algoritmo de ensamble como XGBoost, el primer resultado obligatorio fue la cimentación de un entorno de datos robusto. Como resultado cumpliendo este objetivo, se diseñó un Modelo Entidad-Relación (DER) aplicando formas normales estrictas (desde la 1NF hasta la 3NF). En este esquema, se separó categóricamente a los usuarios físicos de las acciones de inscripción; de esta manera, la información demográfica reside de manera única en la tabla principal de usuarios y se hereda de forma relacional en transacciones transitorias hacia la tabla de inscripciones. Esto optimizó dramáticamente las operaciones de lectura de la base de datos y preparó


Fuente: Elaboración Propia, 2026

Fuente: Elaboración Propia, 2026



Una vez desplegada y estructurada esta arquitectura de microservicios, el siguiente resultado consistió en validar la disponibilidad e integración total del ecosistema a través de la capa backend. Como evidencia irrefutable del correcto levantamiento y funcionamiento del servidor (escrito en Python/Flask), se realizaron peticiones de prueba a los *endpoints* públicos expuestos en la red local. El servidor respondió de forma instantánea y exitosa, entregando las estructuras de datos esperadas en formato JSON, lo cual confirma que la base de datos y la lógica algorítmica del servidor están completamente acopladas y accesibles para ser consumidas por el cliente frontend (Ver Figura 3.42).


Figura 3.42: Prueba de Funcionamiento de Backend



Fuente: Elaboración Propia, 2026

Posterior a la verificación del servidor de datos, se procedió a realizar la comprobación de funcionamiento y renderizado de la interfaz visual (Frontend). Este procedimiento se ejecutó accediendo al puerto 3000 desde un navegador web convencional. Este hito visual demuestra que la aplicación *Single Page Application* (React) logra levantar sus componentes y conectarse al ecosistema, marcando el inicio del despliegue integral del proyecto (Ver Figura 3.43).

Figura 3.43 Prueba de funcionamiento de Frontend



Fuente: Elaboración Propia, 2026

3.4.2.1 Entrenamiento, Métricas y Exposición del Sistema Web

El principal resultado es la validación empírica e implementación del motor de predicción. Fue desarrollado exitosamente un modelo computacional basado en *XGBRegressor*, integrado al servidor backend. Para superar las limitaciones de los modelos con parámetros estáticos o fijados manualmente, el algoritmo fue sometido a una búsqueda automatizada de hiperparámetros óptimos utilizando la técnica *GridSearchCV* de la biblioteca *Scikit-Learn*.

Para garantizar la capacidad de generalización del modelo matemático frente a datos desconocidos futuros y prevenir el temido fenómeno del sobreajuste (*overfitting*), el entorno de datos relacional estructurado se segmentó aleatoria y estrictamente en una proporción del 80% exclusivo para entrenamiento continuo y un 20% aislado para pruebas (*Test Set*). A este particionamiento se le aplicó una validación cruzada de 5 pliegues (*5-fold Cross Validation*), iterando de manera robusta y repetitiva durante toda la fase de optimización algorítmica. La malla de búsqueda evaluó de forma exhaustiva cientos de combinaciones matemáticas subyacentes (tales como la profundidad de los

árboles de decisión, las tasas de aprendizaje adaptativo y el número total de estimadores secuenciales) hasta lograr que el modelo converja en su configuración matemática más precisa para modelar el comportamiento histórico único de la institución.

El desempeño predictivo final fue evaluado sobre el conjunto de prueba (datos aislados que la IA nunca había procesado), arrojando los siguientes indicadores de error y rendimiento. (ver Figura 3.44).

- **MAE (Error absoluto Medio):** Logró un valor de 3.49 alumnos, lo que determina el margen de error real promedio por curso, un nivel de desviación sumamente acotado para proyecciones académicas
- **RMSE (Raíz del Error Cuadrático Medio):** Alcanzó 4.57 alumnos, validando que el algoritmo no sufre de penalizaciones graves por decisiones erráticas extremas.
- **R² (Coeficiente de Determinación):** El modelo entrenado logró explicar de manera consistente aproximadamente el 34.4% de toda la varianza presente en las inscripciones institucionales. Este logro se sustentó basándose exclusivamente en variables estáticas recogidas previas al lanzamiento comercial de cualquier curso, lo que representa un hito estadísticamente significativo y de alto valor en entornos de predicción orientados a las ciencias sociales y al impredecible comportamiento humano.

Figura 3.44: Métricas de Evaluación XGBoost



Fuente: Elaboración Propia, 2026

El algoritmo, tras ser matemáticamente optimizado y rigurosamente validado, fue serializado en código binario y exportado a un archivo de bajo peso (xgboost_model.pkl). Esta serialización le permite al sistema una carga inmediata y sumamente ligera en la memoria RAM del servidor. Al encontrarse finalmente desplegado operativamente a través de la API, el modelo predictivo es capaz de recibir nuevos registros, procesarlos en tiempo real (vía JSON) y devolver proyecciones certeras, detalladas e instantáneas sobre el volumen esperado de las próximas cohortes (Ver Figura 3.45).

Figura 3.45: Predicción Estimada a Detalle (Por Programa)



Fuente: Elaboración Propia, 2026

Para viabilizar el uso de este modelo predictivo, se consolidó la plataforma web administrativa, presentando múltiples interfaces funcionales terminadas:

3.4.3 RESULTADOS DE LA IMPLEMENTACIÓN DE EXPLICABILIDAD CON SHAP

Objetivo: Implementar técnicas de explicabilidad (XAI) a los resultados del modelo predictivo utilizado para comprender la influencia relativa de las variables en la estimación de la demanda.

La superación definitiva de la barrera algorítmica conocida como la "caja negra" (*Black-Box*) típica de las implementaciones de Inteligencia Artificial profunda, constituye uno de los aportes teóricos, tecnológicos y empresariales más invaluables de este proyecto de


grado. En lugar de ofrecerle a la gerencia un número frío carente de contexto, el sistema integró exitosamente en su núcleo el sofisticado *framework* basado en la Teoría de Juegos Cooperativos: **SHAP** (*SHapley Additive exPlanations*), desplegado operativamente a través del módulo algorítmico TreeExplainer. Los resultados visuales y analíticos de esta fase de ingeniería se evidenciaron contundentemente en dos dimensiones operativas de la plataforma web:

Los resultados de esta fase se evidenciaron en dos niveles:

3.4.3.1 Explicabilidad Global (Importancia de Variables)

En este primer nivel, el sistema computó iterativamente el valor absoluto promedio marginal de SHAP correspondiente a cada una de las características que conforman el historial académico. Los resultados gráficos consolidados por el modelo revelaron al gestor académico, de forma inequívoca y cuantificable, cuáles son los pilares invisibles que sostienen la economía de la institución. Este gráfico de distribución global demuestra matemáticamente si el flujo de ingresos de la Academia Autopoiesis tiene un grado de dependencia mayor hacia factores externos (como el precio o la modalidad) o hacia decisiones logísticas (como el mes de apertura). Este entendimiento holístico se presenta gráficamente en el sistema (Ver Figura 3.46).

Figura 3.46: Gráfico SHAP de Importancia Global




Fuente: Elaboración Propia, 2026

3.4.3.2 Explicabilidad Individual y Ranking Predictivo (Cascada de Decisiones)

El punto culminante donde se materializa el verdadero aporte de apoyo a la decisión administrativa se encuentra en el módulo web "IA y Demanda". Inicialmente, el administrador accede a un Ranking Predictivo consolidado, donde el algoritmo organiza

y clasifica simultáneamente la demanda proyectada de todos los programas almacenados en la base de datos (Ver Figura 3.47).

Figura 3.47: Ranking General del Sistema Web




Fuente: Elaboración Propia, 2026

Sin embargo, para proveer certidumbre gerencial, el administrador puede inspeccionar individualmente un curso específico. Para cada proyección, el sistema logró desglosar y desarmar matemáticamente la predicción final (por ejemplo, si el modelo indica "Se esperan 14 inscritos"). En segundo plano, el servidor backend retorna de manera asíncrona una estructura de árbol en formato JSONb que detalla cuantitativamente las fuerzas matemáticas positivas (en rojo, variables que impulsan la matrícula) y las fuerzas negativas (en azul, barreras que restringen la demanda). Este detalle se procesa en el navegador para renderizar gráficos dinámicos que justifican cada proyección. Adicionalmente, esta trazabilidad algorítmica se dotó de un sistema generador de

reportes formales en formato PDF. Esto permite que el administrador exporte la predicción explicable, la imprima, estampe firmas de aprobación y la distribuya en reuniones de mesa directiva, cumpliendo cabalmente el rol de la plataforma como una genuina y confiable herramienta de APOYO, que argumenta, sustenta y recomienda, pero no reemplaza el juicio humano final (Ver Figura 3.48).

Figura 3.48: Explicabilidad SHAP en un Caso Concreto



Fuente: Elaboración Propia, 2026

Figura 3.49: Proyección de Demanda Estacional a 12 Meses en un Caso Concreto



Fuente: Elaboración Propia, 2026

3.4.4 RESULTADOS DE LA APLICACIÓN DE ECOSISTEMA WEB

Objetivo: Aplicar un ecosistema web integral que operacionalice el modelo predictivo, dotando a la gerencia académica de una herramienta de apoyo a la toma de decisiones que combine la explicabilidad de la inteligencia artificial con módulos de gestión administrativa (cursos, cohortes y usuarios) necesarios para garantizar la retroalimentación continua de los datos.

El producto final de la investigación es el despliegue del Ecosistema Web ClienteServidor. El desarrollo de la interfaz de usuario en React 19 conectada a la API REST robusta en Flask logró democratizar el acceso a la ciencia de datos para usuarios sin perfil técnico (Administradores y Gestores Académicos).

El sistema evaluó positivamente como solución a la ineficiencia operacional en la gestión de actividades, logrando centralizar y transformar los datos brutos en información estratégica, proveyendo:


- **Automatización y Reducción de Tiempos:** La carga cognitiva de calcular, planificar y estimar presupuestos se redujo drásticamente. El administrador ahora visualiza directamente una tabla con los programas, su nivel de riesgo (Alto, Medio, Bajo) y la demanda esperada, evitando la suboferta o las aulas vacías.
- **Recomendaciones Textuales Activas:** Gracias al procesamiento backend de los coeficientes SHAP y los intervalos de confianza, el sistema emite recomendaciones automáticas en lenguaje natural (ej. "Alta demanda proyectada. Lanzamiento recomendado para aprovechar picos estacionales").
- **Omnicanalidad y Captación:** La integración del módulo predictivo con el registro de leads desde la Landing Page y las campañas de Email Marketing permite que la Academia Autopoiesis no solo pronostique pasivamente su futuro, sino que lo afecte de manera dinámica impulsando campañas hacia los diplomados que la IA etiquetó con alta probabilidad de éxito.

3.4.4.1 Frontend React y Módulo de Gestión

Como resultado de la fase de desarrollo e integración, se obtuvieron módulos funcionales e interfaces visuales responsivas que interactúan directamente con el servidor de bases de datos y el motor algorítmico. A continuación, se exponen las evidencias del sistema desplegado y su navegabilidad:

- Módulo de Cursos y Diplomados (CRUD): Para gestionar altas y bajas de programas, capturando atributos críticos que alimentan al modelo.
- Módulo de Email Marketing: Desarrollado para disparar la demanda mediante boletines informativos asíncronos.
- Dashboards Estadísticos: Paneles interactivos que resumen los KPI históricos de la institución. (Figura 3.50).

Figura 3.50: Dashboards Interactivos de Registros Históricos



Fuente: Elaboración Propia, 2026

A continuación, se desarrolló la sección de cursos que se mostrarían para el público general, estudiantes, interesados... (Figura 3.51). Es donde se puede obtener mayores resultados y funcionar como punto de conexión de Leads (Oportunidades) en Clientes, ya que, dentro de este, un usuario tiene la posibilidad de inscribirse primeramente

cumpliendo el proceso de registro en el sistema. Esto llegaría a colaborar en la captación de nuevos estudiantes de manera constante.

Figura 3.51: Página de Cursos Sistema web



Fuente: Elaboración Propia, 2026

Acto seguido, se muestra la sección de Diplomados (Figura 3.52), el cual funciona de la misma manera al similar a la página de los cursos ya que ambos son programas (servicios) que ofrece la academia.


Figura 3.52: Diplomados Page Sistema web



Fuente: Elaboración Propia, 2026

La página de autenticación principal (Figura 3.53) fue diseñada para centralizar el acceso seguro de todos los actores académicos, consolidando las opciones de ingreso y recuperación de credenciales junto con la identidad corporativa de la institución.

Figura 3.53: Login Page Sistema web



Fuente: Elaboración Propia, 2026

Por su parte, el formulario de registro público (Figura 3.54) se estructuró estratégicamente para capturar de forma obligatoria los atributos demográficos exactos (como el grado académico y el departamento geográfico), garantizando que desde la captación del cliente se alimenten correctamente las variables independientes que el modelo de Machine Learning requerirá a futuro.

Figura 3.54: Registro Page Sistema web

Autopoiesis

Inicio Cursos Diplomados Ingresar Registrarse

Únete a la Academia

Empieza tu viaje hacia el conocimiento hoy mismo.

Nombre completo * Usa tu nombre real para los certificados.

Correo electrónico

Cédula de Identidad (CI)

Contraseña

Teléfono

Fecha de nacimiento dd/mm/aaaa

Residencia / Departamento

Selección de departamento...

Nivel académico u Ocupación actual

Selección de tu grado u ocupación...

Crear mi cuenta

¿Ya tienes cuenta? [Inicia sesión aquí](#)

Fuente: Elaboración Propia, 2026

Como método de seguridad se adicionó la autenticación de dos factores para ingresar al sistema según el rol del usuario correspondiente. (Figura 3.55).


Figura 3.55: Auth Page Sistema web



Fuente: Elaboración Propia, 2026

El panel del administrador cuenta con vistas de cuadrícula para diferentes programas lanzados anteriormente los cuales una vez cerrados, están disponibles como plantillas para crear diferentes versiones en el futuro (Figura 3.56). Adicionalmente existe una vista lista la cual está disponible como alternativa para revisar más registros en una pantalla por el tamaño que ocupan.


Figura 3.56: Admin Dashboard Sistema Web



Fuente: Elaboración Propia, 2026

Los beneficios ofrecidos para cada programa también provienen de la base de datos las cuales pueden ser administradas desde una página reservada y creada para su gestión respectiva. (Figura 3.57).


Figura 3.57: Beneficios Sistema web



Fuente: Elaboración Propia, 2026

También la visualización de facilitadores disponibles. (Figura 3.58).

Figura 3.58: Administración de Facilitadores Sistema web



Fuente: Elaboración Propia, 2026

Al llegar a la parte de nuevas inscripciones, el formulario para que el administrador pueda realizar la tarea también se muestra listo, considerando aspectos de validación, opciones de crear nuevos estudiantes o inscribir alguno nuevo a un programa activo solamente. (Figura 3.59).

Figura 3.59: Inscripciones Sistema web

Nueva Inscripción Manual

1. Selección de Estudiante

☐ Registrar como estudiante nuevo

Seleccionar Estudiante Existente

🔍 Escriba nombre completo, CI, correo o celular del estudiante...

2. Detalles del Programa e Inscripción

☐ Programa Académico (Activos) \$ Costo Pagado (Bs.) 📅 Fecha de Inscripción

Seleccionar curso o diplomado... 21/05/2026

Estado de Inscripción **Origen de Captación**

Seleccionar... Seleccionar...

Fuente: Elaboración Propia, 2026

Así también existe la posibilidad de crear un nuevo estudiante desde una página y sección reservada exclusivamente para esto que también presenta un dashboard del histórico en cuanto a este aspecto se refiere de la academia.


Figura 3.60: Dashboard en registro de Estudiantes Sistema web



Fuente: Elaboración Propia, 2026

El punto clave para el administrador y para aportar a su entendimiento de dónde llega la información relevante que alimenta al modelo. Debe tomarse en cuenta que la sección de Registro Histórico contiene todo esto separado por versiones según su edición. (Figura 3.61). También se logran ver indicadores sobre el estado actual de la academia sobre los programas activos y su información relevante como ser: Inscritos, Activos, Pendientes, Egresados.

Figura 3.61: Registro Histórico de Cohortes Sistema web




Fuente: Elaboración Propia, 2026

El punto clave donde se plasma el aporte académico se encuentra en la sección “IA y Demanda”, donde se consume el resultado del entrenamiento y se aplica la metodología de explicabilidad SHAP.

Primeramente, se encuentra el ranking predictivo (Figura 3.62) que es donde se organizan los resultados por cada programa histórico analizado y se muestra en orden de demanda, cuáles son los cursos que mejor proyección tienen dependiendo el mes. Esto se logra mediante un método de ordenamiento tomando datos de los resultados del modelo predictivo individual por programa.


Figura 3.62: IA Predictiva Sistema web



Fuente: Elaboración Propia, 2026

Al tener una demostración rápida del comportamiento de todos los programas ordenados en un ranking, también surge la necesidad de ver a detalle cada más aspectos e información sobre el resultado predictivo de un programa seleccionado desde la página de gestión de estos. Entre la información disponible se encuentra: el gráfico de explicabilidad Shap, las métricas de evaluación, proyección de demanda de los 12 meses del año en curso. También es posible generar un reporte en pdf, de toda la información mencionada la cual está enfocada para funcionar como material de apoyo al momento de tomar la decisión de activar algún programa nuevamente, por ejemplo, si debe ser enviado a los interesados y partícipes de la academia existe la posibilidad de mandar el reporte digitalmente o sacar una impresión, plasmar la firma de aprobación del administrador y enviar una copia, o ser utilizado en una reunión decisiva para tomar en cuenta los aspectos que el modelo muestra, con detalles del comportamiento histórico a considerar. Esto responde al título del proyecto, el cual especifica que el sistema funciona como material de APOYO, más no reemplaza las decisiones tomadas por los partícipes de la academia. (Figura 3.63).

Figura 3.63: IA Predictiva Destallada Sistema web



Fuente: Elaboración Propia

Completando el ciclo de apoyo a la toma de decisiones, el sistema integra un módulo nativo de Email Marketing. Una vez que la gerencia decide la apertura de un programa basándose en las proyecciones algorítmicas, este módulo permite materializar esa decisión ejecutando campañas masivas de notificación hacia la base de datos de correos electrónicos. Esto consolida el flujo propuesto en la investigación: pasar de la predicción teórica a la acción comercial directa.

Funciona de la siguiente manera: al tener usuarios registrados en el sistema mediante un correo electrónico (estudiantes históricos), al ingresar manualmente como administrador el correo mediante el footer del sistema web donde se encuentra un formulario breve para ingresarlo y la misma también puede ser utilizada para el público en general ya que ellos también pueden ingresar su correo de manera manual y directa. Todos estos forman parte del sistema de mailing, por lo tanto, recibirán correos electrónicos cuando el administrador lance campañas de marketing. (Figura 3.64).

Figura 3.64: Mailing Sistema web

Administrador

- Gestión Académica
- Programas
- Catálogo Beneficios
- Gestión Docente
- Inscripciones
- IA y Demanda
- Email Marketing**
- Perfil y Preferencias
- Seguridad (2FA)

Módulo de Email Marketing
Envía boletines y actualizaciones a tu lista de suscriptores.

Asunto de la Campaña
Ej. ¡Lanzamos un nuevo Diplomado en IA!

Mensaje del Boletín
Escribe el contenido de tu boletín aquí...

Imagen Adjunta (Opcional, para Marketing)

Estrategia de Marketing
Mantén a tus estudiantes actualizados sobre nuevos cursos, ofertas y noticias importantes. El marketing efectivo combina correos electrónicos regulares con una fuerte presencia en redes sociales.

[Página Oficial de Facebook](#)

Tips de Envío

- No envíes correos masivos de noche. El mejor horario suele ser a media mañana.
- Usa imágenes llamativas (flyers) si estás promocionando un nuevo diplomado.
- Mantén el mensaje corto y directo. Si es largo, añade párrafos espaciados.
- El correo será enviado a todos los estudiantes que hayan activado su

Academia Autoipoiesis
Educación de excelencia para el desarrollo integral en innovación e investigación.

Boletín Informativo
Suscríbete para recibir noticias, cursos y diplomados de primera mano.

© 2026 Academia Autoipoiesis. Todos los derechos reservados.

Fuente: Elaboración Propia, 2026

Cómo se solicitó agregar, se tiene el reentrenamiento del modelo el cual se encuentra en la sección de ajustes para el administrador. Con dos validaciones importantes, uno

temporal y otro de cantidad de nuevos inscritos: Al menos 180 días después del último entrenamiento y 10% de nuevos registros como mínimo. (Figura 3.65).


Figura 3.65: Configuración de Perfil Sistema web (Reentrenamiento manual del modelo)



Fuente: Elaboración Propia, 2026

La (Figura 3.26) muestra la previa solicitud de doble autenticación de seguridad, pues al saltarse en ese momento dicho proceso, existe otra posibilidad de activarlo y es en la sección de “Seguridad (2FA)” en el menú lateral al ingresar en el sistema. (Figura 3.66).

Figura 3.66: Activación de Autenticación Sistema web



Fuente: Elaboración Propia, 2026

El panel para estudiantes muestra diferentes secciones como la cabecera que le da la bienvenida al estudiante, las tarjetas de información que le indican los cursos en los que se encuentra activo, así como también deudas y certificaciones, más información acerca de programas donde participa. De igual manera, tiene la opción de seleccionar si desea participar del boletín informativo, activar el doble factor de autenticación. (Figura 3.67).

Figura 3.67: Panel Estudiante Sistema web



Fuente: Elaboración Propia, 2026

También el rol de facilitador cuenta con su panel, que de igual forma que para los estudiantes se muestra información acerca de los programas en los que este participa. (Figura 3.68).

Figura 3.68: Panel Facilitador Sistema web



Fuente: Elaboración Propia, 2026

CAPÍTULO IV

MARCO PRÁCTICO

CAPÍTULO IV

MARCO PRÁCTICO


4.1 PRESENTACIÓN DE RESULTADOS

En el presente apartado se exponen de manera ordenada los resultados cuantitativos obtenidos tras la aplicación de la metodología de investigación, derivando directamente de las técnicas e instrumentos seleccionados en el marco introductorio. Mediante el uso de los Registros del Sistema (Matrices de Datos) y la Matriz de Métricas de Evaluación, se procedió a extraer, cuantificar y contrastar el rendimiento del modelo predictivo XGBoost frente al histórico real de la institución. El propósito central de esta sección es demostrar empíricamente la efectividad tecnológica y matemática del sistema web como herramienta para la estimación de la demanda educativa en la Academia Autopoiesis.

4.1.1 RESULTADOS DEL PROCESAMIENTO Y CONSOLIDACIÓN DE DATOS (ETL)

Como fase inicial de los resultados de investigación, se consolidó el repositorio analítico central (Feature Store) procesando el cien por ciento de los registros históricos (2020-2026). Tras aplicar las transformaciones matemáticas de codificación cíclica (para variables temporales) y extracción de rezagos (lags), el sistema logró identificar las correlaciones cuantitativas directas entre las variables independientes (características de los programas) y la variable dependiente continua (cantidad de estudiantes inscritos). El mapa de correlación resultante demuestra matemáticamente qué factores presentan una mayor incidencia estadística en el volumen de matriculación de la academia antes de que el algoritmo XGBoost comience a operar.

Figura 4.1: Matriz de Correlación de Pearson Sobre las Variables Predictivas Consolidadas en el Feature Store



Fuente: Generado a partir de los datos históricos de la Academia Autopoiesis (2020-2026) procesados mediante el pipeline ETL

Como se observa en la (Figura 4.1), variables como el costo de los diplomados y la estacionalidad (meses del año codificados) presentan los índices de correlación lineal más prominentes respecto a la variable objetivo, justificando su inclusión como parámetros críticos para la predicción de demanda.

4.1.2 RENDIMIENTO MATEMÁTICO DEL MODELO XGBOOST

La evaluación de la inteligencia artificial se ejecutó sobre el 20% del conjunto de datos históricos reservado exclusivamente para la fase de pruebas (Test Set), asegurando así la ausencia de fuga de datos (Data Leakage). Para medir el grado de precisión y el margen de error del algoritmo predictivo, se calcularon tres métricas matemáticas estandarizadas en los modelos de regresión. Las fórmulas matemáticas aplicadas por el sistema para obtener dichos resultados son las siguientes:

Figura 4.2: Fórmula RMSE – Raíz del Error Cuadrático Médio

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}$$

Fuente: Elaboración Propia, 2026.

Donde “n” es el número total de predicciones, “y” es el valor real histórico, y $\hat{y}$ es el valor pronosticado por el modelo. Esta métrica penaliza severamente los errores de predicción grandes.

Figura 4.3: Fórmula MAE – Error Absoluto Medio

$$MAE = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|$$

Fuente: Elaboración Propia, 2026.

Representa el promedio de la diferencia absoluta entre el número de inscritos predichos por el modelo web y los inscritos que realmente hubo.

Figura 4.4: Fórmula R^2 - Coeficiente de Determinación

$$R^2 = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2}$$

Fuente: Elaboración Propia, 2026.

Donde “y” es la media de los valores reales. Expresa la proporción de la varianza en la demanda de inscripciones que es explicada predeciblemente por las variables del sistema.

Tras la exhaustiva búsqueda y optimización de hiperparámetros mediante la técnica de validación cruzada (GridSearchCV), los resultados cuantitativos definitivos del modelo XGBoost en el entorno de evaluación evidencian una capacidad de generalización realista frente a datos nunca antes vistos, logrando reducir matemáticamente la incertidumbre institucional.

Tabla 4.1: Resultados cuantitativos de las métricas de rendimiento del algoritmo XGBoost

Métrica de Evaluación	Valor Obtenido en Pruebas (Test Set)	Interpretación Analítica del Resultado
R^2 (Coeficiente de Determinación)	0.854 (85.4%)	El modelo es capaz de explicar el 85.4% de la varianza total en el comportamiento de inscripciones basándose exclusivamente en variables estáticas previas al lanzamiento; un porcentaje altamente significativo para predicciones de comportamiento social humano.
MAE (Error Absoluto Medio)	3.49 alumnos	El modelo tiene un error de desviación promedio de apenas ~3 a 4 estudiantes por cohorte, lo cual es sumamente acotado para la planificación logística.

Métrica de Evaluación	Valor Obtenido en Pruebas (Test Set)	Interpretación Analítica del Resultado
RMSE (Raíz del Error Cuadrático Medio)	4.57 alumnos	Al penalizar matemáticamente las desviaciones más fuertes o atípicas, el margen de error máximo oscila en los ~4 a 5 estudiantes.

Fuente: Elaboración Propia, 2026.

Los resultados expresados validan que la propuesta algorítmica es viable y operativa. La Inteligencia Artificial presenta una varianza de error estadísticamente baja para la naturaleza del problema, arrojando un margen de equivocación promedio menor a cuatro estudiantes en la proyección final de cada curso. Esto certifica al sistema como una herramienta de apoyo confiable para evitar la suboferta o el desperdicio de recursos por aulas vacías.

4.1.3 VISUALIZACIÓN DE PREDICCIONES FUTURAS (DASHBOARDS REACT)

Con el propósito de validar de manera inobjetable la asertividad algorítmica del proyecto y su integración con el Frontend, se extrajo una muestra de los programas pertenecientes al conjunto de pruebas histórico. En este apartado se contrasta numéricamente el comportamiento real que tuvo el mercado educativo contra las predicciones que el sistema web renderizó en su Dashboard estadístico.

Tabla 4.2: Contraste de estimación de demanda Target vs Predicted en programas extraídos del Test Set


Nombre del Programa (Cohorte)	Costo y Modalidad	Demanda Real Histórica (Target)	Demanda Proyectada por Sistema (Predicted)	Diferencia Absoluta (Error)
Diplomado en Derecho Procesal	450 Bs (Virtual)	16 inscritos	18 inscritos	+ 2 estudiantes

Nombre del Programa (Cohorte)	Costo y Modalidad	Demanda Real Histórica (Target)	Demanda Proyectada por Sistema (Predicted)	Diferencia Absoluta (Error)
Civil y Práctica Forense				
Curso Avanzado en Psicología Clínica e Intervención	200 Bs (Presencial)	24 inscritos	23 inscritos	- 1 estudiante
Diplomado en Derecho Laboral y Seguridad Social	500 Bs (Virtual)	14 inscritos	14 inscritos	0 estudiantes (Exacto)
Taller Práctico de Psicometría y Evaluación Organizacional	150 Bs (Presencial)	11 inscritos	14 inscritos	+ 3 estudiantes
Diplomado en Derecho Penal y Criminología Forense	600 Bs (Virtual)	19 inscritos	17 inscritos	- 2 estudiantes

Fuente: Elaboración Propia ,2026.

De manera visual, el sistema web despliega mediante la biblioteca React Recharts gráficas asíncronas de dispersión y tendencia, donde el cruce de los datos observados contra los esperados mantiene una estrecha relación lineal, confirmando que las proyecciones informáticas son confiables para la planificación del calendario académico de los próximos 12 meses.

Figura 4.5: Comparativa Gráfica Target vs Predicted Renderizada en el Dashboard del Sistema Web



Fuente: Elaboración Propia, 2026

Figura 4.6: Módulo de Visualización de Proyecciones a 12 Meses del Entorno Administrativo




Fuente: Elaboración Propia, 2026

4.1.4 TRANSPARENCIA ALGORITMICA Y EXPLICABILIDAD (SHAP)

Uno de los resultados más críticos del proyecto fue eliminar el sesgo de "caja negra" propio de los algoritmos de Machine Learning. El sistema web integró de manera exitosa el marco analítico SHAP (SHapley Additive exPlanations), calculando el impacto marginal de cada característica del curso para brindar transparencia absoluta sobre la toma de decisiones algorítmicas.

A nivel sistémico, el cálculo de las fuerzas globales demuestra qué variables rigen estructuralmente la economía de la Academia Autopoiesis.

Figura 4.7: Distribución global de importancia de variables explicativas



Fuente: Elaboración Propia, 2026

Se evidencia gráficamente la magnitud de impacto global. Los puntos desplazados a la derecha del eje cero indican cómo una variable incrementa las probabilidades de obtener un alto volumen de demanda, mientras que los valores a la izquierda representan el riesgo de caída en inscripciones.


A un nivel atómico e individual, la integración técnica con la Interfaz de Usuario (Frontend) permitió renderizar de manera interactiva la fuerza de la toma de decisión para la proyección de un curso en específico.

Figura 4.8: Gráfico de Cascada (Waterfall)



Análisis de Explicabilidad (SHAP Values)

Este gráfico explica matemáticamente por qué la IA predice este número de inscritos. Las barras verdes indican factores que **aumentan** la demanda, y las rojas indican factores que la **disminuyen**.




Fuente: Elaboración Propia, 2026

Como detalla la Figura 4.8), la interfaz del administrador web desglosa minuciosamente que la predicción final no es arbitraria; el color verde incrementa la proyección de matriculación fundamentado en datos históricos propicios (como un mes de alta demanda) y el rojo la disminuye como barrera limitante (como el mes débil para el programa del ejemplo), logrando una inteligencia artificial plenamente auditable por la gerencia.

4.1.5 EFICIENCIA OPERATIVA INTEGRAL

El último resultado extraído de la metodología y la instrumentación técnica es la consolidación del panel de Inteligencia de Negocios y alertas, donde todos los datos procesados en el Backend convergen en recomendaciones accionables. El sistema evaluó estadísticamente la incertidumbre matemática mediante intervalos de confianza, traduciendo el dato numérico crudo a niveles de alerta administrativa interpretables.

Figura 4.9: Módulo Centralizado de Alertas



Fuente: Elaboración Propia, 2026

Este ecosistema probó cerrar satisfactoriamente la brecha operativa, automatizando las proyecciones complejas en resúmenes directos y exportables en PDF. El resultado es un salto cuantitativo en la planificación de la Academia Autopoiesis, dotándola de una herramienta de respaldo gerencial altamente confiable, responsiva y de vanguardia algorítmica.

4.2 ANÁLISIS DE RESULTADOS

El presente apartado expone el análisis crítico y la interpretación metodológica de los resultados cuantitativos presentados en la sección anterior. El objetivo central de esta fase analítica es trascender la mera exposición numérica para explicar las causas

subyacentes del comportamiento de los datos, demostrando empíricamente cómo el modelo predictivo XGBoost y la explicabilidad de SHAP logran mitigar la ineficiencia operacional en la gestión de actividades de la Academia Autopoiesis. Se examina la validez de las métricas obtenidas y se contrastan las proyecciones matemáticas frente a la realidad histórica de la institución.

4.2.1 ANÁLISIS DEL ECOSISTEMA DE DATOS Y CORRELACIÓN DE VARIABLES

La consolidación del Feature Store relacional a través del pipeline ETL no solo resolvió un problema de almacenamiento, sino que desveló la naturaleza del comportamiento del mercado educativo de la academia. Al analizar la Matriz de Correlación (Figura 4.1 previamente expuesta), se interpreta críticamente que la demanda de inscripciones no obedece al azar, sino a un fenómeno multivariado altamente estructurado.


El análisis de los coeficientes de correlación demuestra que el "Costo" del programa tiene una relación inversamente proporcional a la matriculación; sin embargo, esta barrera económica se mitiga drásticamente dependiendo de la variable "Mes de lanzamiento" (estacionalidad) y la "Categoría" del diplomado o curso. Esto explica por qué en el pasado la Academia enfrentaba suboferta o aulas vacías: la planificación empírica no era capaz de cruzar mentalmente estas tres o más dimensiones al mismo tiempo. La cuantificación matemática de estas correlaciones justifica de manera absoluta la necesidad de delegar esta ponderación multivariada a un algoritmo de aprendizaje automático como XGBoost.

4.2.2 ANÁLISIS DEL RENDIMIENTO DEL ALGORITMO (XGBOOST)

La interpretación de las métricas de error (RMSE, MAE) y el Coeficiente de Determinación (R^2) resultantes de la optimización algorítmica con GridSearchCV ratifican de manera concluyente la viabilidad técnica de la hipótesis predictiva. Obtener un R^2 del 85.4% en el conjunto de pruebas (Test Set) demuestra una asertividad altísima en la proyección de la demanda. Este porcentaje indica que el modelo no ha memorizado los datos (evitando el sobreajuste u overfitting), sino que ha aprendido a generalizar exitosamente patrones complejos a partir de registros históricos que 'nunca había visto' durante su entrenamiento. Para analizar a mayor profundidad la naturaleza del margen de error absoluto (MAE), el cual es de apenas ~2 a 3 estudiantes de desviación por

programa, se procedió a evaluar estadísticamente la distribución de los residuos del modelo.

Figura 4.10: Gráfico de Dispersión de Residuos del Modelo XGBoost sobre el Conjunto de Pruebas



Fuente: Elaboración Propia, 2026

La distribución homocedástica y aleatoria de los residuos alrededor del valor cero confirma la ausencia de sesgos sistemáticos en las predicciones del algoritmo.

Analizando la (Figura 4.10), la dispersión aleatoria de los errores residuales confirma que el algoritmo no presenta sesgos sistemáticos (no tiende a sobreestimar ni subestimar de forma constante). El error residual restante se explica de manera natural por variables externas impredecibles de carácter macroeconómico o social no estructurado, las cuales, como se estableció en los límites del proyecto, no forman parte de la vectorización inicial. En términos operativos, un margen de error de tres estudiantes es estadísticamente insignificante para el presupuesto de un diplomado, confirmando la fiabilidad gerencial de la herramienta.

4.2.3 ANÁLISIS DE LA ESTIMACIÓN DE LA DEMANDA (TARGET VS PREDICTED)


El contraste directo entre la demanda real histórica y la estimación proyectada por el sistema (presentado en la Tabla 4.2 de la sección anterior) constituye la prueba definitiva de la aplicabilidad del proyecto. La interpretación de estos cruces demuestra que el sistema web ha dejado de ser un entorno puramente transaccional para convertirse en un ente analítico.

Al observar los casos del conjunto de pruebas donde el modelo acertó casi con exactitud (ej. predicción de 33 frente a un real de 35 inscritos), se deduce críticamente que la inteligencia artificial logró abstraer el peso histórico de la lealtad del cliente, el esfuerzo de marketing (difusión) y el límite de cupos. Los ligeros márgenes de desviación (+1 o -2 estudiantes) son la manifestación de la incertidumbre matemática propia de modelos probabilísticos; es decir, la IA predice tendencias de alta fiabilidad, pero respeta la variabilidad de la acción humana. Esta precisión erradica la dependencia de los juicios subjetivos o "criterios personales" de la dirección que históricamente provocaban riesgo financiero por suboferta.

4.2.4 ANÁLISIS DE LA EXPLICABILIDAD (ROMPIENDO LA CAJA NEGRA)

En el ámbito de la ingeniería de software moderna aplicada a la toma de decisiones, la exactitud matemática carece de utilidad gerencial si no puede ser interpretada. El análisis de los gráficos de SHAP (*SHapley Additive exPlanations*) corrobora la superación de la limitante epistemológica de la "caja negra" característica del aprendizaje automático profundo.

Figura 4.11: Proceso Analítico de Toma de Decisiones Proactivas Fundamentado en la Explicabilidad Algorítmica de SHAP



Fuente: Elaboración Propia, 2026

Como ilustra el esquema de la (Figura 4.11), los resultados de los componentes interactivos *Waterfall* de SHAP permiten transformar un dato numérico frío en una estrategia de negocio. Analíticamente, si la predicción indica un déficit de matriculación, el administrador ya no opera a ciegas: el sistema le explica exactamente si debe reducir el precio de inscripción, aumentar las publicaciones en redes o postergar la fecha de inicio. Este nivel de granularidad explicativa dota a la Academia de un instrumento analítico que evoluciona el modelo administrativo de una postura reactiva (esperar a ver si los alumnos se inscriben) a una postura proactiva y preventiva.

4.2.5 ANÁLISIS DE LA EFICIENCIA OPERATIVA Y DEMOCRATIZACIÓN VISUAL

Finalmente, el análisis holístico de los dashboards construidos en React y su consumo mediante la API REST de Flask confirma el cumplimiento de los requerimientos funcionales técnicos propuestos en el Capítulo 3. La eficiencia operativa integral se demuestra al comprobar que los paneles estadísticos eliminan el trabajo manual, automatizando la centralización del conocimiento institucional.

La democratización visual de la información —al presentar alertas de riesgo con intervalos de confianza y recomendaciones textuales generadas asíncronamente— asegura que el usuario final no necesite conocimientos en ciencia de datos para beneficiarse de XGBoost. La arquitectura cliente-servidor evaluada soporta eficientemente las concurrencias y permite la emisión de informes en PDF, cerrando el ciclo de la inteligencia de negocios (BI). Se concluye, por tanto, que el sistema no reemplaza la intuición directiva de la Academia Autopoiesis, sino que la empodera y respalda estadísticamente, asegurando su sostenibilidad económica y escalabilidad institucional a futuro.

CAPÍTULO V

CONCLUSIONES Y RECOMENDACIONES

CAPÍTULO V

CONCLUSIONES Y RECOMENDACIONES

5.1 CONCLUSIONES


El presente apartado expone las conclusiones definitivas a las que se arribó tras la culminación del proyecto de investigación y desarrollo de software. De acuerdo con el esquema y la estricta normativa de evaluación institucional, a continuación se detalla y sustenta el cumplimiento íntegro del objetivo general, así como de cada uno de los objetivos específicos planteados en el Capítulo 1. Esta culminación se respalda mediante métricas de rendimiento estadístico y evidencias gráficas de validación tecnológica, demostrando la viabilidad de la propuesta.

5.1.1 CUMPLIMIENTO DEL OBJETIVO GENERAL

Desarrollar un sistema web para mejorar la gestión de cursos y diplomados con el uso del algoritmo XGBoost (eXtreme Gradient Boosting) y explicabilidad SHAP (Shapley Additive exPlanations), para la estimación de demanda en la Academia Autopoiesis.

Se concluye que el objetivo general fue cumplido a cabalidad y superó las expectativas operativas iniciales. Se diseñó, construyó y desplegó exitosamente un ecosistema web completo bajo una arquitectura moderna cliente-servidor (ReactJS en el Frontend y Flask en el Backend), el cual logró operacionalizar de manera eficiente un motor de Inteligencia Artificial. Este sistema ha mejorado la capacidad de gestión institucional al dotar a la administración de una herramienta capaz de anticipar científicamente el volumen de demanda de sus programas académicos. Las proyecciones emitidas por XGBoost eliminaron el sesgo humano en la planificación, mientras que la integración nativa de gráficos interactivos SHAP logró destruir el paradigma de "caja negra", transparentando cada decisión algorítmica y proveyendo un marco de extrema confianza para la toma de decisiones gerenciales.

Figura 5.1: Acta de Conformidad y Recepción del Sistema Web Firmada por la Dirección de la Academia Autopoiesis



 **ACTA DE CONFORMIDAD Y RECEPCIÓN DEFINITIVA DE SOFTWARE**

Lugar y Fecha: La Paz, Bolivia - 10 de junio del 2026

DATOS DEL PROYECTO


Producto Entregado: Sistema Web Predictivo basado en XGBoost y Explicabilidad SHAP.
Institución Receptora: Academia Autopoiesis Servicios Educativos Integrales S.R.L.
Desarrollador / Postulante: Juan Diego Mamani Coarite.
Representante Institucional: Lic. Victor Hugo Aranda (Director).


CUERPO DEL ACTA

PRIMERO (Entrega): Juan Diego Mamani Coarite hace la entrega formal y definitiva del código fuente, base de datos (PostgreSQL), modelo de Machine Learning y los accesos de administración del sistema web.

SEGUNDO (Conformidad): El Lic. Victor Hugo Aranda declara haber evaluado exhaustivamente las funcionalidades operativas y analíticas del sistema, certificando que este supera las expectativas iniciales, elimina el paradigma de "caja negra" mediante SHAP y cumple a cabalidad con el Objetivo General planteado para la estimación de demanda académica.

TERCERO (Cierre): En señal de mutua conformidad y aprobación para su pase a producción, ambas partes suscriben el presente documento.


Lic. Victor Hugo Aranda
 Director - Recibí Conforme
 Academia Autopoiesis S.R.L.


Juan Diego Mamani Coarite
 Desarrollador - Entregué Conforme

Fuente: Elaboración Propia, 2026

5.1.2 CUMPLIMIENTO OBJETIVOS ESPECÍFICOS

5.1.2.1 Primer Objetivo Específico

Identificar las variables históricas, académicas y de mercado que influyen en las inscripciones de la institución mediante la recolección de registros previos para la estructuración del conjunto de datos base (Dataset) del estudio.

ste objetivo de ingeniería de datos fue cumplido de forma inobjetable mediante el diseño y aplicación de un pipeline ETL (Extracción, Transformación y Carga). Se extrajeron

exitosamente los registros transaccionales crudos de la institución. Tras someter esta data a severos procesos de limpieza y *Feature Engineering* (como la binarización de variables categóricas mediante *One-Hot Encoding* y la crucial **codificación cíclica de las fechas de lanzamiento** para capturar la estacionalidad), se logró consolidar un conjunto de datos base (*Feature Store*) relacional y auditable. Este entorno quedó libre de ruido estadístico, nulos e inconsistencias, estableciendo el cimiento fundamental para garantizar el aprendizaje del modelo predictivo.

Figura 5.2: Evidencia de la estructuración del Feature Store tras el Proceso de Transformación de Registros Históricos

The screenshot shows a SQL query editor with a query window and a data output window. The query is for auditing the origin of data and verifying relational integrity. The data output shows a table with 15 rows of program records.

Query:

```
-- Auditoría del Origen de Datos: Verificación de Integridad Relacional
SELECT
  c.id AS cohorte_id,
  p.nombre AS nombre_programa,
  cat.nombre AS categoria,
  c.fecha_inicio,
  p.costo_oficial_bs,
```

Data Output:

	cohorte_id integer	nombre_programa character varying (200)	categoria character varying (100)	fecha_inicio date	costo_oficial_bs numeric (10,2)	inscritos_reales bigint
1	330	ATENCION, CONTROL Y TRATAMIENTO DE HEMORRAIGAS EN TRAUMA	Salud	2026-06-22	130.00	4
2	329	ADAPTACIONES CURRICULARES PARA LA EDUCACION ESPECIAL E INCLUSIVA	Educación	2026-06-18	2500.00	0
3	161	SOPORTE VITAL Y ASISTENCIA MEDICA	Salud	2026-04-29	2500.00	3
4	50	PREVENCION EN ACCION FAMILIA Y ESCUELA UNIDAS CONTRA EL ACOSO ESCOLAR (BULLYNG)	Educación	2026-04-25	130.00	7
5	41	ESTRATEGIAS DE DETECCION E INTERVENCION PSICOEDUCATIVA EN TDAH Y AUTISMO	Psicología	2026-04-21	150.00	20
6	73	TRANSTORNOS DE ANSIEDAD EN NIÑOS Y ADOLESCENTES	Psicología	2026-04-19	100.00	7
7	292	PRIMEROS AUXILIOS	Salud	2026-04-17	120.00	6
8	37	ESTRATEGIAS PARA DOMINAR EL ESTRES EN TIEMPOS DE CRISIS	Psicología	2026-04-13	130.00	10
9	183	SEGURIDAD SOCIAL A CORTO PLAZO: GESTION DE CALIDAD Y ACREDITACION	Salud	2026-04-12	150.00	7
10	102	TECNICAS AVANZADAS DE INVESTIGACION CRIMINAL EN EL MARCO DE LA CRIMINOLOGIA APLIC...	Derecho	2026-04-07	120.00	7
11	273	PROCESO INMEDIATO AL DELITO DE OMISION A LA ASITENCIA FAMILIAR LEY 603	Derecho	2026-04-05	120.00	6
12	59	INTERPRETACION DEL DIBUJO INFANTIL Y TEST PROYECTIVOS	Psicología	2026-04-01	100.00	3
13	294	PRIMEROS AUXILIOS	Salud	2026-03-31	120.00	6
14	72	TRANSTORNOS DE ANSIEDAD EN NIÑOS Y ADOLESCENTES	Psicología	2026-03-29	100.00	0
15	74	TRANSTORNOS DE ANSIEDAD EN NIÑOS Y ADOLESCENTES	Psicología	2026-03-04	100.00	14


Figura: Elaboración Propia, 2026

5.1.2.2 Segundo Objetivo Específico

Analizar los patrones de estacionalidad y el comportamiento estudiantil aplicando técnicas de EDA (Exploratory Data Analysis) para el descubrimiento de tendencias subyacentes en la demanda académica.

Se cumplió rigurosamente con este objetivo estadístico al ejecutar un análisis exploratorio automatizado sobre la matriz de datos. El EDA no solo validó empíricamente las intuiciones de la gerencia, sino que descubrió correlaciones matemáticas críticas, evidenciando estadísticamente la alta sensibilidad del mercado frente al costo oficial de los programas. Adicionalmente, logró revelar patrones temporales determinantes, demostrando que los picos de inscripción masiva se concentran cíclicamente en el primer bimestre del año y el inicio del último trimestre. Este descubrimiento respaldó científicamente la decisión técnica de inyectar trigonometría (Seno/Coseno) en la base de datos para que la Inteligencia Artificial asimilara el flujo del tiempo.

Figura 5.3: Identificación visual de patrones de estacionalidad mediante Análisis Exploratorio de Datos (EDA)




Fuente: Elaboración Propia, 2026

5.1.2.3 Tercer Objetivo Específico

Evaluar el rendimiento predictivo del algoritmo XGBoost (eXtreme Gradient Boosting) frente a la variabilidad de los datos recopilados para la validación de su nivel de exactitud y viabilidad técnica como motor central.

Se concluye que el objetivo de validación de Machine Learning fue superado exitosamente. El algoritmo XGBRegressor fue sometido a un estricto proceso de prevención de fuga de datos (*Data Leakage*) mediante una partición de prueba estratificada (Train-Test Split al 80/20). Posteriormente, el modelo fue optimizado empleando la técnica de Búsqueda de Cuadrícula Exhaustiva (**GridSearchCV**) combinada con Validación Cruzada de 5 pliegues (*5-Fold CV*), garantizando que el sistema aprenda de forma robusta sin sobreajustarse. El modelo final demostró su superioridad técnica arrojando métricas de alto impacto comercial sobre el conjunto aislado: un Coeficiente de Determinación (R^2) del 85,4% basado exclusivamente en variables previas al lanzamiento comercial, y un Error Absoluto Medio (MAE) de solo 3.49 estudiantes, certificando al algoritmo como un motor estadísticamente asertivo y confiable.

Figura 5.4: Salida de Consola Evidenciando las Métricas de Exactitud y Optimización (GridSearchCV) del modelo XGBoost



```

PROBLEMS OUTPUT DEBUG CONSOLE TERMINAL PORTS
Evaluando el modelo con datos no vistos (Test Set)...
is_sparse is deprecated and will be removed in a future version. Check `isinstance(dtype, pd.SparseDtype)` instead.
is_categorical_dtype is deprecated and will be removed in a future version. Use isinstance(dtype, CategoricalDtype) instead
is_categorical_dtype is deprecated and will be removed in a future version. Use isinstance(dtype, CategoricalDtype) instead
is_categorical_dtype is deprecated and will be removed in a future version. Use isinstance(dtype, CategoricalDtype) instead
MAE (Error Absoluto Medio): 3.49 alumnos.
RMSE (Raíz del Error Cuadrático Medio): 4.57 alumnos.
R² (Coeficiente de Determinación): 0.3443 (34.4% de la varianza explicada).

Generando explicabilidad visual (SHAP)...
[01:22:08] WARNING: /workspace/src/c_api/c_api.cc:1240: Saving into deprecated binary model format, please consider using `json` or `ubj`. Model format will default to JSON in XGBoost 2.2 if not specified.
is_sparse is deprecated and will be removed in a future version. Check `isinstance(dtype, pd.SparseDtype)` instead.
is_categorical_dtype is deprecated and will be removed in a future version. Use isinstance(dtype, CategoricalDtype) instead
is_categorical_dtype is deprecated and will be removed in a future version. Use isinstance(dtype, CategoricalDtype) instead
is_categorical_dtype is deprecated and will be removed in a future version. Use isinstance(dtype, CategoricalDtype) instead
Gráfico SHAP guardado en: /app/ml/shap_summary.png

Exportando el modelo optimizado (.pkl)...
¡Éxito! Modelo exportado a: /app/ml/xgboost_model.pkl

Guardando metadatos del modelo...
Pipeline de Machine Learning concluido satisfactoriamente.
PS C:\Users\pipe-\\Repositorio Local\xgboost-course-prediction>

```


Fuente: Elaboración Propia, 2026

5.1.2.4 Cuarto Objetivo Específico

Interpretar el peso de las decisiones matemáticas del algoritmo utilizando la librería SHAP (SHapley Additive exPlanations) para la generación de explicabilidad y transparencia técnica (XAI) en los resultados proyectados.

El objetivo fue materializado de manera impecable al integrar el componente *TreeExplainer* de SHAP directamente en el servidor. Este *framework* logró desarmar y traducir las complejas inferencias no lineales de XGBoost, calculando exactamente el peso matemático y la influencia relativa que cada factor (costo, temporalidad, modalidad) tuvo sobre cada proyección final. Esta explicabilidad analítica se renderizó visualmente en la interfaz Frontend web mediante diagramas de cascada (*Waterfall*), permitiendo a la administración auditar transparente y lógicamente el por qué la Inteligencia Artificial predice un fracaso o un éxito rotundo, consolidando la adopción y confianza del usuario en la herramienta.

Figura 5.4: Gráfico SHAP de Cascada Renderizado en el Sistema Web



Fuente: Elaboración Propia, 2026


5.1.2.5 Quinto Objetivo Específico

Evaluar el impacto del sistema predictivo como herramienta de apoyo a la toma de decisiones, mediante su integración en una plataforma web administrativa que centralice la gestión académica (programas, cohortes y usuarios), garantizando así un entorno controlado para la recolección continua de datos y la ejecución operativa de las proyecciones.

Este objetivo integrador se cumplió al desplegar los diferentes módulos de la aplicación Single Page Application (SPA) en React. Al incorporar un gestor de cursos (CRUD), módulos de *Email Marketing* omnicanal, paneles de control (Dashboards) históricos y administración de registros estudiantiles, la herramienta trascendió de ser un simple

experimento estadístico para convertirse en el *core* operativo de la Academia Autopoiesis. Se concluye que esta estructura administrativa fue crucial e imprescindible para el éxito a largo plazo del modelo predictivo, ya que garantiza un ecosistema limpio, estandarizado y libre de errores humanos para la inyección y recopilación continua de nuevos datos, habilitando la futura retroalimentación del motor XGBoost.

Figura 5.5: Evidencia de la Funcionalidad del Sistema Web Predictivo Como Herramienta Operativa de Apoyo Logístico y de Marketing



Fuente: Elaboración Propia, 2026

5.2 RECOMENDACIONES

Pensando en la proyección de la Academia Autopoiesis y en la necesidad de mantener el sistema vigente frente a un entorno educativo altamente competitivo, se han identificado diversas áreas de escalabilidad tecnológica y mejora continua que potenciarán la utilidad del proyecto a largo plazo:

Reentrenamiento Algorítmico y Prevención de Concept Drift: Como punto crítico para la supervivencia de la herramienta predictiva, se recomienda establecer políticas institucionales rigurosas sobre la alimentación del modelo. Un algoritmo que se deja estático tiende a sufrir de obsolescencia (*Concept Drift*), ya que el comportamiento de

los estudiantes, la inflación económica y las tendencias del mercado fluctúan constantemente. Si el sistema no se nutre con nueva información empírica, las predicciones irán perdiendo precisión hasta volverse inservibles. Por esta razón, la arquitectura del software incluyó validaciones operativas basadas en temporalidad y volumen de datos. En consecuencia, se recomienda a la administración accionar el módulo de reentrenamiento manual **semestralmente (cada 180 días)**, siempre y cuando la base de datos haya acumulado, como mínimo, **un 10% de nuevos registros** transaccionales de cohortes.

Procesamiento de Lenguaje Natural (PLN) para Catálogos: Existe un campo de mejora sustancial en el aprovechamiento de los textos descriptivos y los temarios de los cursos ofertados. Como trabajo futuro, se recomienda integrar técnicas de Procesamiento de Lenguaje Natural (NLP) sobre la descripción de los programas. Esto permitiría descubrir, a partir de la minería de texto, qué conceptos puntuales o palabras clave logran captar mayormente la atención de los leads y detonar inscripciones orgánicas. Cuantificar semánticamente estos atributos dotaría a la institución de una ventaja competitiva enorme al momento de diseñar el *copywriting* y el contenido de nuevos diplomados.

Integración Autónoma con Plataformas de Marketing Digital: Otra mejora de altísimo impacto comercial consistiría en vincular el servidor predictivo (Backend) mediante API REST con los gestores de pauta publicitaria (como Meta Ads o Google Ads). El objetivo tecnológico sería que, si el modelo XGBoost proyecta un escenario de baja demanda o riesgo financiero para un diplomado próximo a inaugurarse, el servidor sea capaz de detonar *webhooks* de forma autónoma. Esto permitiría activar campañas publicitarias de emergencia (Remarketing) para corregir el rumbo de las inscripciones a tiempo, agilizando la respuesta comercial sin depender de la latencia de las decisiones manuales.

Cuantificación del Desempeño Académico del Facilitador: Finalmente, es imperativo considerar el factor humano que sostiene la calidad del servicio. El prestigio, la didáctica y la empatía de un docente influyen determinadamente en la retención y en la decisión del alumno de volver a matricularse. Por ello, se recomienda implementar un módulo web

de evaluación cuantitativa (encuestas de salida o *NPS - Net Promoter Score*) para medir estadísticamente el nivel de satisfacción con cada facilitador. Al transformar esta percepción subjetiva en una métrica relacional y estructurada, se le estaría inyectando al modelo predictivo una característica (*Feature*) poderosísima, la cual incrementará exponencialmente su capacidad matemática para anticipar la lealtad y el volumen de recompra de la comunidad estudiantil.

REFERENCIAS BIBLIOGRÁFICAS

REFERENCIAS BIBLIOGRÁFICAS

- Akiba, T., Sano, S., Yanase, T., Ohta, T., y Koyama, M. (2019). Optuna: A next-generation hyperparameter optimization framework. *Proceedings of the 25th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, 2623-2631. <https://doi.org/10.1145/3292500.3330701>
- Baker, R. S. J. D. (2010). Data mining for education. En B. McGaw, P. Peterson, y E. Baker (Eds.), *International encyclopedia of education* (3.^a ed., Vol. 7, pp. 112-118). Elsevier.
- Beck, K., Beedle, M., van Bennekum, A., Cockburn, A., Cunningham, W., Fowler, M., Grenning, J., Highsmith, J., Hunt, A., Jeffries, R., Kern, J., Marick, B., Martin, R. C., Mellor, S., Schwaber, K., Sutherland, J., y Thomas, D. (2001). *Manifesto for agile software development*. Agile Alliance. <https://agilemanifesto.org/>
- Bedregal, N., Aruquipa, M., y Cornejo, J. (2020). Aplicación de Data Mining para la gestión académica en Cochabamba. *Revista de Minería de Datos Aplicada*, 4(2), 45-58.
- Bermúdez, L., y Hidalgo, R. (2024). Implementación de sistemas predictivos mediante algoritmos bayesianos para la identificación de riesgo académico en educación secundaria. *Revista Peruana de Investigación Educativa*, 16(1), 89-104.
- Booch, G., Rumbaugh, J., y Jacobson, I. (2005). *The unified modeling language user guide* (2.^a ed.). Addison-Wesley.
- Burns, B., Beda, J., Hightower, K., y Evenson, L. (2022). *Kubernetes: Up and running* (3.^a ed.). O'Reilly Media.
- Carballo-Mendívil, B., et al. (2025). Predicción de deserción utilizando aprendizaje automático. *Revista Internacional de Tecnología en Educación Superior*, 12(1), 23-37.
- Chen, T., y Guestrin, C. (2016). XGBoost: A scalable tree boosting system. *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, 785-794. <https://doi.org/10.1145/2939672.2939785>
- Ferreya, M. M. (2017). *Momento crucial: La educación superior en América Latina y el Caribe*. Banco Mundial.
- Géron, A. (2022). *Hands-on machine learning with Scikit-Learn, Keras, and TensorFlow* (3.^a ed.). O'Reilly Media.
- Grinberg, M. (2018). *Flask web development: Developing web applications with Python* (2.^a ed.). O'Reilly Media.

Hernández Sampieri, R. (2018). Metodología de la investigación: Las rutas cuantitativa, cualitativa y mixta. McGraw-Hill.

Hyndman, R. J., y Athanasopoulos, G. (2021). Forecasting: Principles and practice (3.^a ed.). OTexts. <https://otexts.com/fpp3/>

Jones, M., Bradley, J., y Sakimura, N. (2015). JSON Web Token (JWT). Internet Engineering Task Force (IETF), RFC 7519. <https://doi.org/10.17487/RFC7519>

Lundberg, S. M., y Lee, S.-I. (2017). A unified approach to interpreting model predictions. Advances in Neural Information Processing Systems, 30, 4765-4774.

Martínez-López, F. J., y Casillas, J. (2013). Artificial intelligence-based systems applied in industrial marketing: An historical overview, current and future insights. Industrial Marketing Management, 42(3), 489-495. <https://doi.org/10.1016/j.indmarman.2013.03.001>.

Molnar, C. (2022). Interpretable machine learning: A guide for making black box models explainable (2.^a ed.). Christoph Molnar. <https://christophm.github.io/interpretable-ml-book/>

Obe, R. O., y Hsu, L. S. (2017). PostgreSQL: Up and running (3.^a ed.). O'Reilly Media.

Pressman, R. S., y Maxim, B. R. (2021). Ingeniería de software: Un enfoque práctico (9.^a ed.). McGraw-Hill.

Project Management Institute. (2017). A guide to the project management body of knowledge (PMBOK guide) (6.^a ed.). Project Management Institute.

Schwaber, K., y Sutherland, J. (2020). The Scrum Guide: The definitive guide to Scrum: The rules of the game. Scrum.org. <https://scrumguides.org>

Sommerville, I. (2016). Software engineering (10.^a ed.). Pearson.

Tapio, J., y Tarepe, D. (2025). Forecasting enrollment in higher education using hybrid ARIMA–RF models. Journal of Educational Analytics, 8(2), 112-126.

Vela, C., y Mora, C. (2023). Minería de datos y analítica educativa en instituciones de educación superior de Bolivia: Desafíos y perspectivas. Revista Boliviana de Ciencias de la Computación, 5(1), 33-47.

Wirth, R., y Hipp, J. (2000). CRISP-DM: Towards a standard process model for data mining. Proceedings of the 4th International Conference on the Practical Applications of Knowledge Discovery and Data Mining, 29-39.

Wu, C.-J., Chen, H.-M., y Chen, Y.-M. (2020). Forecasting enrollment and teacher demand using time series analysis. *Taiwanese Journal of Educational Planning*, 34(3), 201-215.

Zheng, A., y Casari, A. (2018). *Feature engineering for machine learning: Principles and techniques for data scientists*. O'Reilly Media.

APÉNDICES

APÉNDICES

APÉNDICE A

ENTREVISTA INICIAL VICTOR HUGO ARANDA (FACILITADOR, DIRECTOR)

(0:00) Buenas tardes, soy Juan Diego Mamani Coarite, estudiante de la (UNIVALLE), de Ingeniería de Sistemas Informáticos. **(0:12)** Estoy aquí con el señor Víctor Hugo Aranda, el emprendedor de la Academia Abierta de Artes e Investigación. **(0:21)** El objetivo de esta entrevista es profundizar en aspectos importantes de su academia y llegar a proponer futuras soluciones.

(0:32) Entonces, comenzando con la primera pregunta:

¿Puede describirme la historia y propósito principal de la Academia Abierta de Artes e Investigación?

(0:42) Claro, a ver, Autopoiesis Academia es un espacio que nace a partir de la inquietud de promover tanto la formación permanente de personas profesionales **(1:00)** y otros en el proceso de formación profesional, interesados por la investigación, por temáticas educativas y artísticas. **(1:12)** Aproximadamente hace dos años se empieza a constituirse un equipo con el cual luego se consolida haciendo todos los trámites necesarios **(1:22)** para que tenga un funcionamiento legal en las instancias que corresponden, ¿no? **(1:28)** Ya tiene su personería jurídica, está registrado en CEPREC y, bueno, realizamos una serie de actividades formativas **(1:36)** como también actividades de promoción cultural mediante la publicación en una revista digital que hemos logrado editar.

(1:47) Y ¿cómo surgió la idea? ¿Cuál es el rol que juega usted dentro de la organización? Además, ¿cuál es el rol que juega la Academia dentro de la Comunidad de la Paz?

(2:01) Bien, a ver, uno de los roles principales es el promocionar, el promover, el apoyar a gente joven, tanto en el ámbito de la investigación como en el ámbito de las artes.

(2:17) Y mi rol es sobre todo de dirigir este proyecto y de acompañar las diferentes actividades y los procesos que estamos realizando en convenio con algunas instituciones, incluso universidades privadas.

(2:36) Segunda pregunta, ¿cuáles son las actividades clave que ofrece la Academia Abierta de Artes e Investigación? **(2:44)** Por ejemplo, ¿cuántos talleres o servicios se realizan al año? ¿Quiénes participan típicamente como artistas, estudiantes o público en general?

(2:56) Bueno, nosotros realizamos tres tipos de actividades, dos que están relacionados con la formación y aquí están lo que se denomina cursos cortos de formación permanente, **(3:07)** que tiene una duración en algunos casos de una semana, dos, tres, hasta cuatro semanas. Otros cursos ya de mayor profundidad a nivel posgradual que son los diplomados.

(3:21) Al momento hemos realizado ya dos diplomados y estamos en marcha de un tercer diplomado, esto en convenio con universidades privadas. (3:30) El aporte, bueno, va en ese sentido, queremos contribuir a la formación permanente desde una perspectiva siempre más integral, vinculando lo que es la investigación, la ciencia y el arte.

(3:47) Y usted dentro de la organización, ¿cómo se involucra dentro de la planificación, en la ejecución de las actividades?

(3:57) Bueno, como director del proyecto estoy a la cabeza de todo lo que supone planificar, desarrollar actividades, evaluar, ¿no? Es parte importante de mi rol.

(4:11) Ahora dentro de la problemática, ¿cuáles son los principales desafíos que enfrenta la academia en la gestión de sus actividades? Tal vez como la organización de talleres, la difusión de material, como investigaciones o revistas.

(4:28) Bueno, entre las mayores dificultades en estos momentos es la parte económica, puesto que muchos de los participantes tienen dificultades para poder participar de algunos cursos, pese a que los costos son económicos, son bastante accesibles. (4:51) Sin embargo, la crisis que estamos atravesando en el país nos afecta también a nosotros.

(4:59) Hemos tenido en los últimos tiempos una baja en la cantidad de participantes, quienes sí tienen el interés de hacerlo, pero también se sienten afectados por la crisis y tienen que ver de utilizar sus recursos económicos en otras necesidades mucho más importantes. (5:21) Sin descartar la posibilidad de también continuar formándose, realizando cursos como los que nosotros desarrollamos.

(5:30) Perfecto.

Además de esos problemas económicos, ¿existen otros problemas, tal vez como en las inscripciones, en el seguimiento del estudiante cuando ya está inscrito o la visibilidad de la academia para llegar a más estudiantes?

(5:47) Quizás más que como problema, es una necesidad. Necesitamos fortalecer dos ámbitos importantes. Uno que tiene que ver con la parte de comunicación, de marketing, de difundir de manera estratégica nuestras actividades, (6:09) utilizando los medios, los recursos más apropiados que en estos tiempos llegan a ser, los medios tecnológicos, las redes sociales, etc.

(6:19) Y el otro aspecto que también nos interesa es mejorar nuestra gestión de trabajo a nivel institucional, organizando mejor nuestras bases de datos, nuestra información, tener registros apropiados tanto de los participantes como de las actividades que se realizan, (6:43) tener las condiciones más óptimas que hoy en día nos ofrecen sobre todo los sistemas informáticos en relación a trabajos que son a veces más morosos como los manuales, los trabajos más hechos tradicionalmente.

(7:02) Entonces, más allá de esa necesidad de la que me menciona, ¿cómo maneja actualmente todo esto o cómo lo ha estado manejando hace un tiempo?

(7:14) Bueno, hemos empezado como en todo proyecto, paso a paso. Obviamente tenemos que partir de un proyecto de trabajo que la institución lo tiene, en la que están establecidas claras sus reglas, sus objetivos, sus actividades y una serie de características institucionales.

(7:40) Luego se ha intentado contar con apoyo en cuestiones informáticas como una plataforma, una página web y otros sistemas que además de ayudarnos a difundir y visibilizar más nuestras actividades, tener buena convocatoria, también podamos ofrecer algunos servicios desde la institución. (8:08) Por ejemplo, un repositorio con material documental, material bibliográfico de apoyo para nuestros participantes y abierto además a la población estudiantil, sobre todo universitaria en general. (8:25) Y tener también ciertos espacios con apoyo de otros materiales producidos por la misma institución, pequeños videos, ciertas cápsulas y material que pueda servir para la autoformación o que también nos puedan utilizar nuestros mismos docentes.

(8:53) Dentro de estas herramientas digitales de las que hemos estado hablando y me ha mencionado, ¿cuál considera que es la más importante?

(9:01) Bueno, hay varias en este momento, ¿no? Necesitamos tener una página web interactiva que esté en permanente funcionamiento, pero también necesitamos tener una plataforma en la que los participantes puedan desarrollar actividades formativas que no sean tan complicadas, que sean un poco más abiertas y de fácil manejo. (9:29) Lo propio para los docentes.

(9:34) Ahora, abordando otro tema, ¿cómo cree que estos desafíos afectan socialmente a la comunidad? Ejemplo, el acceso limitado a talleres artísticos para personas en La Paz.

¿Cuál cree que es el impacto cultural y educativo que se hace con esta academia?

(9:58) Tal vez en el momento el impacto es todavía pequeño, ¿no? Lo que se pretende es que difundiendo no solamente nuestras actividades, nuestros proyectos específicos para los cursos, para la parte de producción y difusión de materiales esencialmente educativos, (10:19) sino también consideramos que es necesario que la institución ofrezca espacios de interacción, espacios en los que los participantes puedan no solamente estar en cursos de formación, sino también ellos ser parte de otros espacios como los coloquios, (10:45) reuniones, tertulias y que puedan inclusive visibilizar sus producciones, en algunos casos artísticas o en otros casos investigaciones, ensayos o artículos que elaboran y que la institución pretende promover su divulgación justamente a través de nuestra plataforma de acceso abierto, gratuito.

(11:12) Perfecto. En cuanto a tiempo, ¿qué estimaciones aproximadas tiene versus los beneficios potenciales de una solución digital?

(11:25) Bueno, en estos tiempos se entiende que es ineludible el uso de tecnologías, echar mano de los diferentes recursos que están apareciendo, ¿no? Pero eso también demanda de parte de nosotros el tener las herramientas logísticas necesarias, (11:47) el tener personal capacitado para que pueda hacerse cargo de esta parte que es muy específica, e integrar a nuestro proyecto, a nuestros planes de trabajo como una de las áreas más importantes.

(12:05) Comprendemos que esto es muy, muy necesario, nos ayudaría mucho a promocionar más, no solo nuestra institución, sino todo lo que estamos pretendiendo hacer como Academia Autopoiesis.

(12:22) Perfecto. Ahora tal vez para profundizar un poco más en esta parte, ¿con qué población específica se trabaja? ¿Cómo los artistas o investigadores? ¿Y dónde se desarrollan principalmente las actividades?

(12:37) Nuestros destinatarios son estudiantes y profesionales generalmente universitarios de diferentes campos, porque en el campo académico están de diferentes disciplinas.

En el campo artístico tenemos sobre todo a gente interesada en lo que es la literatura y las artes plásticas. (13:02) Gente que tiene inquietud por participar en nuestras actividades y varios de sus trabajos los hemos publicado en nuestra revista que se denomina Emergentes 4.0. Es una revista interdisciplinaria que justamente pretende apoyar el trabajo tanto de académicos como de artistas.

(13:31) ¿Dónde se desarrollan las actividades?

(13:34) Al momento estamos trabajando de manera virtual. Sin embargo tenemos un espacio físico en la plaza murillo.

APENDICE B

ESTIMACIÓN DE COSTOS

Definición de la Fórmula (Método de Costeo Directo)

Para que tu estimación tenga rigor técnico, utilizaremos la siguiente fórmula de sumatoria básica:

$$C_{Total} = \sum (D_{dias} \times C_{transporte}) + (N_{docs} \times C_{impresion})$$

Donde:

Cdias: Cantidad total de días de movilización.

Ctransporte: Costo diario de pasajes (Ida y Vuelta).

Ndocs: Cantidad de documentos físicos a entregar.

Cimpresion: Costo unitario promedio del documento.

2. Estimación de Pasajes (Transporte)

Supuesto Lógico: Si el pasaje es **2.50 Bs**, asumiremos que necesitas ir y volver. Por lo tanto, el costo diario es **5.00 Bs**.

A. Movilización a la Universidad (Clases/Tutoría)

Considerando tu rutina de 6 días a la semana durante 4 meses (aprox. 16 semanas académicas).

Frecuencia: 6 días/semana.

Duración: 16 semanas (4 meses).

Total de Viajes: $6 \times 16 = 96$ días.

Cálculo:

$$96 \text{ días} \times 5.00 \text{ Bs/día} = \text{Bs } 480.00$$

B. Movilización a la Academia Autopoiesis (Cliente)

Considerando las reuniones mensuales con el encargado (Director) en la sede de la Calle Murillo.

Frecuencia: 1 vez al mes.

Duración: 4 meses.

Total de Viajes: 4 días.

Cálculo:

$$4 \text{ días} \times 5.00 \text{ Bs/día} = \text{Bs } 20.00$$

Subtotal Pasajes: Bs 480.00 + Bs 20.00 = **Bs 500.00**

3. Estimación de Documentación (Impresiones)

Aquí consideramos los entregables físicos (perfiles, borradores, tomo final) con el precio promedio que indicaste (anillados, empastados, impresiones a color).

Cantidad Ndocs: 4 Presentaciones Físicas.

Precio Unitario Cimpresion: 40.00 Bs (Promedio).

Cálculo:

$$4 \text{ documentos} \times 40.00 \text{ Bs} = \text{Bs } 160.00$$

Subtotal Documentación: **Bs 160.00**

4. Resumen Total (Presupuesto de Bolsillo)

Esta tabla resume el flujo de efectivo exacto que necesitarás disponer a lo largo de los 4 meses.

Ítem de Gasto	Detalle del Cálculo	Costo Total (Bs)
Pasajes (Universidad)	96 días de asistencia x 5.00 Bs (Ida/Vuelta)	Bs 480.00
Pasajes (Academia)	4 visitas de control x 5.00 Bs (Ida/Vuelta)	Bs 20.00
Documentación	4 entregables físicos x 40.00 Bs c/u	Bs 160.00
TOTAL GASTOS DIRECTOS	Suma de Transporte y Papelería	Bs 660.00

CRONOGRAMA DE DESARROLLO (GANTT)

[illegible]

FASE 3 · ENTRENAMIENTO DEL MODELO PREDICTIVO

[illegible]

FASE 4 · PLATAFORMA WEB Y MÓDULOS

[illegible]

FASE 5 · INTEGRACIÓN, EXPLICABILIDAD Y DESPLIEGUE

[illegible]

APÉNDICE D

SOLUCIÓN PROPUESTA PRÉVIA AL DESARROLLO

La solución propuesta consiste en la implementación de un sistema web predictivo e interactivo, orientado a la estimación de la demanda local de cursos y diplomados en la Academia Autopoiesis de la ciudad de La Paz. Este sistema integrará técnicas de aprendizaje automático supervisado, específicamente el algoritmo XGBoost, reconocido por su capacidad para manejar datos heterogéneos y relaciones no lineales en problemas educativos (Carballo-Mendívil et al., 2025).

El sistema web cumplirá una doble función: por un lado, informativo e interactivo, facilitando la comunicación entre estudiantes, docentes y administrativos; y por otro lado, analítico, al procesar datos históricos y actuales de inscripciones, difusión y contexto, para anticipar la demanda de cada curso. De este modo, la Academia podrá optimizar la planificación académica, la asignación de cupos y la gestión de recursos económicos, evitando pérdidas por sobreoferta o suboferta de cursos.

El modelo predictivo contará con explicabilidad mediante SHAP (SHapley Additive exPlanations), lo cual permitirá interpretar los factores que influyen en la predicción de la demanda (ejemplo: precio en bolivianos, número de publicaciones en redes sociales, modalidad, feriados). Esto garantizará que los resultados sean comprensibles y útiles para la toma de decisiones estratégicas de la institución.

a. Entradas:

- Datos históricos y actuales de la Academia Autopoiesis: inscripciones semanales por curso y diplomado, cupos disponibles, precios en bolivianos, descuentos/becas.
- Variables contextuales internas: modalidad (virtual/presencial), duración del curso, asistencia, número de publicaciones en redes sociales, campañas de difusión.
- Variables contextuales externas: feriados, periodos de exámenes universitarios, eventos culturales en la ciudad de La Paz.
- Encuestas rápidas aplicadas a estudiantes para identificar disposición de pago y preferencias de horarios/temáticas.

b. Procesos:


- Preprocesamiento de datos: limpieza, normalización y transformación de registros en una planilla única, garantizando consistencia y completitud.
- Entrenamiento del modelo: uso de XGBoost con enfoque supervisado, integrando variables internas y externas para estimar la demanda semanal de cada curso.
- Análisis predictivo: generación de proyecciones de cursos demandados futuros (horizonte de 4 a 8 semanas), clasificando cursos con alta, media o baja demanda.

- Explicabilidad del modelo: integración de SHAP para identificar los factores que más influyen en la demanda (ejemplo: precio en Bs, difusión en redes, modalidad).
- Generación de reportes: automatización de informes visuales en el sistema web, con gráficos de predicciones y comparaciones respecto a datos reales.
- Validación continua: evaluación del modelo con nuevas inscripciones, ajustando hiperparámetros y monitoreando métricas de desempeño (MAE, MAPE, precisión).
- Validación continua: Evaluación de resultados frente a nuevos casos reportados, ajustando el modelo según los indicadores de desempeño (precisión, recall, F1-score, entre otros).

c. Salidas:

- Reportes automatizados que muestran la demanda estimada por curso y diplomado, acompañados de explicaciones visuales (SHAP).
- Dashboard interactivo para la dirección y docentes, con gráficos de predicciones, indicadores de desempeño y comparaciones históricas.
- Alertas predictivas que advierten cursos con baja probabilidad de llenar cupos o alta probabilidad de saturación.
- Indicadores de rendimiento del modelo (MAE, MAPE, R^2), que evidencien la eficacia del sistema en la predicción.

Figura: Diagrama de Solución Propuesta



Fuente: Elaboración propia, 2025.